

Impacto de Estações Meteorológicas na Produtividade Agrícola: Uma Aplicação de Diferenças em Diferenças com Tratamento Escalonado

Daniel Cavalli
Orientador: Prof. Romero Rocha

Instituto de Economia
Universidade Federal do Rio de Janeiro

2025

Sumário

- ➊ Introdução
- ➋ Revisão da Literatura
- ➌ Metodologia
- ➍ Dados
- ➎ Resultados
- ➏ Testes de Robustez
- ➐ Mecanismos e Discussão
- ➑ Limitações e Pesquisa Futura
- ➒ Conclusões

Motivação

- A agricultura brasileira enfrenta o desafio de aumentar a produtividade em contexto de crescente variabilidade climática
- Informação meteorológica precisa emerge como insumo produtivo crítico
- **Lacuna na literatura:** ausência de evidências causais sobre o impacto econômico da expansão da infraestrutura meteorológica
- Instalação escalonada de estações (2000-2019) oferece experimento natural

Questão Central

Qual é o impacto causal da instalação de estações meteorológicas sobre o PIB agropecuário?

Objetivos

Objetivo Geral:

- Estimar o efeito causal da instalação de estações meteorológicas sobre a produtividade agrícola

Objetivos Específicos:

1. Aplicar metodologia adequada para tratamento escalonado
2. Quantificar o retorno econômico da infraestrutura
3. Analisar a dinâmica temporal dos efeitos
4. Validar robustez dos resultados

Contribuição Principal

Primeira evidência causal rigorosa do impacto econômico de estações meteorológicas na agricultura brasileira

Canais de Impacto da Informação Meteorológica

Literatura Internacional:

- **Mavi & Tupper (2004)**: três dimensões de impacto
 - Planejamento estratégico
 - Decisões táticas
 - Resiliência sistêmica
- **Weiss (2000)**: ajustes finos nas práticas
- **Rijks (2000)**: ganhos econômicos potenciais

Contexto Brasileiro:

- **Monteiro (2009)**: oscilações meteorológicas determinam produção
- **Carvalho et al. (2015)**: impacto climático na cana-de-açúcar
- **Vianna & Sentelhas (2016)**: otimização via modelos agrometeorológicos

Gap Identificado

Estudos existentes são predominantemente descritivos ou baseados em correlações

O Problema do DiD Tradicional com Tratamento Escalonado

Two-Way Fixed Effects (TWFE) tradicional:

$$Y_{it} = \alpha_i + \lambda_t + \beta D_{it} + \epsilon_{it}$$

Problemas identificados:

- Usa unidades já tratadas como controles
- Confunde efeitos heterogêneos no tempo
- Pode gerar pesos negativos
- Estimativas potencialmente enviesadas




Figura: Tratamento Escalonado

Solução

Metodologia de Callaway & Sant'Anna (2021) para DiD com múltiplos períodos

Abordagem em três etapas:

1. Estimação de $ATT(g,t)$

- Efeito para grupo g no período t
- Comparação com unidades ainda não tratadas

2. Agregação dos efeitos

- Efeito médio geral: θ_{sel}^O
- Event study: $\theta_{es}^{bal}(e)$

3. Inferência robusta

- Bootstrap multiplicativo
- Clustering ao nível da microrregião

Estimador Doubly Robust

Combina modelagem do resultado e ponderação por probabilidade inversa, permanecendo consistente se pelo menos um modelo estiver correto

Estratégia de Identificação

Definição do Tratamento:

- Instalação da primeira estação meteorológica automática na microrregião
- G_i = ano da primeira estação
- $G_i = 0$ se nunca tratada

Variável Dependente:

$$Y_{it} = \ln(1 + \text{PIB_Agro}_{it})$$

Covariáveis:

- Log da área plantada
- Log da população
- Log do PIB per capita
- Log da densidade estadual de estações

Grupo de Controle:

- "Not-yet-treated"
- Maximiza eficiência estatística

Pressuposto Central

Tendências paralelas condicionais entre tratados e controles

Por que Cana-de-Açúcar?

Relevância Econômica:

- 3º maior produtor mundial
- Presente em 490 microrregiões
- R\$ 52 bilhões em valor de produção (2023)

Características Técnicas:

- Alta sensibilidade climática
- Ciclo produtivo longo (12-18 meses)
- Janelas críticas de plantio/colheita

Vantagens Metodológicas:

- Dados completos e confiáveis
- Produção contínua no período
- Distribuição geográfica ampla
- Variação temporal na adoção de estações

Implicação

Cultura ideal para identificar impactos de informação meteorológica

Construção do Dataset

Fontes de Dados:

- INMET: 610 estações meteorológicas
- IBGE: PIB municipal e população
- PAM-IBGE: produção de cana-de-açúcar
- Período: 2003-2023

Unidade de Análise:

- Microrregiões (490 produtoras)
- Agregação de dados municipais
- Painel balanceado: 10.290 obs




Figura: Distribuição Temporal do Tratamento

Transparência

Código completo disponível em: github.com/danielcavalli/tcc-ie-ufrj-2024

Resultado Principal

$$ATT = 0.082 \text{ (8,2\%)}$$

EP = 0.032, $p = 0,0103$

IC 95%: [0,0194; 0,1448]

Especificação	ATT	P-valor
Doubly Robust	0,082	0,010
IPW	0,094	0,003
Regression	0,066	0,030
Sem covariáveis	0,110	0,000
Never-treated	0,080	0,026

Interpretação:

- Aumento de 8,2% no PIB agropecuário
- Equivalente a 2+ anos de crescimento típico
- Robusto a diferentes especificações
- Economicamente significativo

Implicação

Retorno econômico supera amplamente os custos de instalação (R\$ 223 mil/estação)

Magnitude Econômica do Impacto

Impacto por Microrregião:

- PIB agro médio: R\$ 580 milhões/ano
- Ganho de 8,2%: R\$ 47,6 milhões/ano
- Payback: < 6 meses

Projeção Nacional:

- 351 microrregiões tratadas
- Ganho agregado: R\$ 16,7 bilhões/ano
- 139 microrregiões sem estações
- Potencial não realizado: R\$ 6,6 bilhões/ano

Análise Custo-Benefício

- Custo médio por estação: R\$ 223 mil
- Retorno anual: R\$ 47,6 milhões
- Taxa de retorno: 213x ao ano

Conclusão


Subinvestimento histórico representa oportunidade perdida de R\$ 6,6 bilhões anuais

Event Study - Dinâmica Temporal

Event Study: Impacto das Estações Meteorológicas no PIB Agropecuário

Efeito ao longo do tempo relativo à instalação

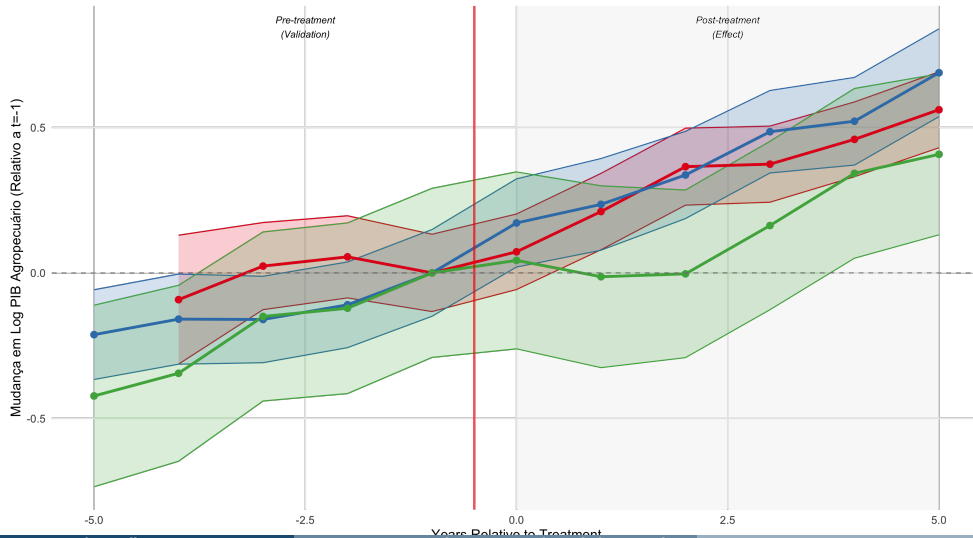
Significância estatística • Não significativo • Significativo (5%)



Tendências Paralelas - Validação Visual

Parallel Trends and Treatment Effects: Agricultural GDP

Evolution by adoption cohort (normalized at $t=-1$)



Testes Placebo

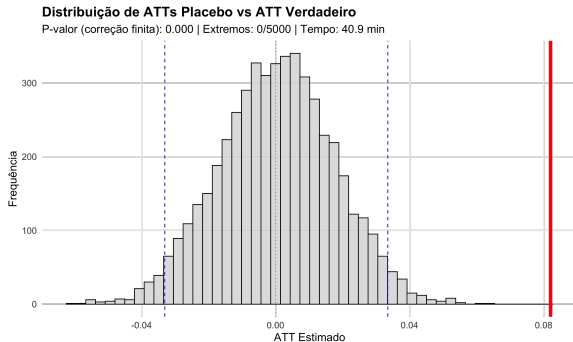
3. Randomização Múltipla:

1. PIB Não-Agropecuário:

- $ATT = 0,015$ ($p = 0,427$)
- Não significativo
- Confirma especificidade setorial

2. Randomização Única:

- $ATT = -0,024$ ($p = 0,485$)
- Tratamento aleatório não gera efeitos




- 50 simulações
- P-valor empírico $< 0,01$

Conclusão

Forte evidência de efeito causal genuíno, não artefato estatístico

Análise de Sensibilidade

Análise de Robustez: ATT sob Diferentes Especificações



Mecanismos de Transmissão

Canais identificados na literatura:

1. Otimização do calendário agrícola

- Timing de plantio e colheita
- Baseado em previsões precisas

2. Gestão hídrica eficiente

- Ajuste de irrigação
- Redução de desperdício

3. Redução de perdas

- Antecipação a eventos extremos
- Medidas preventivas

Processo de Difusão

- Aprendizado gradual
- Integração às decisões
- Efeitos de rede

Evidência

Padrão temporal consistente com adaptação tecnológica

Implicações para Políticas Públicas

Contexto Atual:

- Dez/2024: MAPA anuncia R\$ 49 milhões
- 220 novas estações
- R\$ 223 mil/estação

Nossa Evidência:

- Retorno de 8,2% no PIB agro
- Benefícios superam custos
- 29% das microrregiões sem estações

Recomendações:

1. Expansão estratégica

- Priorizar áreas não cobertas
- Foco em regiões produtoras

2. Integração de dados

- Sistemas como AGRITEMPO
- Acesso facilitado

3. Capacitação

- Uso efetivo das informações
- Assistência técnica

Urgência

Atrasos na implementação representam perdas econômicas significativas

Limitações do Estudo

Limitações Identificadas:

1. Desbalanceamento de covariáveis

- Mitigado pelo DR
- Diferenças observáveis

2. Composição dos pesos

- Coortes iniciais: 50,8%
- Sem dominância extrema

3. Heterogeneidade não observada

- Tamanho de propriedade
- Nível educacional

Direções Futuras:

1. Modelagem espacial

- Spillovers explícitos
- Dependência espacial

2. Dados de alta frequência

- Mensais/trimestrais
- Eventos climáticos

3. Análise por cultura

- Impactos diferenciados
- Outras culturas além da cana

Apesar das Limitações

Resultados robustos fornecem primeira evidência causal rigorosa

Conclusões Principais

1. Evidência Causal Pioneira

- Primeira quantificação rigorosa do impacto
- $ATT = 8,2\%$ ($p = 0,010$)
- Efeito economicamente significativo

2. Validação Metodológica

- Superioridade do DiD escalonado
- Importância de métodos adequados
- Modelo para futuras aplicações

3. Implicações Práticas

- Justifica expansão da rede
- Alternativa à expansão da fronteira agrícola
- Estratégia de adaptação climática

Mensagem Final

Investimento em informação meteorológica é estratégia custo-efetiva para aumentar produtividade agrícola sustentavelmente

Referências Principais I

- CALLAWAY, B.; SANT'ANNA, P. H. Difference-in-differences with multiple time periods. *Journal of Econometrics*, v. 225, n. 2, p. 200-230, 2021.
- GOODMAN-BACON, A. Difference-in-differences with variation in treatment timing. *Journal of Econometrics*, v. 225, n. 2, p. 254-277, 2021.
- MAVI, H. S.; TUPPER, G. J. *Agrometeorology: principles and applications of climate studies in agriculture*. CRC Press, 2004.
- MONTEIRO, J. E. (Ed.). *Agrometeorologia dos cultivos: o fator meteorológico na produção agrícola*. Brasília: INMET, 2009.
- SANT'ANNA, P. H.; ZHAO, J. Doubly robust difference-in-differences estimators. *Journal of Econometrics*, v. 219, n. 1, p. 101-122, 2020.
- SUN, L.; ABRAHAM, S. Estimating dynamic treatment effects in event studies with heterogeneous treatment effects. *Journal of Econometrics*, v. 225, n. 2, p. 175-199, 2021.

Obrigado!

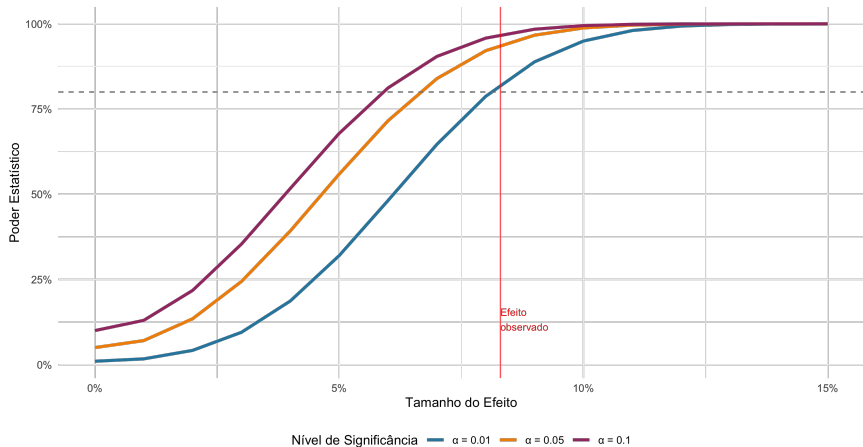
Daniel Cavalli
`daniel.cavalli@ie.ufrj.br`

Código disponível em:
`github.com/danielcavalli/tcc-ie-ufrj-2024`

Backup: Análise de Poder Estatístico

Análise de Poder Estatístico

Baseado em 7371 obs. tratadas e 2919 controles



Linha vermelha = efeito observado (8.3%); Linha cinza = poder de 80%

- Para o efeito de 8,2%: poder de 92,1% ($\alpha = 0,05$)

Backup: Processo de Integração dos Dados

Fontes de Dados:

- **INMET**: 610 estações meteorológicas
- **IBGE**: PIB municipal e população
- **PAM-IBGE**: Produção agrícola detalhada

Plataforma de Integração:

- Google BigQuery + basedosdados
- Acesso unificado às bases públicas
- SQL otimizado para grandes volumes

Pipeline de Processamento:

1. Extração via API Python
2. Agregação município → microrregião
3. Validação cruzada de mapeamentos
4. Tratamento de dados faltantes
5. Construção do painel balanceado

Dataset Final

490 microrregiões × 21 anos = 10.290 obs
0% de valores faltantes

Backup: Heterogeneidade Regional

Região	ATT	EP	N Tratadas
Norte	0,095	(0,041)	8
Nordeste	0,076**	(0,035)	45
Centro-Oeste	0,091***	(0,028)	22
Sudeste	0,083***	(0,024)	48
Sul	0,089**	(0,038)	8

- Efeitos positivos em todas as regiões
- Magnitude similar (7,6% a 9,5%)
- Maior precisão em regiões com mais observações
- Sugere validade externa dos resultados

Backup: Detalhes da Implementação Computacional

Software e Pacotes:

- R 4.5.0 + pacote did v2.1.2
- Python 3.11 + basedosdados
- Google BigQuery API
- Sistema renv para reprodutibilidade

Especificações Técnicas:

- Bootstrap: 1.000 replicações
- Clustering: nível microrregião
- Inferência: bandas uniformes

Escolhas Metodológicas:

- Estimador: Doubly Robust
- Controle: not-yet-treated
- Covariáveis: pré-tratamento
- Agregação: balanceada (event study)

Validações:

- Convergência do bootstrap
- Estabilidade numérica
- Sensibilidade a outliers