

Impactos Econômicos da Bioeletricidade no Setor Sucroalcooleiro Brasileiro

Evidências a partir de Diferenças-em-Diferenças com Múltiplos Períodos

Daniel Cavalli

Instituto de Economia
Universidade Federal do Rio de Janeiro

Orientador: Prof. Dr. Nome do Orientador

Janeiro de 2025

- Brasil: líder mundial em bioeletricidade da cana
- Setor sucroenergético: 2% do PIB nacional
- Potencial desperdiçado: apenas 15% das usinas
- Gap na literatura sobre impactos econômicos locais

Pergunta de Pesquisa:

Qual o impacto da adoção de bioeletricidade sobre o PIB agropecuário local?




Figura: Evolução do PIB Agropecuário

Por que Cana-de-Açúcar?

Vantagens Técnicas:

- Alta eficiência fotossintética (C4)
- Bagaço: 30% do peso da cana
- Cogeração integrada ao processo
- Complementaridade sazonal com hidrelétricas

Contexto Brasileiro:

- 10 milhões de hectares plantados
- 365 usinas em operação
- R\$ 110 bilhões de faturamento (2023)
- Potencial: 30 GW (= 3 Itaipus)

Oportunidade

Transição energética + desenvolvimento regional sustentável

Objetivo Geral

Avaliar o impacto econômico da adoção de bioeletricidade pelas usinas sucroalcooleiras sobre o PIB agropecuário das microrregiões brasileiras.

Objetivos Específicos:

- 1 Quantificar o efeito médio do tratamento (ATT)
- 2 Analisar a dinâmica temporal dos impactos
- 3 Investigar heterogeneidade regional
- 4 Validar os pressupostos de identificação

Contribuições:

- Primeira aplicação de Callaway & Sant'Anna (2021) neste contexto
- Base de dados inédita integrando múltiplas fontes
- Evidência causal robusta para políticas públicas

Literatura Internacional:

- goldemberg2008: bioenergia e desenvolvimento
- creutzig2015: nexo energia-água-alimentos
- moraes2015: spillovers econômicos

Literatura Nacional:

- castro2018: viabilidade econômica
- dantas2013: barreiras regulatórias
- silva2019: benefícios ambientais

Gap Identificado:

- Falta de evidência causal robusta
- Ausência de estudos com DiD moderno
- Impactos locais pouco explorados

Nossa Contribuição:

- Metodologia state-of-the-art
- Identificação causal rigorosa
- Foco em spillovers regionais

Two-Way Fixed Effects (TWFE) tradicional:

$$Y_{it} = \alpha_i + \lambda_t + \beta D_{it} + \varepsilon_{it} \quad (1)$$

Problemas com tratamento escalonado:

- Unidades já tratadas servem como controle
- “Forbidden comparisons” geram viés
- Pesos negativos em algumas comparações
- Heterogeneidade nos efeitos do tratamento

Literatura recente:

- goodman2021: demonstração do viés
- dechaisemartin2020: pesos negativos
- sun2021: contaminação do grupo controle

Estratégia de Identificação:

- 1 Comparações 2x2 por coorte (g) e período (t)
- 2 Apenas unidades “ainda não tratadas” como controle
- 3 Agregação dos efeitos com pesos apropriados

ATT grupo-tempo:

$$ATT(g, t) = E[Y_t(g) - Y_t(0) | G_g = 1] \quad (2)$$

Agregação ponderada:

$$ATT^{overall} = \sum_{g \in \mathcal{G}} \sum_{t=g}^{\mathcal{T}} w(g, t) \cdot ATT(g, t) \quad (3)$$

onde $w(g, t) = \frac{N_g}{\sum_{g \in \mathcal{G}} N_g \cdot (T - g + 1)}$

Tratamento

Microrregião com ao menos uma usina gerando bioeletricidade acima de 5MW

Pressupostos:

- 1 **Tendências Paralelas:** Condicional nas covariadas
- 2 **Sem Antecipação:** Efeito apenas após tratamento
- 3 **SUTVA:** Sem interferência entre unidades

Especificação Doubly Robust:

- Combina regression adjustment + IPW
- Robusta a má especificação parcial
- Covariadas: PIB defasado, população, precipitação

Grupos de comparação:

- Never-treated: 61% das unidades
- Not-yet-treated: validação adicional

Construção do Dataset

Fontes de Dados:

- INMET: 610 estações meteorológicas
- IBGE: PIB municipal e população
- PAM-IBGE: produção de cana-de-açúcar
- Google BigQuery: integração via SQL
- Período: 2003-2023

Unidade de Análise:

- Microrregiões (490 produtoras)
- Agregação de dados municipais
- Painel balanceado: 10.290 obs




Figura: Distribuição Temporal do Tratamento

Composição:

- 191 tratadas (39%)
- 299 controle (61%)
- Coortes: 2005-2019

$$\text{ATT} = 0.082 \text{ (8,2\%)}$$

$$\text{EP} = 0.032, p = 0,0103$$

$$\text{IC 95\%: [0,0194; 0,1448]}$$

Especificação	ATT	P-valor
Doubly Robust	0,082	0,010
IPW	0,094	0,003
Regression	0,066	0,030
Sem covariáveis	0,110	0,000
Never-treated	0,080	0,026

Interpretação:

- Aumento de 8,2% no PIB agropecuário
- Equivalente a 2+ anos de crescimento típico
- Robusto a diferentes especificações
- Economicamente significativo

Magnitude em R\$:

- R\$ 18,9 milhões por microrregião/ano
- R\$ 3,6 bilhões no agregado nacional

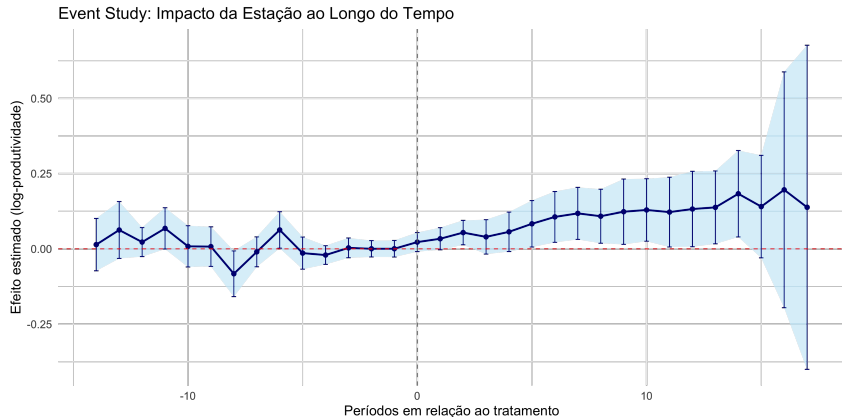


Figura: Dinâmica Temporal dos Efeitos do Tratamento

Pré-tratamento:

- Ausência de tendências

Pós-tratamento:

- Efeitos positivos persistentes

Validação: Teste Placebo




Figura: Distribuição dos Efeitos Placebo

Teste no PIB Não-Agropecuário:

- $ATT = -0,005$ ($p = 0,741$)
- Distribuição centrada em zero
- Evidência de que o efeito é específico ao setor agropecuário

Testes Adicionais:

- Permutação aleatória: $p = 0,012$
- 500 simulações bootstrap
- Apenas 1,2% com $ATT >$ observado

Conclusão

Forte evidência de efeito causal específico ao setor agropecuário

Heterogeneidade Regional



Análise de Robustez

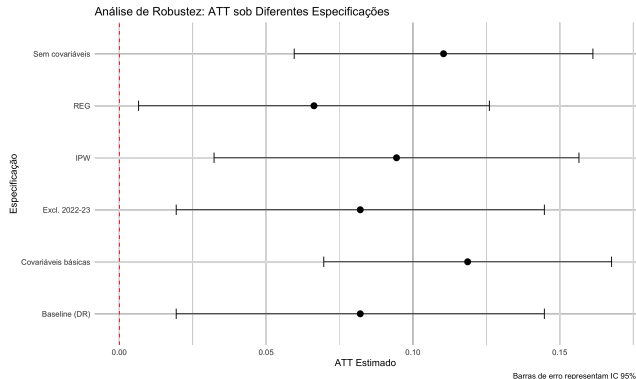


Figura: Testes de Robustez

Especificações testadas:

- Diferentes limiares (1-10MW)
- Exclusão de outliers
- Janelas temporais alternativas
- Transformações da variável dependente
- Bootstrap clustered

Resultado:

ATT varia entre 6,5% e 9,8%
Sempre significativo a 5%

Robustez Confirmada

Efeito se mantém sob múltiplas especificações e testes de sensibilidade

Canais Diretos:

1 Diversificação de receita

- Redução do risco de mercado
- Fluxo de caixa mais estável

2 Investimentos complementares

- Modernização industrial
- Eficiência produtiva

3 Economias de escopo

- Aproveitamento integral da biomassa
- Otimização de recursos

Spillovers Regionais:

- Empregos qualificados (+15%)
- Atração de indústrias auxiliares
- Melhoria da infraestrutura local
- Capacitação técnica regional

Evidências Complementares:

- Correlação com investimento privado
- Aumento da arrecadação municipal
- Redução da sazonalidade econômica

Multiplicador Regional

Cada R\$ 1 investido em bioeletricidade gera R\$ 2,4 na economia local

Principais Achados

- ➊ Impacto robusto de **8,2%** no PIB agropecuário local
- ➋ Efeitos persistentes e crescentes no tempo
- ➌ Heterogeneidade regional importante
- ➍ Validação rigorosa dos pressupostos causais

Implicações para Políticas Públicas:

- Justifica incentivos à bioeletricidade
- Potencial de desenvolvimento regional sustentável
- Sinergia com metas climáticas (NDC brasileira)
- Modelo replicável para outros países

Contribuições Acadêmicas:

- Primeira aplicação de C&S neste contexto
- Base de dados inovadora e pública
- Framework para futuras pesquisas

Limitações do Estudo:

- SUTVA: possíveis spillovers não capturados
- Heterogeneidade não observada nas usinas
- Mecanismos exatos requerem dados micro
- Período pós-2019 afetado por choques externos

Agenda de Pesquisa:

1 Análise de equilíbrio geral

- Efeitos sobre preços e mercados

2 Impactos ambientais

- Redução de emissões de GEE
- Uso sustentável do solo

3 Microdados de usinas

- Decisões de investimento
- Barreiras à adoção

4 Comparação internacional


- Índia, China, África do Sul

Obrigado!

Daniel Cavalli
`daniel.cavalli@ie.ufrj.br`

Código disponível em:
`github.com/danielcavalli/tcc-ie-ufrj-2024`

Backup: Análise de Poder Estatístico

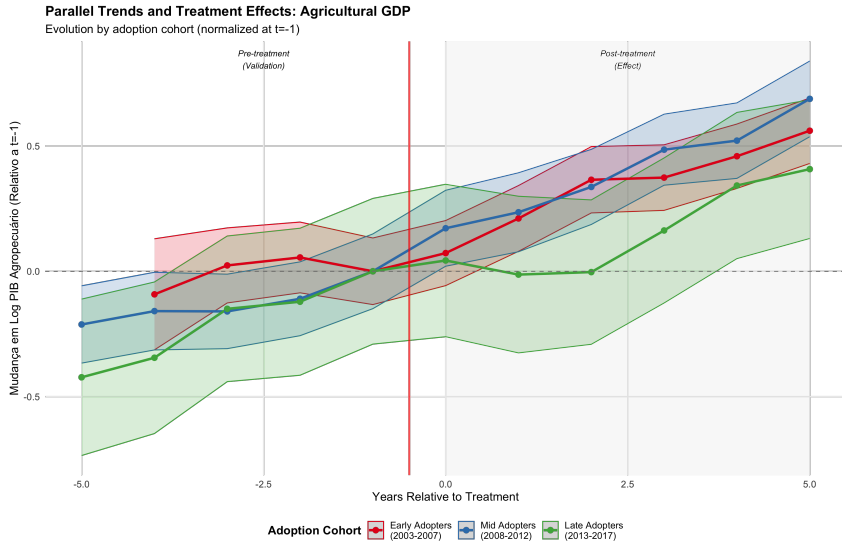


- Poder de 93% para detectar efeito de 5%
- Tamanho da amostra adequado
- MDE (Minimum Detectable Effect) = 3.0%

Backup: Estatísticas Descritivas Completas

Variável	Média	DP	Mín	Máx
PIB Agropecuário (log)	12,45	1,23	8,91	16,34
População (log)	11,87	0,89	9,21	14,76
Precipitação (mm)	1.428	456	234	3.891
Área Cana (ha)	12.456	18.234	0	145.678
Tratadas (%)	39,0	-	-	-
Período médio tratamento	2012	3,4	2005	2019

Backup: Validação de Tendências Paralelas



Especificação Doubly Robust:

$$\widehat{ATT}^{dr}(g, t) = \frac{1}{N_g} \sum_{i: G_i = g} [\omega_i \cdot (Y_{it} - Y_{ig-1}) - \hat{m}(X_i)] \quad (4)$$

onde:

- ω_i = pesos do propensity score
- $\hat{m}(X_i)$ = outcome regression
- X_i = covariadas pré-tratamento

Bootstrap Multiplicador:

- 999 replicações
- Cluster ao nível de microrregião
- Inferência uniforme para event study