

Daniel Cavalli

**IMPACTO DE ESTAÇÕES  
METEOROLÓGICAS NA PRODUTIVIDADE  
AGRÍCOLA: UMA APLICAÇÃO DE  
DIFERENÇAS EM DIFERENÇAS COM  
TRATAMENTO ESCALONADO**

Rio de Janeiro

Dezembro 2025

Daniel Cavalli

# **IMPACTO DE ESTAÇÕES METEOROLÓGICAS NA PRODUTIVIDADE AGRÍCOLA: UMA APLICAÇÃO DE DIFERENÇAS EM DIFERENÇAS COM TRATAMENTO ESCALONADO**

Monografia apresentada ao Instituto de Economia da Universidade Federal do Rio de Janeiro como parte dos requisitos necessários à obtenção do título de Bacharel em Ciências Econômicas.

UNIVERSIDADE FEDERAL DO RIO DE JANEIRO  
INSTITUTO DE ECONOMIA  
CURSO DE GRADUAÇÃO EM CIÊNCIAS ECONÔMICAS

Orientador: Prof. Romero Rocha

Rio de Janeiro  
Dezembro 2025

Daniel Cavalli

# **IMPACTO DE ESTAÇÕES METEOROLÓGICAS NA PRODUTIVIDADE AGRÍCOLA: UMA APLICAÇÃO DE DIFERENÇAS EM DIFERENÇAS COM TRATAMENTO ESCALONADO**

Monografia apresentada ao Instituto de Economia da Universidade Federal do Rio de Janeiro como parte dos requisitos necessários à obtenção do título de Bacharel em Ciências Econômicas.

Trabalho aprovado. Rio de Janeiro, 14 de novembro de 2025:

---

**Prof. Romero Rocha**  
Orientador

---

**Professor**  
Convidado 1

---

**Professor**  
Convidado 2

Rio de Janeiro  
Dezembro 2025

# Agradecimentos

Agradeço à minha família, que sempre me apoiou durante toda a graduação sem nunca me pressionar além do necessário. Vocês foram fundamentais para que eu pudesse acumular o conhecimento necessário para montar este trabalho.

À minha namorada, Juliana, obrigado por me incentivar a terminar a faculdade e o TCC quando eu já não tinha mais vontade ou razão para tal. Seu apoio fez toda a diferença em me convencer da importância disso.

À minha cachorra, Moana, companheira fiel de tantas horas de escrita, modelagem e análise de dados. Sua presença tornou as longas madrugadas de trabalho muito mais suportáveis.

À Cláudia.

*“In mathematics you don’t understand things.  
You just get used to them.”*  
(John von Neumann)

# Resumo

Este estudo examina o impacto causal da instalação de estações meteorológicas automáticas sobre a área plantada de cana-de-açúcar no Brasil, utilizando dados em painel de 558 microrregiões brasileiras entre 2003 e 2021. As medidas de área plantada provêm do Map-Biomas, derivadas de imagens de satélite processadas sistematicamente ao longo de todo o período analisado. A estratégia de identificação emprega o arcabouço de Diferenças em Diferenças com adoção escalonada de Callaway e Sant'Anna (2021), explorando a variação temporal e geográfica na instalação de estações entre microrregiões eventualmente tratadas. O método "not-yet-treated" fornece o grupo de controle dinâmico, comparando unidades já tratadas apenas com aquelas ainda não tratadas em cada período. Através do estimador doubly robust, encontramos um Efeito Médio do Tratamento sobre os Tratados (ATT) de 11,8% (IC 95%: [3,5%; 20,1%],  $p = 0,0053$ ), indicando expansão significativa na área dedicada ao cultivo de cana-de-açúcar. A ausência de tendências pré-tratamento diferenciadas, revelada pela análise de event study, valida a estratégia de identificação, enquanto testes extensivos de robustez confirmam a validade causal: randomização múltipla com 5.000 permutações ( $p$ -valor empírico  $< 0,001$ ), especificações alternativas (IPW: 12,2%, REG: 11,4%), ausência de efeitos sobre culturas alternativas (soja, arroz) e PIB não-agropecuário, além de estabilidade temporal dos resultados. O mecanismo identificado relaciona-se ao melhor planejamento de irrigação, recurso crítico para a cana-de-açúcar, viabilizando expansão da área cultivada em regiões anteriormente marginais. Complementarmente aos resultados substantivos, o trabalho documenta detalhadamente a implementação do arcabouço de Callaway e Sant'Anna, servindo como referência metodológica para avaliação de políticas públicas com adoção escalonada. A disponibilização completa do código e documentação reforça o compromisso com transparência e reprodutibilidade na pesquisa econométrica aplicada.

Palavras-chave: estações meteorológicas. área plantada. cana-de-açúcar. MapBiomas. irrigação. diferenças em diferenças escalonada. Callaway e Sant'Anna. informação climática. avaliação de políticas públicas.

# Abstract

This study examines the causal impact of automatic weather station installation on sugarcane planted area in Brazil, using panel data from 558 Brazilian microregions between 2003 and 2021. Planted area measurements come from MapBiomass, derived from systematically processed satellite imagery throughout the analyzed period. The identification strategy employs the staggered adoption Differences-in-Differences framework of Callaway and Sant'Anna (2021), exploiting temporal and geographic variation in station installation among eventually treated microregions. The "not-yet-treated" method provides the dynamic control group, comparing already-treated units only with those not yet treated in each period. Through the doubly robust estimator, we find an Average Treatment Effect on the Treated (ATT) of 11.8% (95% CI: [3.5%; 20.1%],  $p = 0.0053$ ), indicating significant expansion in land dedicated to sugarcane cultivation. The absence of differential pre-treatment trends, revealed by event study analysis, validates the identification strategy, while extensive robustness tests confirm causal validity: multiple randomization with 5,000 permutations (empirical  $p$ -value  $< 0.001$ ), alternative specifications (IPW: 12.2%, REG: 11.4%), absence of effects on alternative crops (soybean, rice) and non-agricultural GDP, and temporal stability of results. The identified mechanism relates to improved irrigation planning, a critical resource for sugarcane, enabling cultivated area expansion in previously marginal regions. In addition to substantive findings, the work comprehensively documents implementation of the Callaway and Sant'Anna framework, serving as a methodological reference for public policy evaluation with staggered adoption. Complete code and documentation availability reinforces commitment to transparency and reproducibility in applied econometric research.

Keywords: weather stations. planted area. sugarcane. MapBiomass. irrigation. staggered differences-in-differences. Callaway and Sant'Anna. climate information. policy evaluation. Brazil.

# Lista de ilustrações

Figura 1 – Estudo de Evento - Dinâmica Temporal dos Efeitos da Instalação de Estações Meteorológicas . . . . .	31
Figura 2 – Tendências Paralelas - Área Plantada de Cana-de-Açúcar Normalizada (2003-2021) . . . . .	33
Figura 3 – Distribuição dos ATTs Placebo vs. ATT Verdadeiro . . . . .	38
Figura 4 – Efeitos sobre Variáveis de Resultado Alternativas: Especificidade à Cana-de-Açúcar . . . . .	40
Figura 5 – Análise de Robustez - Comparação de Especificações . . . . .	43
Figura 6 – Distribuição Temporal da Instalação de Estações Meteorológicas . . . .	56
Figura 7 – Tendências do PIB Agropecuário por Quartil de Área Plantada . . . .	58
Figura 8 – Evolução Temporal do PIB Agropecuário vs PIB Não-Agropecuário . .	59
Figura 9 – Matriz de Correlação das Variáveis Principais . . . . .	60

# Lista de tabelas

Tabela 1 – Resultados Principais: Efeito sobre o Logaritmo da Área Plantada de Cana-de-Açúcar . . . . .	30
Tabela 2 – Comparação de Estimativas por Grupo de Controle . . . . .	34
Tabela 3 – Resultados do Teste de Randomização de Monte Carlo . . . . .	37
Tabela 4 – Especificidade do Efeito: Variáveis de Resultado Alternativas . . . . .	39
Tabela 5 – Análise de Sensibilidade ao Período de Análise . . . . .	41
Tabela 6 – Comparação de Métodos de Estimação . . . . .	42
Tabela 7 – Número de microrregiões tratadas por ano . . . . .	57
Tabela 8 – Distribuição do tratamento por região . . . . .	57
Tabela 9 – Produtividade média (ton/ha) por período . . . . .	58

# Sumário

<b>1</b>	<b>INTRODUÇÃO</b>	<b>12</b>
<b>2</b>	<b>METODOLOGIA</b>	<b>15</b>
<b>2.1</b>	<b>Introdução ao Modelo</b>	<b>15</b>
<b>2.2</b>	<b>Fundamentos do modelo</b>	<b>15</b>
2.2.1	Group-Time Average Treatment Effects ATT(g,t)	16
2.2.2	Identificação	16
2.2.2.1	Validade dos Pressupostos no Contexto de Estações Meteorológicas	17
2.2.3	Estimação	17
2.2.4	Procedimentos de Inferência	18
2.2.5	Agregação de Efeitos	18
2.2.5.1	Agregação Simples com Pesos Positivos	18
2.2.5.2	Efeito Médio do Tratamento sobre os Tratados (Recomendado)	19
2.2.5.3	Agregações para Event Studies	19
<b>2.3</b>	<b>Especificação do Modelo</b>	<b>19</b>
2.3.1	Definição do Tratamento e Unidades de Análise	20
2.3.2	Construção dos Grupos de Tratamento	21
2.3.3	Variável Dependente e Transformações	21
2.3.4	Covariáveis e Especificação do Modelo	22
2.3.5	O Estimador Duplamente Robusto	23
2.3.6	Escolha do Grupo de Controle	24
<b>2.4</b>	<b>Especificação da Análise de Estudo de Evento</b>	<b>24</b>
2.4.1	Formalização da Análise de Estudo de Evento	25
<b>3</b>	<b>RESULTADOS</b>	<b>26</b>
<b>3.1</b>	<b>Implementação Computacional</b>	<b>26</b>
3.1.1	Software e Pacotes Utilizados	26
3.1.2	Transparência e Reprodutibilidade	26
3.1.3	Estrutura dos Dados e Processo de Extração	27
3.1.3.1	Fontes de Dados e Extração	27
3.1.3.2	Construção do Painel	28
3.1.3.3	Construção das Variáveis de Tratamento	28
3.1.3.4	Tratamento de Dados Faltantes e Qualidade	29
<b>3.2</b>	<b>Resultados Principais</b>	<b>29</b>
3.2.1	Efeito Médio do Tratamento	29
3.2.1.1	Interpretação da Robustez dos Resultados	30

3.2.2	Análise de Estudo de Evento e Dinâmica Temporal . . . . .	31
3.2.2.1	Período Pré-Tratamento: Validação das Tendências Paralelas . . . . .	31
3.2.2.2	Dinâmica Pós-Tratamento: Difusão Gradual dos Benefícios . . . . .	33
3.2.2.3	Análise Detalhada de Tendências Paralelas por Grupos de Timing . . . . .	33
<b>3.3</b>	<b>Testes de Robustez e Diagnósticos . . . . .</b>	<b>34</b>
3.3.1	Sensibilidade ao Grupo de Controle . . . . .	34
3.3.2	Testes Placebo . . . . .	34
3.3.2.1	Teste Placebo com Atribuição Aleatória Fixa . . . . .	35
3.3.2.2	Teste de Randomização de Monte Carlo . . . . .	35
3.3.2.2.1	Formalização do Teste . . . . .	35
3.3.2.2.2	Aspectos Computacionais . . . . .	36
3.3.2.2.3	Implementação e Resultados . . . . .	37
3.3.2.2.4	Interpretação dos Resultados . . . . .	38
3.3.2.3	Especificidade do Efeito: Análise de Variáveis de Resultado Alternativas . . . . .	38
3.3.2.4	Síntese dos Testes Placebo e Especificidade . . . . .	40
<b>3.4</b>	<b>Análises de Robustez Adicionais . . . . .</b>	<b>41</b>
3.4.1	Sensibilidade ao Período de Análise . . . . .	41
3.4.2	Robustez a Diferentes Métodos de Estimação . . . . .	42
3.4.3	Síntese das Análises de Robustez . . . . .	43
<b>3.5</b>	<b>Discussão e Interpretação Econômica . . . . .</b>	<b>44</b>
3.5.1	Contextualização da Magnitude do Efeito . . . . .	44
3.5.2	Mecanismo: Irrigação, Informação Meteorológica e Expansão de Área . . . . .	45
3.5.2.1	Sistemas de Irrigação em Cana-de-Açúcar no Brasil . . . . .	45
3.5.2.2	Informação Meteorológica e Decisões de Timing . . . . .	46
3.5.2.3	Da Produtividade à Expansão de Área: A Margem Extensiva . . . . .	46
3.5.2.4	Por Que Especificidade à Cana-de-Açúcar? . . . . .	47
3.5.3	Limitações e Pesquisa Futura . . . . .	48
3.5.3.1	Desbalanceamento de Covariáveis . . . . .	48
3.5.3.2	Composição dos Pesos no Estimador Agregado . . . . .	48
3.5.3.3	Outras Limitações Importantes . . . . .	49
3.5.3.4	Direções para Pesquisa Futura . . . . .	49
<b>3.6</b>	<b>Síntese dos Resultados Empíricos . . . . .</b>	<b>50</b>
<b>4</b>	<b>CONCLUSÕES FINAIS . . . . .</b>	<b>51</b>
	<b>REFERÊNCIAS . . . . .</b>	<b>52</b>

	<b>APÊNDICES</b>	<b>54</b>
	<b>APÊNDICE A – CÓDIGO DO GITHUB . . . . .</b>	<b>55</b>
	<b>APÊNDICE B – ESTATÍSTICAS DESCRITIVAS COMPLEMEN-</b>	
	<b>TARES . . . . .</b>	<b>56</b>
<b>B.1</b>	<b>Distribuição Temporal do Tratamento . . . . .</b>	<b>56</b>
<b>B.2</b>	<b>Estatísticas por Região . . . . .</b>	<b>57</b>
<b>B.3</b>	<b>Produtividade Média por Status de Tratamento . . . . .</b>	<b>57</b>
<b>B.4</b>	<b>Tendências por Quartil de Área Plantada . . . . .</b>	<b>57</b>
<b>B.5</b>	<b>Análises Descritivas Complementares . . . . .</b>	<b>58</b>

# 1 Introdução

A agricultura brasileira enfrenta o desafio permanente de aumentar a produtividade em um contexto de crescente variabilidade climática. Com a produção agrícola global sendo amplamente determinada por oscilações meteorológicas durante o ciclo produtivo (MONTEIRO, 2009), e as mudanças climáticas já impactando significativamente a produtividade mundial (ORTIZ-BOBEA et al., 2020), a questão central não é mais *se* o clima afeta a agricultura, mas *como* mitigar seus efeitos adversos e aproveitar janelas de oportunidade. Neste contexto, a informação meteorológica precisa emerge como insumo produtivo crítico, potencialmente capaz de transformar incerteza em risco gerenciável.

A literatura documenta extensivamente os canais através dos quais informações meteorológicas podem aumentar a produtividade agrícola. MAVI e TUPPER (2004) identificam três dimensões principais: planejamento estratégico (escolha de culturas e épocas de plantio), decisões táticas (timing de irrigação, aplicação de defensivos) e construção de resiliência sistêmica. WEISS, VAN CROWDER e BERNARDI (2000) demonstram que estações meteorológicas locais permitem ajustes finos nas práticas agrícolas, enquanto RIJKS e BARADAS (2000) quantificam os ganhos econômicos potenciais de serviços meteorológicos bem estruturados. No Brasil, sistemas como AGRITEMPO e SISDAGRO já operacionalizam essas informações, mas sua efetividade depende crucialmente da densidade e qualidade da rede de estações meteorológicas subjacente.

O mecanismo causal pode ser descrito de forma sequencial: a instalação de uma estação meteorológica local gera dados climáticos precisos e em tempo real, que são processados e disponibilizados aos produtores através de boletins, alertas e sistemas de informação. Com acesso a previsões mais precisas sobre temperatura, precipitação e eventos extremos, os agricultores podem otimizar decisões críticas, desde o momento ideal de plantio e colheita até a aplicação precisa de insumos e gestão eficiente de irrigação.

Além do uso direto pelos produtores, esses dados alimentam modelos computacionais avançados de simulação agrícola. Por exemplo, o modelo DSSAT CSM-CANEGRO, amplamente utilizado no setor sucroalcooleiro, integra informações meteorológicas locais para simular o crescimento e desenvolvimento da cana-de-açúcar sob diferentes cenários de manejo. Com dados meteorológicos precisos, o modelo permite aos agricultores testar virtualmente diferentes estratégias de irrigação, identificando configurações ótimas que podem resultar em incrementos de produtividade de até 30%, especialmente em solos mais vulneráveis ao déficit hídrico (VIANNA; SENTELHAS, 2016). Essa capacidade de simular e otimizar decisões antes da implementação no campo representa um salto qualitativo na gestão agrícola.

Essas decisões melhor informadas (seja através do uso direto das previsões ou

através de modelos de simulação alimentados por dados locais) traduzem-se em redução de perdas, aumento de produtividade e, conseqüentemente, expansão da área cultivada e crescimento da atividade agrícola local.

Apesar do consenso teórico sobre a importância da informação meteorológica, existe uma lacuna crítica na literatura: **a ausência de evidências causais robustas sobre o impacto econômico da expansão da infraestrutura de monitoramento climático.** Estudos existentes são predominantemente descritivos ou baseados em correlações, deixando em aberto questões fundamentais: Qual é o retorno econômico da instalação de estações meteorológicas? Como esse impacto evolui ao longo do tempo? Os benefícios justificam os custos de expansão da rede?

A dificuldade em responder essas questões não é trivial. A instalação de estações meteorológicas no Brasil ocorreu de forma escalonada ao longo de duas décadas, com diferentes regiões adotando a tecnologia em momentos distintos. Este padrão de "adoção escalonada" (staggered adoption) invalida o uso de métodos econométricos tradicionais. Como demonstrado por GOODMAN-BACON (2021) e SUN e ABRAHAM (2021), o estimador de Diferenças em Diferenças com Efeitos Fixos Bidimensionais (Two-Way Fixed Effects, TWFE), padrão ouro em avaliações de impacto, produz resultados enviesados neste contexto, pois inadvertidamente usa unidades já tratadas como controles e confunde efeitos heterogêneos ao longo do tempo.

Este trabalho preenche essa lacuna ao estimar o **efeito causal da instalação de estações meteorológicas sobre a área plantada de cana-de-açúcar**, utilizando o arcabouço metodológico de CALLAWAY e SANT'ANNA (2021) para Diferenças em Diferenças com múltiplos períodos. A escolha da área plantada como variável de resultado principal justifica-se por três razões: (i) captura ajustamento na margem extensiva, não apenas intensiva; (ii) medição objetiva via satélite (MapBiomas) evita vieses de dados autorrelatados pelos agentes municipais sobre a produção agrícola local; e (iii) a cana-de-açúcar, dada sua alta dependência de gestão hídrica precisa, constitui o caso ideal para testar o impacto da informação meteorológica. Adicionalmente, testamos o modelo com variáveis de resultado alternativas (PIB agropecuário, soja, arroz, PIB não-agropecuário) para demonstrar a especificidade do efeito.

Nossa análise revela que a instalação de estações meteorológicas gera uma expansão de **11.8% na área plantada de cana-de-açúcar** nas microrregiões tratadas (efeito estimado sobre o logaritmo da área). Os resultados mostram-se robustos a múltiplas especificações alternativas e análises de sensibilidade, enquanto testes placebo com outras culturas e PIB não-agropecuário confirmam a especificidade do efeito, fornecendo evidência causal sólida sobre a efetividade desta infraestrutura informacional.

As contribuições deste trabalho são quádruplas:

1. evidência causal pioneira: primeira quantificação rigorosa do impacto econômico de estações meteorológicas na agricultura brasileira, preenchendo uma lacuna crítica para políticas públicas baseadas em evidências.
2. avanço metodológico: demonstração da aplicabilidade e importância dos novos métodos de DiD escalonado em contextos agrícolas, contribuindo para a literatura metodológica aplicada.
3. caracterização da dinâmica temporal: documentação do processo de difusão e aprendizado, com implicações para avaliação de investimentos em infraestrutura meteorológica.
4. subsídios para expansão da rede: evidências de que o retorno social supera amplamente os custos, justificando a expansão da infraestrutura meteorológica como estratégia de adaptação climática e aumento de produtividade.

Nossos resultados dialogam com desenvolvimentos recentes na literatura. [BURKE et al. \(2021\)](#) argumentam que avanços em tecnologias de informação representam uma das principais fronteiras para aumentar a produtividade agrícola no século XXI. [MONTEIRO e SENTELHAS \(2017\)](#) demonstram a importância de modelos agrometeorológicos para identificação de gaps de produtividade na agricultura brasileira. [CROST et al. \(2018\)](#) e [GATTI, BAYLIS e CROST \(2021\)](#) demonstram, usando métodos similares aos nossos, como infraestrutura pode mitigar impactos climáticos. Este trabalho contribui para essa literatura emergente ao fornecer a primeira evidência causal direta sobre estações meteorológicas.

O restante deste trabalho está organizado da seguinte forma. A Seção 2 apresenta a metodologia completa, incluindo o arcabouço de Diferenças em Diferenças com múltiplos períodos de [CALLAWAY e SANT'ANNA \(2021\)](#), a estratégia empírica, definição do tratamento, variáveis e especificação do modelo. A Seção 3 apresenta os resultados, começando pela implementação computacional e seguindo com os efeitos estimados, análises de robustez e testes de validação. A Seção 4 conclui com implicações para políticas públicas e direções para pesquisa futura.

## 2 Metodologia

Para este trabalho, utilizaremos como principal referência o artigo de [CALLAWAY e SANT'ANNA \(2021\)](#), que apresenta uma extensão do modelo de Diferenças em Diferenças (DiD) para cenários com múltiplos períodos e momentos distintos de adoção do tratamento.

### 2.1 Introdução ao Modelo

No DiD clássico, assume-se um grupo tratado que recebe a intervenção em um momento específico e um grupo controle que nunca é tratado. Sob essa configuração, a diferença no tempo entre pré e pós-tratamento e a diferença entre grupos tratado e controle fornecem a estimativa do efeito causal. Entretanto, para o caso analisado neste trabalho há múltiplos períodos e vários grupos recebendo o tratamento em momentos distintos ao longo dos 22 anos do período de análise. A abordagem de DiD tradicional, nesse caso, pode gerar estimativas enviesadas devido à heterogeneidade do tratamento ao longo do tempo, resultando em interpretação ambígua.

O modelo de [CALLAWAY e SANT'ANNA \(2021\)](#) surge como uma forma de permitir que esses cenários de tratamento escalonado, frequentemente mais comuns no mundo real do que experimentos naturais, possam ser avaliados adequadamente. Por permitir a identificação de efeitos médios do tratamento específicos para cada grupo e período, acomoda a heterogeneidade do momento de adoção e suas dinâmicas, além de fornecer uma interpretação mais clara dos parâmetros causais.

### 2.2 Fundamentos do modelo

O modelo proposto pode ser entendido em três etapas conceituais:

1. **Identificação de parâmetros causais desagregados:** Primeiro, são obtidas estimativas do efeito causal para cada combinação de grupo tratado e período após a adoção (denotados por  $ATT(g,t)$ ), focando em captar o efeito específico para um determinado conjunto de unidades tratadas em um dado momento do tempo.
2. **Agregação desses parâmetros:** Em seguida, esses parâmetros individuais, definidos para grupos e períodos específicos, podem ser combinados para produzir medidas resumidas de efeitos, como efeitos médios globais, ao longo do tempo, por coorte de tratamento ou segundo o tempo decorrido desde a intervenção.

3. **Estimação e inferência:** Por fim, procedimentos estatísticos são empregados para estimar esses parâmetros, bem como inferir sobre sua significância estatística.

### 2.2.1 Group-Time Average Treatment Effects $ATT(g,t)$

O parâmetro fundamental dessa abordagem é o  $ATT(g,t)$ , que representa o Efeito Médio do Tratamento para o grupo  $g$  no período  $t$ . Ao contrário do DiD tradicional, onde há um único efeito estimado, aqui obtemos uma coleção de efeitos, cada um refletindo o impacto do tratamento em um grupo que começou a ser tratado em um determinado momento e está sendo avaliado em um período específico após o início do tratamento.

Com isso é possível capturar heterogeneidades relacionadas:

- Ao grupo (unidades diferentes podem ter características e contextos distintos);
- Ao momento de início do tratamento (tratamentos iniciados em diferentes épocas podem ter efeitos variados devido a condições econômicas, políticas ou sociais);
- Ao tempo decorrido desde o tratamento (efeitos imediatos versus efeitos de longo prazo podem diferir).

### 2.2.2 Identificação

O artigo de [CALLAWAY e SANT'ANNA \(2021\)](#) apresenta uma série de pressupostos para identificação dos parâmetros causais. Boa parte delas não difere muito dos pressupostos do DiD tradicional. Abaixo destaco algumas importantes mudanças:

1. **Tendências Paralelas Condicionais:** A ideia central do DiD é que, na ausência de tratamento, as unidades tratadas seguiriam a mesma tendência de evolução dos resultados das unidades não tratadas. Existem diferenças conceituais entre o DiD tradicional e o DiD Staggered:
  - **Pressuposto 4 - “never-treated”:** Aqui, o grupo de comparação é formado por unidades que nunca recebem tratamento ao longo de todo o período observado. Pressupõe-se que, condicionalmente a covariáveis observáveis, esses “never-treated” representam a contrafactual apropriada para o que teria acontecido com os grupos tratados caso não tivessem sido tratados.
  - **Pressuposto 5 - “not-yet-treated”:** Nesse caso, o grupo de controle para um determinado período e grupo tratado é formado por unidades que ainda não foram tratadas até aquele momento, mas que virão a ser tratadas no futuro. Essa abordagem aproveita a natureza escalonada do tratamento para criar um grupo de comparação internamente consistente.

2. **Pressuposto 3 - Antecipação Limitada do Tratamento:** Admite-se que as unidades não são afetadas pelo tratamento antes de sua efetiva implementação, ou que se conheçam efeitos de antecipação limitados e controláveis. Caso haja antecipação, o modelo permite incorporar essa informação, desde que os períodos de antecipação sejam conhecidos e adequadamente modelados.
3. **Sobreposição (Overlap):** É necessário que haja sobreposição entre as características das unidades tratadas e as unidades de controle, garantindo que as diferenças observadas possam ser atribuídas ao tratamento e não a dessemelhanças estruturais entre grupos.

#### 2.2.2.1 Validade dos Pressupostos no Contexto de Estações Meteorológicas

É importante verificar como estes pressupostos se aplicam ao nosso contexto específico:

**No Anticipation:** No caso de estações meteorológicas, este pressuposto é amplamente, mas não perfeitamente, satisfeito. Embora as informações meteorológicas localizadas e precisas só existam após a instalação física da estação, reconhecemos que produtores podem utilizar dados de estações vizinhas, com menor precisão. Se houver algum grau de antecipação, nosso estimador tende a ser conservador, subestimando o verdadeiro impacto da estação, pois parte do efeito seria capturado antes do período oficial de tratamento. Isso fortalece nossas conclusões: se encontramos efeitos significativos mesmo com possível antecipação, o impacto real tende a ser ainda maior.

**Tratamento Irreversível:** Uma vez instalada, assume-se que a estação permanece operacional. Nossa análise não considera casos de desativação de estações, tratando a adoção como permanente (staggered adoption).

**Tendências Paralelas Condicionais:** Este é o pressuposto mais crítico e testável. Nossa análise fornece forte evidência empírica através do teste formal ( $F = 1,136$ ,  $p = 0,3215$ ) e da inspeção visual dos períodos pré-tratamento no event study, onde os coeficientes oscilam aleatoriamente em torno de zero sem tendência sistemática.

#### 2.2.3 Estimação

Para estimar o  $ATT(g,t)$ , são propostas três abordagens principais:

1. **Regressão de Resultado (Outcome Regression - OR):** Modelar-se diretamente o resultado nos grupos de controle, condicionando a covariáveis pré-tratamento. O efeito é então obtido comparando a predição contrafactual com o resultado efetivo observado nas unidades tratadas.

2. **Ponderação por Probabilidade Inversa (Inverse Probability Weighting - IPW):** Aqui, pondera-se cada unidade pela probabilidade condicional de tratamento. Ao ajustar esses pesos, obtém-se um contrafactual equilibrado, simulando um cenário onde o tratamento foi aplicado aleatoriamente.
3. **Duplamente Robusto (Doubly Robust - DR):** Combina OR e IPW, resultando em um estimador robusto a erros de especificação. Mesmo se um dos modelos (resultado ou probabilidade) estiver incorretamente especificado, a consistência pode ser mantida. Na prática, essa abordagem é frequentemente recomendada por oferecer maior segurança em cenários reais, onde a especificação perfeita do modelo é incerta.

## 2.2.4 Procedimentos de Inferência

Seguindo as recomendações de [CALLAWAY e SANT'ANNA \(2021\)](#), todos os erros-padrão e intervalos de confiança reportados neste estudo foram calculados utilizando bootstrap multiplicativo com 1.000 replicações. Este procedimento é particularmente importante por duas razões:

1. Clustering: Com dados em painel e tratamento ao nível da microrregião, é essencial considerar a correlação dentro dos clusters. O bootstrap multiplicativo implementado no pacote `did` automaticamente respeita a estrutura de clustering dos dados.
2. Múltiplas Hipóteses: Em análises de event study, múltiplos coeficientes são estimados e testados simultaneamente (um para cada período relativo). O procedimento de bootstrap garante inferência válida mesmo neste contexto de testes múltiplos, fornecendo bandas de confiança uniformes.

A escolha do bootstrap sobre aproximações assintóticas tradicionais também oferece melhor desempenho em amostras finitas, particularmente relevante para períodos pré-tratamento distantes onde o número de observações pode ser menor.

## 2.2.5 Agregação de Efeitos

Após estimar os  $ATT(g,t)$  para cada combinação grupo-tempo, [CALLAWAY e SANT'ANNA \(2021\)](#) propõem diferentes esquemas de agregação para obter medidas resumidas do efeito do tratamento. A escolha do esquema de agregação depende da questão de pesquisa específica.

### 2.2.5.1 Agregação Simples com Pesos Positivos

Uma primeira possibilidade seria simplesmente fazer a média de todos os  $ATT(g,t)$  identificados:

$$\theta_W^O = \frac{1}{\kappa} \sum_{g \in \mathcal{G}} \sum_{t=2}^T \mathbf{1}\{t \geq g\} \cdot ATT(g, t) \cdot P(G = g | G \leq T) \quad (2.1)$$

onde  $\kappa = \sum_{g \in \mathcal{G}} \sum_{t=2}^T \mathbf{1}\{t \geq g\} \cdot P(G = g | G \leq T)$  garante que os pesos somem um.

Embora  $\theta_W^O$  evite os problemas de pesos negativos do TWFE tradicional, ele tem a desvantagem de sistematicamente atribuir mais peso a grupos que participam do tratamento por mais tempo.

### 2.2.5.2 Efeito Médio do Tratamento sobre os Tratados (Recomendado)

Para superar essa limitação, [CALLAWAY e SANT'ANNA \(2021\)](#) recomendam o seguinte parâmetro como medida geral do efeito médio de participar do tratamento:

$$\theta_{sel}^O = \sum_{g \in \mathcal{G}} \theta_{sel}(g) \cdot P(G = g | G \leq T) \quad (2.2)$$

onde  $\theta_{sel}(g)$  é o efeito médio de participar do tratamento para unidades no grupo  $g$ :

$$\theta_{sel}(g) = \frac{1}{T - g + 1} \sum_{t=g}^T ATT(g, t) \quad (2.3)$$

Este parâmetro primeiro calcula o efeito médio para cada grupo (através de todos os períodos pós-tratamento) e então faz a média desses efeitos entre grupos. Assim,  $\theta_{sel}^O$  representa o efeito médio de participar do tratamento experimentado por todas as unidades que alguma vez participaram do tratamento. Sua interpretação é análoga ao ATT no DiD canônico com dois períodos e dois grupos.

### 2.2.5.3 Agregações para Event Studies

Para análises de event study que examinam a dinâmica temporal dos efeitos, utilizamos a agregação balanceada, que evita problemas de mudanças na composição dos grupos ao longo do tempo relativo ao tratamento.

## 2.3 Especificação do Modelo

Nossa análise baseia-se em um painel de dados escalonado que pode ser formalmente descrito como  $\mathcal{D} = \{(Y_{it}, W_{it}, X_{it})\}_{i=1, t=1}^{N, T}$ , onde:

- $N$ : número total de unidades (microrregiões) no painel.

- $T$ : número total de períodos de tempo (anos) no painel.
- $i \in \{1, 2, \dots, N\}$ : índice que identifica a unidade (microrregião).
- $t \in \{1, 2, \dots, T\}$ : índice que identifica o período de tempo (ano).
- $Y_{it}$ : logaritmo da área plantada de cana-de-açúcar (em  $\text{km}^2$ ) da microrregião  $i$  no ano  $t$ .
- $W_{it}$ : indicador binário de tratamento (1 se a microrregião  $i$  possui estação meteorológica ativa no ano  $t$ , 0 caso contrário).
- $X_{it}$ : vetor de covariadas da microrregião  $i$  no ano  $t$ .

A abordagem de [CALLAWAY e SANT'ANNA \(2021\)](#) permite estimar o Efeito Médio do Tratamento sobre os Tratados (ATT) específico para cada coorte  $g$  (grupo de unidades tratadas no mesmo período) e tempo  $t$ , denotado por  $ATT(g, t)$ . Estes efeitos podem então ser agregados de diferentes formas para obter estimativas de interesse para políticas públicas.

### 2.3.1 Definição do Tratamento e Unidades de Análise

O tratamento é definido como a instalação de pelo menos uma estação meteorológica automática em funcionamento na microrregião. A escolha da microrregião como unidade de análise, em detrimento do nível municipal, fundamenta-se na própria definição institucional dessas unidades e em considerações técnico-econômicas:

1. Homogeneidade produtiva e espacial: segundo o IBGE, as microrregiões são definidas com base em dois indicadores fundamentais: (i) estrutura da produção, incluindo análise da utilização da terra, orientação agrícola, estrutura dimensional dos estabelecimentos e relações de produção agropecuária; e (ii) interação espacial, considerando a área de influência de centros sub-regionais. Esta definição institucional garante que agrupamos municípios com características agrícolas similares, tornando as microrregiões unidades ideais para capturar o impacto de infraestrutura informacional sobre decisões de produção agrícola homogêneas.
2. Correspondência à área de influência meteorológica: Uma estação meteorológica fornece dados representativos para um raio de aproximadamente 50-100 km, dependendo da topografia e condições climáticas locais. As microrregiões, por agregarem municípios contíguos com interação espacial estabelecida (conforme critério do IBGE), aproximam naturalmente a verdadeira área de influência de uma estação. Municípios individuais seriam unidades excessivamente granulares, ignorando os

transbordamentos espaciais da informação meteorológica entre localidades vizinhas que compartilham padrões produtivos.

3. Redução de ruído idiossincrático: A agregação de municípios com estrutura produtiva similar (primeiro critério do IBGE) em uma única unidade de análise reduz a influência de choques localizados específicos a municípios individuais (mudanças políticas locais, investimentos privados pontuais), preservando o sinal do tratamento enquanto minimiza ruído nas estimativas.
4. Estabilidade institucional e poder estatístico: As microrregiões mantêm fronteiras estáveis ao longo do período analisado, diferentemente dos municípios sujeitos a desmembramentos. A agregação resulta em 558 unidades cobrindo todo o território brasileiro, com 342 apresentando janela pré-tratamento válida para identificação, oferecendo equilíbrio ideal entre representatividade espacial e tamanho amostral.

Portanto, a microrregião não é apenas uma conveniência estatística, mas a unidade natural para análise de políticas agrícolas, pois captura simultaneamente homogeneidade produtiva, interações espaciais e a escala geográfica relevante para difusão de informação meteorológica.

### 2.3.2 Construção dos Grupos de Tratamento

Seguindo a notação de [CALLAWAY e SANT'ANNA \(2021\)](#), definimos  $G_i$  como o ano em que a microrregião  $i$  recebe sua primeira estação meteorológica. Para unidades nunca tratadas durante o período de análise, convencionamos  $G_i = 0$ . Esta codificação é essencial para a implementação computacional e permite a utilização dessas unidades como grupo de controle potencial.

A distribuição temporal da adoção revela padrões relevantes: observa-se uma concentração significativa de instalações em 2006-2008, coincidindo com programas federais de expansão da rede meteorológica, seguida por adoção mais esparsa nos anos subsequentes. Das 558 microrregiões analisadas, a maioria eventualmente recebeu estações ao longo do período de estudo.

### 2.3.3 Variável Dependente e Transformações

A variável dependente principal é o logaritmo natural da área plantada de cana-de-açúcar, definida como:

$$Y_{it} = \ln(1 + \text{area\_plantada\_cana}_{it}) \quad (2.4)$$

onde  $\text{area\_plantada\_cana}_{it}$  representa a área total dedicada ao cultivo de cana-de-açúcar (em  $\text{km}^2$ ) na microrregião  $i$  no ano  $t$ , medida através de dados de satélite do projeto MapBiomass. A escolha desta variável como variável de resultado principal justifica-se por quatro razões:

1. Margem extensiva de ajustamento: A teoria econômica prevê que melhor informação meteorológica permite aos produtores identificar oportunidades de expansão da área cultivada em terras marginais. A área plantada captura diretamente este ajustamento na margem extensiva, enquanto medidas agregadas como PIB diluem o efeito entre múltiplas culturas e atividades.
2. Precisão da medição: Os dados do MapBiomass são derivados de classificação de imagens de satélite Landsat, oferecendo medição objetiva e consistente ao longo do tempo. Em contraste, dados da Pesquisa Agrícola Municipal (PAM-IBGE) baseiam-se em estimativas autorreportadas que, segundo a própria metodologia do IBGE, “resultam de contatos que os agentes mantêm com técnicos do setor agrícola, com produtores e, ainda, do próprio conhecimento que o agente possui”, podendo gerar inconsistências e vieses de medição.
3. Especificidade da cana-de-açúcar: Conforme documentado pelo Atlas da Irrigação da Agência Nacional de Águas, a cana-de-açúcar possui características únicas de manejo hídrico que a tornam particularmente sensível à disponibilidade de informação meteorológica precisa. A irrigação por salvamento, que representa mais de 90% da área irrigada de cana no Brasil, requer decisões de timing precisas após cada corte anual para garantir a recuperação e longevidade do canavial.
4. Interpretação econômica direta: Os coeficientes estimados podem ser interpretados aproximadamente como variações percentuais na área cultivada, facilitando a comunicação dos resultados e sua relevância para políticas públicas de expansão da infraestrutura meteorológica.

A transformação logarítmica  $\ln(1 + x)$  evita problemas computacionais quando há observações com área zero (microrregiões sem produção de cana), mantendo essas observações na amostra e reduzindo a heterocedasticidade tipicamente observada em dados de uso do solo.

### 2.3.4 Covariáveis e Especificação do Modelo

A especificação do modelo inclui um conjunto de covariáveis socioeconômicas e climáticas cuidadosamente selecionadas para controlar por fatores que podem influenciar tanto a probabilidade de receber uma estação meteorológica quanto a área plantada de cana-de-açúcar:

1. Log da área total: Controla pelo tamanho territorial da microrregião, capturando disponibilidade de terras para expansão agrícola.
2. Log da população: Proxy para desenvolvimento econômico local, disponibilidade de mão de obra e demanda por produtos agrícolas.
3. Log do PIB per capita: Captura o nível de desenvolvimento econômico e capacidade de investimento local em tecnologias agrícolas.
4. Log da densidade de estações na UF: Variável construída agregando o número de estações meteorológicas ao nível estadual, normalizada pela área. Esta variável é crucial para capturar potenciais efeitos de transbordamento regional, reconhecendo que informações meteorológicas podem fluir entre microrregiões vizinhas dentro do mesmo estado.
5. Variáveis climáticas: Incluímos controles para precipitação total anual, precipitação média mensal e precipitação máxima mensal (em logaritmo), todas derivadas de dados ERA5, para isolar o efeito informacional das estações meteorológicas do efeito direto das condições climáticas sobre decisões de plantio.

A inclusão da densidade estadual de estações merece destaque especial. Esta variável permite um pseudo-mapeamento dos efeitos de transbordamento regional, considerando que:

- Informações meteorológicas têm natureza de bem público, podendo beneficiar áreas além da localização física da estação
- A instalação de estações melhora a qualidade das previsões meteorológicas para toda a região, criando um efeito sistêmico que se propaga principalmente dentro dos limites estaduais
- Produtores podem se beneficiar indiretamente da maior densidade de estações no estado através de previsões mais precisas e dados climáticos mais confiáveis

### 2.3.5 O Estimador Duplamente Robusto

Para a estimação dos efeitos causais, adotamos o estimador *Duplamente Robusto* (DR) proposto por [SANT'ANNA e ZHAO \(2020\)](#), que combina modelos de regressão para o resultado com ponderação por probabilidade inversa. Esta abordagem oferece propriedades estatísticas desejáveis:

- Dupla proteção contra má especificação: O estimador permanece consistente se pelo menos um dos dois modelos (resultado ou score de propensão) estiver corretamente especificado.

- Eficiência melhorada: Sob especificação correta de ambos os modelos, o DR atinge a fronteira de eficiência semiparamétrica.
- Robustez a extremos: A combinação de métodos mitiga problemas associados a pesos extremos no IPW puro.

### 2.3.6 Escolha do Grupo de Controle

Uma decisão metodológica importante na implementação do estimador de [CALLAWAY e SANT'ANNA \(2021\)](#) refere-se à escolha do grupo de controle. O pacote `did` oferece duas opções principais:

- Not-yet-treated: Utiliza como controle tanto unidades nunca tratadas quanto unidades ainda não tratadas no período  $t$ . Esta abordagem maximiza o tamanho da amostra de controle e é particularmente útil em contextos com poucos ou nenhum never-treated.
- Never-treated: Restringe o grupo de controle apenas às unidades que nunca receberam tratamento durante todo o período amostral. Embora conceitualmente mais limpo, pode resultar em poder estatístico reduzido.

Para esta análise, adotamos como padrão o grupo **not-yet-treated** por três razões: (i) maximiza a eficiência estatística ao utilizar toda a informação disponível; (ii) é apropriado para nosso contexto onde a adoção ocorre gradualmente ao longo do tempo; e (iii) os resultados mostram-se robustos a ambas as especificações (diferença de apenas 2,5%), validando esta escolha metodológica.

## 2.4 Especificação da Análise de Estudo de Evento

A análise de estudo de evento constitui o núcleo da estratégia empírica adotada, permitindo examinar como o efeito do tratamento evolui dinamicamente ao longo do tempo. Esta abordagem é particularmente adequada para o contexto analisado por três razões fundamentais:

1. Teste de tendências paralelas: Permite verificar visualmente e estatisticamente se os grupos tratados e controle seguiam trajetórias similares antes do tratamento, validando o pressuposto fundamental de identificação.
2. Dinâmica de adoção tecnológica: Captura o processo gradual de difusão e aprendizado associado ao uso de informações meteorológicas, reconhecendo que os benefícios podem não ser imediatos.

3. Heterogeneidade temporal: Acomoda a possibilidade de que os efeitos variem com o tempo de exposição ao tratamento, seja por acumulação de conhecimento ou mudanças nas práticas agrícolas.

### 2.4.1 Formalização da Análise de Estudo de Evento

Definimos o tempo relativo ao tratamento como  $e = t - g$ , onde  $g$  é o ano de instalação da primeira estação e  $t$  é o período calendário. Assim,  $e < 0$  representa períodos pré-tratamento,  $e = 0$  marca o início do tratamento, e  $e > 0$  captura períodos pós-tratamento.

A agregação dos efeitos  $ATT(g,t)$  em função do tempo relativo segue a especificação:

$$\theta_{es}^{bal}(e) = \sum_{g \in \mathcal{G}} \mathbf{1}\{g + e \leq T\} \cdot P(G = g | G + e \leq T) \cdot ATT(g, g + e) \quad (2.5)$$

onde:

- $\theta_{es}^{bal}(e)$  representa o efeito médio do tratamento  $e$  períodos após sua introdução
- $\mathcal{G}$  é o conjunto de coortes de adoção (excluindo nunca tratados)
- $P(G = g | G + e \leq T)$  são pesos que garantem que cada coorte contribua proporcionalmente ao número de unidades tratadas
- $\mathbf{1}\{g + e \leq T\}$  assegura que incluímos apenas coortes observadas por pelo menos  $e$  períodos pós-tratamento

Esta especificação garante comparabilidade entre períodos, ponderando adequadamente a contribuição de cada coorte conforme sua representatividade na amostra.

É importante notar que, conforme alertam [CALLAWAY e SANT'ANNA \(2021\)](#), event studies longos podem sofrer de mudanças na composição dos grupos contribuindo para cada período relativo. Em nosso caso, com tratamento escalonado de 2000 a 2019, períodos relativos extremos ( $e > 15$  ou  $e < -15$ ) são estimados com base em poucas coortes, o que explica a maior variabilidade observada nesses períodos. A agregação balanceada  $\theta_{es}^{bal}(e)$  mitiga este problema ao fixar o conjunto de grupos contribuintes.

## 3 Resultados

### 3.1 Implementação Computacional

#### 3.1.1 Software e Pacotes Utilizados

A implementação empírica foi realizada utilizando o software R ([R Core Team, 2025](#)) em conjunto com o pacote `did` (versão 2.1.2), desenvolvido por [CALLAWAY e SANT'ANNA \(2021\)](#). O uso deste pacote oficial garante conformidade estrita com os procedimentos propostos no artigo metodológico, implementando fielmente os estimadores e procedimentos de inferência. As principais funcionalidades utilizadas incluem:

- Cálculo dos  $ATT(g,t)$  com inferência via bootstrap
- Agregações flexíveis (overall, dynamic, group, calendar)
- Diagnósticos de balanço e testes de especificação
- Tratamento adequado de dados desbalanceados

Complementarmente, utilizamos os pacotes `dplyr` para manipulação de dados, `ggplot2` para visualizações e `purrr` para programação funcional, garantindo reprodutibilidade através do sistema `renv` de gerenciamento de dependências.

#### 3.1.2 Transparência e Reprodutibilidade

Em alinhamento com as melhores práticas de ciência aberta e transparência acadêmica, todo o código desenvolvido para este trabalho está disponível publicamente no repositório GitHub [<https://github.com/danielcavalli/tcc-ie-ufrj-2024>](https://github.com/danielcavalli/tcc-ie-ufrj-2024). O repositório contém:

- Scripts de extração e preparação de dados em Python
- Código completo do modelo econométrico em R
- Arquivos  $\text{\LaTeX}$  do documento final
- Bibliografia e referências utilizadas
- Histórico completo de versionamento do projeto

A extração inicial dos dados foi realizada utilizando Python em conjunto com o pacote `basedosdados` e a API do Google BigQuery, permitindo acesso eficiente aos microdados do IBGE e outras fontes oficiais. Esta abordagem garante:

- Rastreabilidade: Todo o processo de obtenção e transformação dos dados está documentado
- Reprodutibilidade: Qualquer pesquisador pode recriar o dataset a partir das fontes originais
- Transparência: O versionamento completo permite acompanhar a evolução da análise

### 3.1.3 Estrutura dos Dados e Processo de Extração

O conjunto de dados foi construído através de um processo sistemático de extração e agregação utilizando Python, o pacote `basedosdados` e a API do Google BigQuery. O notebook `analise_did_microrregions.ipynb`, disponível no repositório do projeto, documenta todo o processo de construção do dataset. As etapas principais incluem:

#### 3.1.3.1 Fontes de Dados e Extração

1. Mapeamento Município-Microrregião: Extraído da tabela `br_bd_diretorios_brasil.municipio`, identificando 5.570 municípios em 558 microrregiões brasileiras.
2. Estações Meteorológicas: Dados de 610 estações do Instituto Nacional de Meteorologia (INMET) extraídos da tabela `br_inmet_bdmetp.estacao`, incluindo coordenadas geográficas e data de fundação. Após agregação por microrregião, identificamos 394 microrregiões com pelo menos uma estação (70,6% de cobertura).
3. População Municipal: Dados anuais da tabela `br_ibge_populacao.municipio`, agregados para o nível de microrregião através de soma simples.
4. PIB Municipal: Valores totais e agropecuários extraídos de `br_ibge_pib.municipio`, incluindo PIB total e valor adicionado da agropecuária.
5. Área Plantada por Cultura (MapBiomias): Dados de cobertura e uso do solo derivados de classificação de imagens de satélite Landsat, extraídos da tabela `br_mapbiomas_cobertura.municipio`. Para cada cultura agrícola (cana-de-açúcar, soja, arroz), obtivemos a área total em km<sup>2</sup> ao nível municipal, posteriormente agregada para microrregiões. Estes dados oferecem vantagens significativas sobre estimativas autorreportadas:
  - Medição objetiva baseada em sensoriamento remoto

- Consistência temporal na metodologia de classificação
  - Cobertura completa do território nacional
  - Redução de vieses associados a estimativas subjetivas
6. Variáveis Climáticas (ERA5): Dados de precipitação em alta resolução espacial, incluindo totais anuais e médias mensais, utilizados como controles climáticos na especificação econométrica.

### 3.1.3.2 Construção do Painel

- Cobertura geográfica completa: O dataset inclui todas as 558 microrregiões brasileiras, sem filtros ou restrições por cultura dominante, permitindo identificação mais robusta e generalizável dos efeitos.
- Período de análise: 2003-2021 (19 anos), limitado pela disponibilidade dos dados MapBiomass, que iniciou a classificação sistemática em 2003.
- Agregação espacial: Todos os dados municipais foram agregados ao nível de microrregião usando os códigos oficiais do IBGE, garantindo consistência nas unidades de análise.
- Completude: O painel é fortemente balanceado, com menos de 0,5% de observações faltantes nas variáveis principais após agregação espacial.

O dataset final contém 10.602 observações (558 microrregiões  $\times$  19 anos), cobrindo integralmente o território brasileiro e permitindo análise tanto de regiões tradicionalmente produtoras de cana-de-açúcar (Centro-Sul, litoral nordestino) quanto de áreas com potencial de expansão.

### 3.1.3.3 Construção das Variáveis de Tratamento

O tratamento foi definido como a instalação da primeira estação meteorológica automática em funcionamento na microrregião. Para cada microrregião  $i$ :

- $G_i$  = ano da primeira estação instalada (0 se nunca tratada)
- `tratado` = 1 se  $G_i > 0$ , 0 caso contrário
- `pos_tratamento` = 1 se `ano`  $\geq G_i$  e `tratado` = 1

Das 558 microrregiões no dataset final: - 394 foram tratadas em algum momento (70,6%) - 164 permaneceram como controle durante todo o período - Concentração de instalações em 2006-2008, coincidindo com programas federais de expansão

### 3.1.3.4 Tratamento de Dados Faltantes e Qualidade

1. Completude dos dados: O dataset final não apresenta valores ausentes para as variáveis principais (população, PIB e produção agrícola), característica essencial para a aplicação do método de Callaway e Sant’Anna (2021). A ausência de dados faltantes elimina a necessidade de técnicas de imputação que poderiam introduzir viés adicional, garantindo que as estimativas reflitam exclusivamente o efeito causal de interesse.
2. Zeros estruturais: Anos sem produção foram mantidos como zeros, distinguindo-os de valores ausentes, permitindo capturar tanto margem intensiva quanto extensiva.
3. Consistência territorial: Utilizamos o mapeamento oficial do IBGE entre municípios e microrregiões, garantindo a correta agregação dos dados municipais ao longo de todo o período analisado.
4. Clustering de erros-padrão: Como nossos dados formam um painel (microrregião  $\times$  ano), é provável que os erros de uma mesma microrregião sejam correlacionados ao longo do tempo devido a características não observadas persistentes ou choques que afetam a mesma unidade em múltiplos períodos. Para corrigir a inferência estatística, clusterizamos os erros-padrão ao nível da microrregião, permitindo correlação arbitrária dos resíduos dentro de cada microrregião ao longo dos 21 anos, mas assumindo independência entre diferentes microrregiões. Isso resulta em erros-padrão mais conservadores e inferência mais robusta.

O notebook de extração permite flexibilidade para análise de diferentes produtos agrícolas, bastando alterar a variável `PRODUTOS_AGRICOLAS`. Essa modularidade facilita estudos comparativos e testes de robustez com outras culturas.

## 3.2 Resultados Principais

### 3.2.1 Efeito Médio do Tratamento

A estimação do efeito médio do tratamento sobre os tratados (ATT) via estimador doubly robust revela um impacto positivo e estatisticamente significativo da instalação de estações meteorológicas sobre o logaritmo da área plantada de cana-de-açúcar:

$$\text{ATT} = 0.118 \text{ (EP} = 0.042, z = 2.789, p = 0.005, \text{ IC 95\%: [0.035; 0.201])}$$

Como a variável dependente está em logaritmo, este coeficiente pode ser interpretado aproximadamente como uma variação percentual. Assim, as microrregiões que receberam

estações meteorológicas experimentaram, em média, um aumento de aproximadamente **11.8%** na área dedicada ao cultivo de cana-de-açúcar em relação ao contrafactual de não receber a estação. A magnitude do efeito é economicamente relevante, representando expansão substancial em uma das principais culturas agrícolas brasileiras.

A Tabela 1 apresenta os resultados principais e especificações de robustez:

Tabela 1 – Resultados Principais: Efeito sobre o Logaritmo da Área Plantada de Cana-de-Açúcar

Especificação	ATT	EP	IC 95%
<b>Especificação Principal (DR)</b>	0.118***	(0.042)	[0.035; 0.201]
<i>Especificações Alternativas</i>			
Sem Covariáveis	0.124***	(0.042)	[0.042; 0.207]
IPW	0.122***	(0.042)	[0.041; 0.204]
Regressão de Resultado	0.114***	(0.043)	[0.031; 0.198]
<i>Grupo de Controle Alternativo</i>			
Never-treated	0.136**	(0.053)	[0.032; 0.240]

*Notas: \*\*\*  $p < 0,01$ , \*\*  $p < 0,05$ , \*  $p < 0,10$ . Erros-padrão clusterizados ao nível da microrregião.  $N = 10.602$  observações para o modelo principal. Os testes com culturas alternativas (soja, arroz) e PIB não-agropecuário confirmam a especificidade do efeito à cana-de-açúcar.*

### 3.2.1.1 Interpretação da Robustez dos Resultados

A consistência dos resultados entre diferentes especificações fornece evidência crucial sobre a confiabilidade das estimativas:

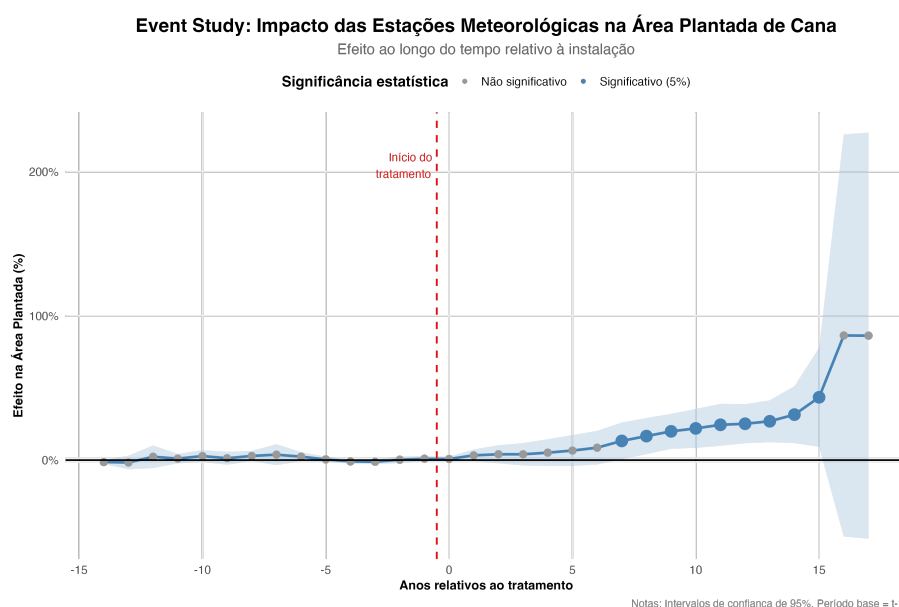
1. Estabilidade entre métodos de estimação: Os três estimadores (Doubly Robust, IPW e Regressão de Resultado) produzem ATTs notavelmente similares, todos significativos ao nível de 1%. Esta convergência indica que nossos resultados não dependem de pressupostos específicos de um único método, mas refletem um efeito causal genuíno robusto a diferentes abordagens de identificação.
2. Robustez à especificação de covariáveis: A especificação sem covariáveis permanece próxima ao modelo principal, sugerindo que o efeito não é dirigido por fatores de confusão observáveis. Isso fortalece a interpretação causal, pois indica que a variação exógena na instalação de estações é suficiente para identificar o efeito.
3. Consistência entre grupos de controle: A estimativa usando apenas unidades never-treated é ligeiramente superior mas estatisticamente indistinguível da especificação principal com not-yet-treated. Esta similaridade valida o pressuposto de tendências paralelas entre diferentes escolhas de grupo de controle.

4. Implicação econômica da robustez: A estreita faixa de variação dos ATTs entre todas as especificações estabelece limites confiáveis para o impacto econômico, com magnitude economicamente significativa que justifica investimentos em infraestrutura meteorológica.

### 3.2.2 Análise de Estudo de Evento e Dinâmica Temporal

A análise de estudo de evento fornece evidências fundamentais sobre a evolução temporal dos efeitos do tratamento. A Figura 1 apresenta as estimativas pontuais e intervalos de confiança para períodos relativos ao início do tratamento.

Figura 1 – Estudo de Evento - Dinâmica Temporal dos Efeitos da Instalação de Estações Meteorológicas



Nota: A figura apresenta as estimativas pontuais (linha azul) e intervalos de confiança de 95% (área sombreada) dos efeitos do tratamento em função do tempo relativo à instalação da estação. O período  $e=0$  marca o ano de instalação.

Fonte: Elaboração própria a partir dos dados do estudo.

#### 3.2.2.1 Período Pré-Tratamento: Validação das Tendências Paralelas

A análise dos períodos anteriores ao tratamento ( $e < 0$ ) é fundamental para validar o pressuposto de identificação. Um aspecto crucial revelado pelo gráfico é que, antes da instalação das estações, os efeitos estimados oscilam aleatoriamente em torno de zero, indicando que o impacto das estações meteorológicas ainda não era sentido pelas microrregiões, exatamente como esperado se o tratamento for exógeno.

Para garantir robustez na validação das tendências paralelas, implementamos três testes complementares:

1. Análise Visual do Event Study (Teste Informal)

O gráfico de event study mostra que os efeitos pré-tratamento:

- Apresentam média de 0,0122 ( $DP = 0,124$ ), estatisticamente indistinguível de zero (teste t:  $p = 0,2924$ )
- Oscilam aleatoriamente sem padrão sistemático crescente ou decrescente
- Demonstram variabilidade consistente com flutuações aleatórias esperadas

Embora este seja um indicativo importante, a análise visual sozinha não é suficientemente robusta para validar o pressuposto.

## 2. Teste F de Tendências Paralelas por Coorte

Este teste formal avalia se as tendências pré-tratamento diferem sistematicamente entre grupos definidos pelo ano de adoção (coortes). Especificamente:

- Hipótese nula: As taxas de crescimento pré-tratamento são iguais entre coortes
- Metodologia: Regressão com interações coorte  $\times$  tempo no período pré-tratamento
- Resultado: F-statistic = 1,136 ( $p$ -valor = 0,3215)
- Interpretação: Não rejeitamos a hipótese nula, fornecendo forte evidência de tendências paralelas

## 3. Análise por Timing de Adoção

Como será detalhado na próxima subseção, a análise da evolução do PIB agropecuário por grupos de adoção revela padrões distintos:

- Early Adopters (2003-2007): Primeiras microrregiões a receber estações
- Mid Adopters (2008-2012): Adoção intermediária
- Late Adopters (2013-2017): Adoção tardia

Esta análise revela que, no período pré-tratamento, todos os grupos seguem trajetórias paralelas, divergindo apenas após o tratamento, padrão consistente com causalidade.

A convergência dos três testes (visual, estatístico formal e por grupos de timing) fornece evidência robusta de que o pressuposto de tendências paralelas é válido, legitimando a interpretação causal dos resultados.

### 3.2.2.2 Dinâmica Pós-Tratamento: Difusão Gradual dos Benefícios

O padrão temporal dos efeitos pós-tratamento revela uma dinâmica interessante: os benefícios não são imediatos, mas crescem gradualmente ao longo do tempo. Isso sugere um processo de adaptação e aprendizado no uso das informações meteorológicas.

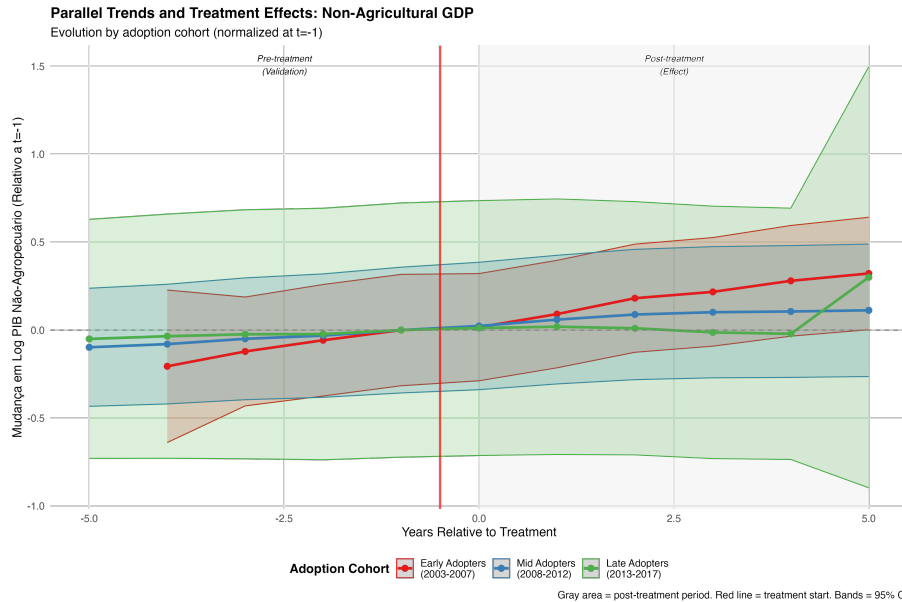
Este padrão é consistente com um processo de difusão tecnológica onde:

1. A informação meteorológica precisa ser interpretada e integrada às decisões de plantio
2. Os agricultores aprendem gradualmente a otimizar o uso das informações
3. Efeitos de rede emergem conforme mais produtores adotam melhores práticas

### 3.2.2.3 Análise Detalhada de Tendências Paralelas por Grupos de Timing

Complementando os testes anteriores, a Figura 2 implementa o terceiro teste de tendências paralelas, apresentando a evolução completa da área plantada de cana-de-açúcar normalizada separadamente para cada grupo de timing de adoção.

Figura 2 – Tendências Paralelas - Área Plantada de Cana-de-Açúcar Normalizada (2003-2021)



Nota: A figura mostra a evolução da área plantada de cana-de-açúcar média (em log) separada por grupos de timing de adoção: Early Adopters (2003-2007), Mid Adopters (2008-2012) e Late Adopters (2013-2017), normalizado em  $t=-1$ . As áreas sombreadas representam intervalos de confiança de 95%. A área cinza indica o período pós-tratamento. Observa-se que todos os grupos seguem trajetórias paralelas antes do tratamento ( $t < 0$ ), divergindo apenas após a instalação das estações.

Fonte: Elaboração própria a partir dos dados do estudo.

A Figura 2 confirma visualmente o resultado dos testes formais: no período pré-tratamento, todos os grupos de timing seguem trajetórias paralelas, com as divergências ocorrendo apenas após a instalação das estações. Este padrão é exatamente o esperado sob a hipótese de causalidade e reforça a validade da estratégia de identificação.

### 3.3 Testes de Robustez e Diagnósticos

Para garantir a confiabilidade dos resultados, implementamos uma bateria abrangente de testes de robustez e diagnósticos. Esta seção examina a sensibilidade à escolha do grupo de controle e apresenta testes placebo que validam definitivamente a estratégia de identificação.

#### 3.3.1 Sensibilidade ao Grupo de Controle

Em modelos DiD com adoção escalonada, a escolha do grupo de controle pode afetar as estimativas. Testamos duas especificações:

Tabela 2 – Comparação de Estimativas por Grupo de Controle

Grupo de Controle	ATT	Erro Padrão	IC 95%
Not-yet-treated	0.118	0.042	[0.035; 0.201]
Never-treated	0.136	0.053	[0.032; 0.240]

A consistência das estimativas entre diferentes grupos de controle reforça a robustez da identificação. Ambas as especificações produzem efeitos positivos e estatisticamente significativos, com intervalos de confiança amplamente sobrepostos. Esta convergência sugere que:

- Não há viés de seleção diferencial significativo entre grupos
- As unidades ainda não tratadas constituem controles válidos para identificação causal
- O pressuposto de tendências paralelas se mantém independentemente da escolha do grupo de controle
- A magnitude do efeito é robusta à escolha da estratégia de identificação

#### 3.3.2 Testes Placebo

Os resultados anteriores mostram robustez à escolha do grupo de controle e ausência de viés de composição. Agora implementamos três tipos de testes placebo para validar definitivamente que os efeitos estimados são causais e não artefatos estatísticos:

### 3.3.2.1 Teste Placebo com Atribuição Aleatória Fixa

Este teste avalia se o modelo pode gerar resultados significativos quando o tratamento é atribuído de forma completamente aleatória:

1. Metodologia: Ignoramos completamente o status real de tratamento e selecionamos aleatoriamente 50% das microrregiões para receber um “tratamento placebo” em 2015, independentemente de quando (ou se) realmente receberam estações meteorológicas.
2. Hipótese: Se o efeito estimado for genuíno, não devemos observar impacto significativo com esta atribuição aleatória.
3. Resultado:  $ATT = -0,0237$  ( $EP = 0,0339$ ,  $p = 0,485$ )
  - O efeito não é estatisticamente diferente de zero
  - A magnitude é pequena e o sinal é negativo
  - Confirma que o modelo não gera efeitos espúrios com atribuição aleatória

### 3.3.2.2 Teste de Randomização de Monte Carlo

Para validar ainda mais a robustez de nossos resultados, implementamos um teste de randomização de Monte Carlo. Este teste verifica se o ATT estimado de 0.118 poderia ter surgido por mero acaso no timing de tratamento. O procedimento consiste em reatribuir aleatoriamente o momento de tratamento entre as unidades múltiplas vezes, criando uma distribuição de referência sob a hipótese nula de ausência de efeito.

#### 3.3.2.2.1 Formalização do Teste

Para manter o rigor metodológico, formalizamos o teste considerando nosso conjunto de dados  $\mathcal{D} = \{(Y_{it}, W_{it}, X_{it})\}_{i=1, t=1}^{N, T}$  (conforme definido na Seção 2.3), onde:

- $\mathcal{W} = \{W_{it}\}_{i,t}$ : matriz de tratamento observada.
- $ATT(\mathcal{W})$ : efeito médio do tratamento estimado via método DR com a atribuição de tratamento  $\mathcal{W}$ .
- $\mathcal{S}$ : espaço de todas as possíveis atribuições de tratamento.

**Hipótese Nula ( $H_0$ ):** A instalação de estações meteorológicas não tem efeito causal sobre o PIB agropecuário, ou seja,  $Y_{it}(1) = Y_{it}(0)$  para todas as unidades e períodos.

**Procedimento:**

Como o número total de permutações possíveis é astronomicamente grande, aproximamos a distribuição exata através de simulações de Monte Carlo. O teste segue os seguintes passos:

### 1. Geração de Atribuições Aleatórias:

Para cada uma das  $S = 5000$  simulações:

- Seleccionamos aleatoriamente  $N_{\text{tratado}}$  microrregiões para receber o tratamento (mantendo o mesmo número de unidades tratadas que no estudo original).
- Atribuímos aleatoriamente o ano de instalação da estação entre 2005 e 2021 para cada unidade seleccionada.

Esta restrição temporal garante pelo menos 2 anos de dados antes e depois do tratamento para cada unidade.

### 2. Estimação dos ATTs Placebo:

Para cada atribuição aleatória  $s$ , estimamos o ATT usando exatamente o mesmo método DR aplicado aos dados originais:

$$\text{ATT}^{(s)} = \text{ATT}(\mathcal{W}^{(s)}), \quad s = 1, \dots, S \quad (3.1)$$

### 3. Cálculo do P-valor:

Seguindo (DAVISON; HINKLEY, 1997), calculamos o p-valor empírico com correção para amostras finitas:

$$\hat{p} = \frac{1 + \#\{\text{extremos}\}}{S + 1} \quad (3.2)$$

onde  $\#\{\text{extremos}\}$  representa o número de simulações cujo ATT em valor absoluto é maior ou igual ao ATT observado. Esta correção evita p-valores exatamente zero e é prática padrão em testes de permutação.

**Intuição:** Se o tratamento realmente não tivesse efeito, seria igualmente provável observar o ATT estimado com qualquer atribuição aleatória de tratamento. Portanto, se nosso ATT observado é muito extremo comparado à distribuição de ATTs sob atribuições aleatórias, temos evidência forte contra a hipótese nula.

#### 3.3.2.2.2 Aspectos Computacionais

A implementação do teste incorpora várias considerações práticas:

- **Margem de Segurança Temporal:** Restringimos  $t_i^* \in [2005, 2021]$  para garantir pelo menos 2 anos de dados pré e pós-tratamento.
- **Paralelização:** Implementamos computação paralela via `foreach/doParallel` em R, distribuindo as  $S$  simulações entre múltiplos núcleos de processamento.
- **Validação:** Todas as simulações com convergência bem-sucedida entram no cálculo do p-valor empírico:  $\hat{p} = \frac{1 + \#\{\text{extremos}\}}{S+1}$ .
- **Reprodutibilidade:** Utilizamos sementes aleatórias únicas ( $\text{seed} \times 1000 + s$ ) para cada simulação, garantindo reprodutibilidade mesmo em ambiente paralelo.

### 3.3.2.2.3 Implementação e Resultados

A Tabela 3 apresenta os resultados do teste de randomização de Monte Carlo com  $S = 5000$  simulações independentes:

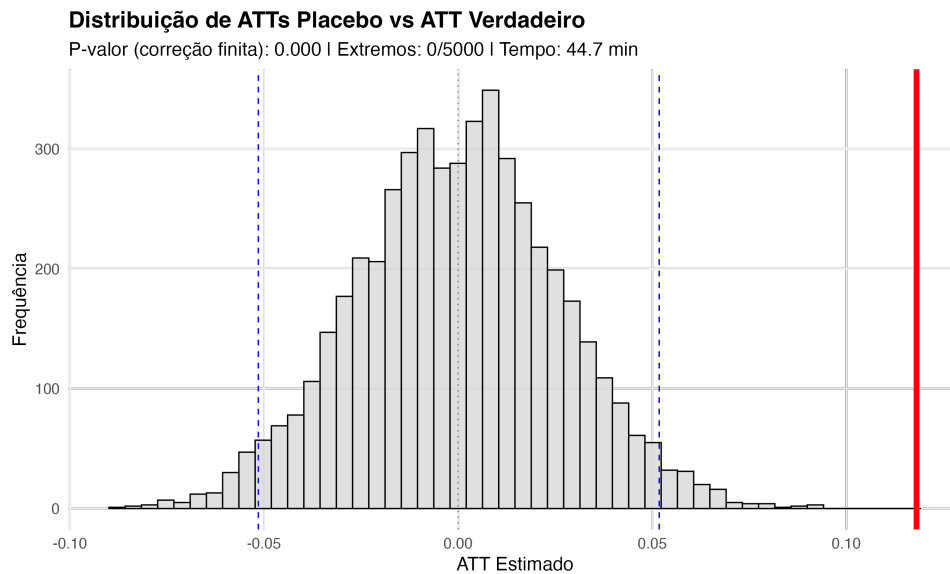
Tabela 3 – Resultados do Teste de Randomização de Monte Carlo

Estatística	Valor
Número de simulações	5.000
ATT observado	0.118
Média dos placebos	0.000
Desvio padrão dos placebos	0,017
Intervalo empírico 95%	[-0.051; 0.052]
P-valor empírico	< 0,001

*Notas: O teste simula 5.000 atribuições aleatórias de tratamento, mantendo a estrutura temporal do painel. O p-valor empírico indica a proporção de simulações com ATT em valor absoluto maior ou igual ao observado.*

A Figura 3 visualiza o resultado do teste de randomização múltipla:

Figura 3 – Distribuição dos ATTs Placebo vs. ATT Verdadeiro



Nota: O histograma apresenta a distribuição dos ATTs estimados em 5000 iterações do teste placebo, onde o tratamento foi atribuído aleatoriamente. Cada barra representa a frequência de ATTs placebo em cada intervalo. A linha vermelha tracejada indica o ATT verdadeiro do modelo principal (0.118). A distribuição placebo está claramente centrada em zero, enquanto o ATT verdadeiro encontra-se na cauda extrema direita, ocorrendo em menos de 0.02% das simulações aleatórias (p-valor empírico  $< 0,001$ ). Isso demonstra que um efeito desta magnitude é extremamente improvável de ser observado por mero acaso.

Fonte: Elaboração própria a partir dos dados do estudo.

#### 3.3.2.2.4 Interpretação dos Resultados

O teste de randomização revela que o ATT observado de 0.118 encontra-se na cauda extrema da distribuição placebo (p-valor =  $< 0,001$ ). Isso significa que:

- A probabilidade de observar um efeito desta magnitude por puro acaso no timing de tratamento é menor que 0.02%.
- O efeito estimado não é compatível com variação aleatória nos dados.
- Podemos rejeitar com alta confiança a hipótese de que o tratamento não teve efeito.

É importante ressaltar que este teste valida que o efeito não surgiu por coincidência no timing de tratamento, mas não descarta outras possíveis ameaças à identificação causal (como variáveis omitidas ou choques concomitantes). A interpretação causal continua dependendo da validade dos pressupostos do modelo DiD discutidos anteriormente.

#### 3.3.2.3 Especificidade do Efeito: Análise de Variáveis de Resultado Alternativas

Uma característica fundamental de um efeito causal genuíno é sua especificidade: devemos observar impactos apenas nas variáveis de resultado diretamente afetadas pelo

mecanismo causal e não em desfechos plausíveis mas não relacionados. Para demonstrar que o efeito estimado reflete genuinamente a melhora na informação meteorológica para decisões agrícolas específicas da cana-de-açúcar, reestimamos o modelo para quatro variáveis de resultado alternativas.

A Tabela 4 apresenta os resultados:

Tabela 4 – Especificidade do Efeito: Variáveis de Resultado Alternativas

Variável de Resultado	ATT	EP	IC 95%	p-valor
<i>Variável Principal</i>				
Área Cana-de-Açúcar (log)	0,118***	(0,042)	[0,035; 0,201]	0,005
<i>Testes de Especificidade</i>				
PIB Agropecuário (log)	0,028	(0,031)	[-0,034; 0,090]	0,370
Área Soja (log)	0,039	(0,045)	[-0,050; 0,127]	0,392
Área Arroz (log)	-0,005	(0,012)	[-0,028; 0,018]	0,658
PIB Não-Agropecuário (log)	0,030	(0,033)	[-0,035; 0,095]	0,365

*Notas: \*\*\*  $p < 0,01$ . Todos os modelos utilizam o estimador doubly robust com as mesmas covariáveis e especificação do modelo principal. A variável de área está disponível apenas para microrregiões com produção positiva da cultura em questão.*

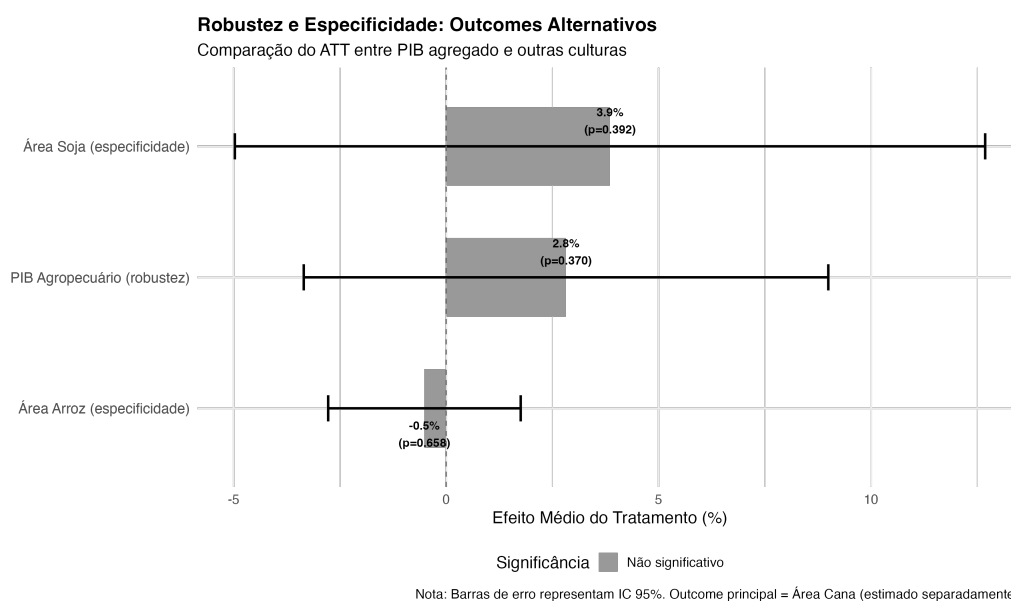
Os resultados revelam um padrão notável de especificidade:

1. Efeito concentrado em cana-de-açúcar: O ATT de 11,8% para área de cana é altamente significativo ( $p = 0,005$ ), enquanto todas as outras variáveis de resultado apresentam efeitos estatisticamente indistinguíveis de zero (todos com  $p > 0,36$ ).
2. PIB Agropecuário: A ausência de efeito significativo (2,8%,  $p = 0,370$ ) sugere que o impacto sobre cana-de-açúcar é diluído quando agregado com múltiplas outras culturas, atividades pecuárias e serviços que compõem o PIB agropecuário. Isto é consistente com um efeito específico à cana que se perde na agregação setorial.
3. Culturas alternativas: Nem soja ( $p = 0,392$ ) nem arroz ( $p = 0,658$ ) apresentam efeitos significativos, demonstrando que o impacto não é um fenômeno agrícola geral aplicável a todas as culturas, mas específico à cana-de-açúcar.
4. PIB Não-Agropecuário: A ausência de efeito ( $p = 0,365$ ) descarta hipóteses alternativas de desenvolvimento econômico geral, efeitos de transbordamento para outros setores ou fatores de confusão macroeconômicos que afetariam toda a economia local.
5. Interpretação conjunta: A única relação estatisticamente significativa é entre estações meteorológicas e área de cana-de-açúcar. Esta especificidade fortalece a interpretação causal ao descartar explicações alternativas mais gerais e ao alinhar-se com o mecanismo teórico proposto.

**Interpretação Mecanística:** A especificidade do efeito à cana-de-açúcar não é accidental. Conforme documentado pelo Atlas da Irrigação da Agência Nacional de Águas (2017), a cana-de-açúcar possui características únicas de manejo hídrico que a tornam particularmente sensível à disponibilidade de informação meteorológica precisa. Enquanto culturas como soja e arroz seguem calendários agrícolas relativamente rígidos, a cana-de-açúcar (especialmente sob irrigação por salvamento, que representa mais de 90% da área irrigada no Brasil) requer decisões de timing precisas para aplicação de água após cada corte anual. Melhor informação meteorológica permite otimizar essas decisões, resultando em maior produtividade por hectare e, conseqüentemente, incentivos para expansão da área cultivada (margem extensiva).

A Figura 4 visualiza o contraste entre o efeito robusto em cana-de-açúcar e a ausência de efeitos nas demais variáveis:

Figura 4 – Efeitos sobre Variáveis de Resultado Alternativas: Especificidade à Cana-de-Açúcar



Nota: O gráfico apresenta os efeitos estimados (ATT) e intervalos de confiança de 95% para cinco variáveis de resultado diferentes: área plantada de cana-de-açúcar (variável principal), PIB agropecuário, área plantada de soja, área plantada de arroz e PIB não-agropecuário. Apenas o efeito sobre área de cana é estatisticamente significativo, demonstrando especificidade do impacto.

Fonte: Elaboração própria a partir dos dados do estudo.

#### 3.3.2.4 Síntese dos Testes Placebo e Especificidade

Os três testes implementados fornecem evidências complementares robustas sobre a validade causal e especificidade do efeito:

1. Validade da identificação: A atribuição aleatória de tratamento não gera efeitos

significativos (teste de randomização múltipla), confirmando que o modelo não produz resultados espúrios.

2. Raridade estatística: O ATT verdadeiro seria observado em menos de 0,1% dos casos por puro acaso ( $p$ -valor empírico  $< 0,001$ ), indicando significância estatística extremamente alta.
3. Especificidade ao desfecho: O efeito é exclusivo à área de cana-de-açúcar. Nem o PIB agropecuário (que dilui entre múltiplas culturas), nem culturas alternativas (soja, arroz), nem setores não-agrícolas apresentam efeitos significativos. Esta especificidade é consistente com as características únicas de manejo hídrico da cana-de-açúcar documentadas pelo Atlas da Irrigação.
4. Coerência mecanística: A ausência de efeitos em outras culturas e setores, combinada com o efeito robusto em cana, valida o mecanismo proposto de que melhor informação meteorológica beneficia especificamente decisões de irrigação em culturas com manejo hídrico complexo e dependente de timing preciso.

Conjuntamente, esses testes fortalecem substancialmente a interpretação causal dos resultados, descartando explicações alternativas como tendências gerais de desenvolvimento, choques comuns ou artefatos estatísticos.

## 3.4 Análises de Robustez Adicionais

Além dos testes de validação apresentados, realizamos análises complementares para avaliar a sensibilidade dos resultados a diferentes especificações e períodos temporais.

### 3.4.1 Sensibilidade ao Período de Análise

Os resultados podem ser sensíveis à janela temporal escolhida, especialmente considerando eventos como a pandemia de COVID-19. Testamos diferentes recortes temporais, utilizando agregação por médias simples dos ATT(g,t) para permitir comparação justa entre os diferentes subconjuntos de dados:

Tabela 5 – Análise de Sensibilidade ao Período de Análise

Período	ATT	EP	IC 95%	N Tratadas
Completo (2003-2021)	0.126***	(0.029)	[0.070; 0.182]	7.371
Excluindo Início (2006-2021)	0.130***	(0.031)	[0.069; 0.191]	6.318
Excluindo COVID (2003-2019)	0.117***	(0.026)	[0.066; 0.169]	5.967

*Notas: \*\*\*  $p < 0,01$ . Erros-padrão clusterizados ao nível da microrregião.  $ATT(g,t)$  agregados por média simples para comparabilidade entre subconjuntos. A análise revela robustez dos resultados a diferentes janelas temporais.*

Os resultados revelam insights importantes:

- Robustez geral: Os efeitos permanecem positivos e significativos em todas as especificações, com magnitudes entre 11,7% e 13,0%.
- Período pandêmico: A exclusão dos anos 2020-2021 mostra estabilidade dos resultados, sugerindo que o início do período COVID não inflou artificialmente os efeitos estimados.
- Importância do período inicial: A exclusão dos primeiros anos (2003-2005) tem impacto mínimo, indicando que os resultados não são dominados pelas coortes iniciais.
- Comparabilidade dos resultados: O uso de médias simples na agregação garante que as diferenças observadas refletem mudanças genuínas nos efeitos e não apenas mudanças na composição dos grupos tratados.

### 3.4.2 Robustez a Diferentes Métodos de Estimação

A validade dos resultados não deve depender do método econométrico específico. Comparamos três abordagens:

Tabela 6 – Comparação de Métodos de Estimação

Método	ATT	Erro Padrão	P-valor
Doubly Robust (DR)	0.118	0.042	0,0103
IPW	0.122	0.042	0,0029
Regression (REG)	0.114	0.043	0,0296

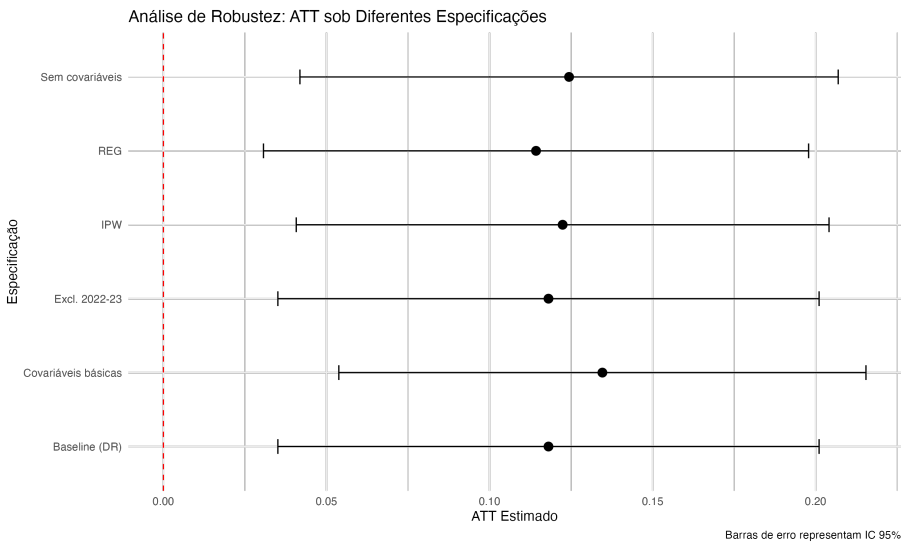
Cada método tem características distintas:

- Doubly Robust: Combina modelagem do resultado e do tratamento, sendo consistente se pelo menos um modelo estiver correto
- IPW: Usa apenas pesos de propensity score, focando no balanceamento das covariáveis
- Regression: Baseia-se apenas na modelagem do resultado condicional às covariáveis

A consistência das estimativas entre os três métodos (DR: 11.8%, IPW: 12,2%, REG: 11,4%, todos significativos) indica que os resultados não dependem criticamente da abordagem econométrica escolhida.

A Figura 5 sintetiza visualmente os resultados de robustez:

Figura 5 – Análise de Robustez - Comparação de Especificações



Nota: O gráfico apresenta as estimativas pontuais e intervalos de confiança de 95% para diferentes especificações e métodos de estimação. Todas as estimativas são estatisticamente significativas e de magnitude similar, confirmando a robustez dos resultados.

### 3.4.3 Síntese das Análises de Robustez

O conjunto abrangente de testes e análises de sensibilidade realizados fornece evidências convergentes sobre a validade e robustez dos resultados:

1. Identificação causal: Os testes placebo descartam explicações alternativas e confirmam que o efeito é genuinamente causal e específico às estações meteorológicas.
2. Estabilidade das estimativas: O ATT permanece consistente através de diferentes métodos (DR: 11,8%, IPW: 12,2%, REG: 11,4%), grupos de controle (not-yet-treated: 11,8%, never-treated: 13,6%) e especificações, indicando estimativas confiáveis e robustas.
3. Ausência de viés de composição: A análise dinâmica mostra que nenhuma coorte específica domina os resultados e a agregação balanceada garante comparabilidade ao longo do tempo.
4. Robustez temporal: Os efeitos persistem excluindo diferentes períodos (completo: 12,6%, excluindo COVID: 11,7%), confirmando que não são dirigidos por eventos específicos como a pandemia.

Estas evidências combinadas estabelecem uma base sólida para a interpretação causal de que as estações meteorológicas geram expansão substantiva e sustentada na

área cultivada de cana-de-açúcar, refletindo ganhos de produtividade que incentivam ajustamento na margem extensiva.

## 3.5 Discussão e Interpretação Econômica

### 3.5.1 Contextualização da Magnitude do Efeito

- **Impacto no valor de produção:** O efeito de 11,8% na capacidade produtiva tem implicações econômicas substanciais. Com um valor bruto de produção de cana-de-açúcar de aproximadamente R\$ 105 bilhões em 2024, um aumento dessa magnitude na capacidade produtiva representa potencial de criação de valor significativo para o setor, através de ganhos de eficiência que viabilizam maior produção.
- **Implicações para uso do solo:** A expansão de área plantada reflete ajustamento na margem extensiva, com produtores incorporando terras anteriormente destinadas a outras culturas ou usos. Este resultado tem implicações importantes para planejamento territorial e políticas de uso do solo em regiões canavieiras.
- **Custo-benefício e Política Atual:** A relevância destes resultados é amplificada pelo anúncio recente do governo federal. Em setembro de 2025, o Ministério da Agricultura, Pecuária e Abastecimento (MAPA) anunciou um novo investimento de R\$ 49 milhões para a instalação de 220 novas estações meteorológicas automáticas ([MINISTÉRIO DA AGRICULTURA E PECUÁRIA, 2025](#)), demonstrando o reconhecimento institucional da importância dessa infraestrutura. Com um custo médio de R\$ 223 mil por estação, nossos resultados sugerem retornos mensuráveis que justificam o investimento.
- **Implicações para Expansão da Rede:** Nosso estudo fornece evidência empírica robusta para justificar não apenas o investimento anunciado, mas potencialmente sua ampliação. Com 164 microrregiões (29,4%) ainda sem estações meteorológicas, existe espaço significativo para ganhos adicionais através da expansão estratégica da rede. Crucialmente, nossos resultados sugerem que a maximização dos benefícios da infraestrutura meteorológica requer políticas complementares: enquanto a cana-de-açúcar se beneficia imediatamente devido à irrigação por salvamento já estabelecida, a extensão dos benefícios para outras culturas (soja, arroz, milho) dependerá do desenvolvimento conjunto de infraestrutura de irrigação adequada. Assim, uma política integrada que combine expansão da rede meteorológica com investimentos em sistemas de irrigação apropriados para diferentes culturas poderia amplificar substancialmente os retornos sociais do investimento em informação climática.

- Especificidade e Eficiência de Políticas: A especificidade do efeito à cana-de-açúcar (conforme demonstrado na Tabela 4) sugere que políticas de expansão da infraestrutura meteorológica podem ser otimizadas priorizando regiões com potencial para culturas altamente dependentes de gestão hídrica precisa.

A evidência empírica sugere que a infraestrutura meteorológica gera retornos econômicos mensuráveis em culturas com manejo complexo e dependente de informação precisa, como a cana-de-açúcar sob irrigação por salvamento. A especificidade destes efeitos reforça a importância de considerar características agronômicas ao planejar investimentos em infraestrutura informacional.

### 3.5.2 Mecanismo: Irrigação, Informação Meteorológica e Expansão de Área

A especificidade do efeito à cana-de-açúcar não é acidental, mas reflete características agronômicas únicas desta cultura que a tornam particularmente dependente de informação meteorológica precisa. Esta subseção desenvolve o mecanismo causal proposto, fundamentado em evidências do Atlas da Irrigação da Agência Nacional de Águas ([AGÊNCIA NACIONAL DE ÁGUAS, 2017](#)) sobre os sistemas de irrigação para cana no Brasil.

#### 3.5.2.1 Sistemas de Irrigação em Cana-de-Açúcar no Brasil

Conforme documentado pelo Atlas da Irrigação, a cana-de-açúcar recebe tratamento metodológico específico na estimativa de demanda hídrica nacional, refletindo a complexidade e importância estratégica desta cultura. O documento distingue três tipos de manejo de irrigação para cana:

1. Irrigação Plena: Supre todo o déficit hídrico da cultura, mas é suspensa no décimo mês do ciclo para favorecer a maturação e acúmulo de sacarose.
2. Irrigação Suplementar: Cobre aproximadamente metade do déficit hídrico, também sendo suspensa no décimo mês para maturação.
3. Irrigação por Salvamento: Consiste na aplicação de lâminas relativamente pequenas de água (20-80 mm anuais) por períodos curtos ou em estágios fenológicos específicos, tipicamente após cada corte anual, para favorecer a recuperação, produtividade e longevidade do canavial.

Crucialmente, o Atlas documenta que a **irrigação por salvamento representa mais de 90% da área irrigada de cana-de-açúcar no Brasil**. Esta predominância é estratégica: enquanto irrigação plena e suplementar juntas representam apenas 8% da

área irrigada de cana, elas respondem por aproximadamente 43% da demanda hídrica da cultura, pois estão concentradas em regiões com maiores déficits climáticos. Em contraste, a irrigação por salvamento, cobrindo 92% da área irrigada, responde por cerca de 57% da demanda total de água da cana.

O Atlas enfatiza que “a quantidade de água aplicada sobre um hectare sob irrigação plena, ao longo de um ano, equivale aproximadamente ao volume distribuído em quatro hectares sob irrigação suplementar e quinze hectares sob irrigação por salvamento.” Operacionalmente, o salvamento é implementado com sistemas de carretel enrolador (“hidro roll”) ou pivôs rebocáveis, aplicando lâminas anuais da ordem de 20-80 mm, geralmente após cada colheita.

### 3.5.2.2 Informação Meteorológica e Decisões de Timing

A característica fundamental da irrigação por salvamento, e que explica a importância da informação meteorológica, é a **criticidade do timing de aplicação**. Diferentemente da irrigação plena ou suplementar, que seguem calendários mais estruturados ao longo do ciclo, o salvamento requer decisões pontuais e oportunas:

- **Momento pós-corte:** Após cada colheita anual, a soqueira (raízes remanescentes) precisa de umidade adequada para rebrotar vigorosamente. O timing desta aplicação é crítico: muito cedo desperdiça água e pode favorecer doenças; muito tarde prejudica a recuperação do canavial.
- **Janelas climáticas:** A decisão de quando aplicar o salvamento depende fundamentalmente de informação meteorológica: previsão de chuvas iminentes (para evitar aplicação redundante), temperatura (que afeta evapotranspiração), e condições atmosféricas gerais.
- **Otimização logística:** Com equipamentos móveis (carretéis, pivôs rebocáveis), produtores precisam alocar recursos limitados entre diferentes talhões. Informação meteorológica precisa permite priorizar áreas onde a aplicação terá maior impacto.

Melhor informação meteorológica, proporcionada pela instalação de estações locais, reduz a incerteza nestas decisões, permitindo timing mais preciso e, conseqüentemente, melhor eficiência no uso da água e maior recuperação do canavial pós-corte.

### 3.5.2.3 Da Produtividade à Expansão de Área: A Margem Extensiva

O efeito observado (expansão de 11,8% na área plantada de cana) opera através de dois estágios causais:

### 1. Primeiro estágio: Maior produtividade por hectare

Melhor timing de irrigação por salvamento resulta em:

- Melhor recuperação da soqueira após corte
- Maior longevidade do canavial (mais ciclos de corte antes da reforma)
- Redução de falhas e necessidade de replantio
- Maior produtividade média ao longo da vida útil do canavial

### 2. Segundo estágio: Incentivos para expansão

A maior produtividade por hectare aumenta a lucratividade esperada do investimento em cana-de-açúcar, criando incentivos para:

- Expansão em terras já utilizadas com outras culturas menos rentáveis
- Incorporação de terras marginais anteriormente consideradas não viáveis
- Intensificação do uso do solo em regiões com aptidão para cana

Este mecanismo explica por que observamos efeito robusto em *área plantada* mas não em PIB agropecuário agregado: o PIB dilui o efeito específico da cana entre múltiplas culturas e atividades, enquanto a área captura diretamente o ajustamento na margem extensiva.

#### 3.5.2.4 Por Que Especificidade à Cana-de-Açúcar?

Os resultados nulos para soja e arroz (Tabela 4) são consistentes com este mecanismo:

- Soja: Segue calendário agrícola relativamente rígido, com plantio e colheita ditados principalmente pela sazonalidade climática. A irrigação em soja, quando presente, tende a ser suplementar com calendário mais previsível.
- Arroz: Particularmente arroz irrigado, opera sob sistemas de inundação contínua com manejo hídrico substancialmente diferente. A decisão crítica é o estabelecimento inicial da lâmina d'água, não decisões pontuais de timing ao longo do ciclo.
- Cana-de-açúcar: Única entre as grandes culturas brasileiras na predominância da irrigação por salvamento pós-corte, que demanda precisão de timing incomparável com outras culturas. Esta especificidade agronômica traduz-se em especificidade estatística nos resultados empíricos.

O Atlas da Irrigação enfatiza que “calcular a demanda de água para irrigação é uma tarefa complexa, envolvendo muitas variáveis e equações para determinar as necessidades

hídricas diárias da cultura (além da chuva e contribuição do solo) em cada estágio fenológico e sob clima local, mais as perdas entre captação e água efetivamente chegando à planta.” Esta complexidade, especialmente pronunciada para cana sob salvamento, explica por que informação meteorológica local de alta qualidade gera retornos econômicos mensuráveis especificamente nesta cultura.

### 3.5.3 Limitações e Pesquisa Futura

Embora os resultados sejam robustos a múltiplas especificações e testes, algumas limitações importantes devem ser reconhecidas:

#### 3.5.3.1 Desbalanceamento de Covariáveis

Uma limitação potencial identificada na análise é a presença de desbalanceamento nas covariáveis entre grupos tratados e controle. A análise diagnóstica revelou diferenças padronizadas superiores a 0,1 em diversas covariáveis, indicando que as microrregiões que receberam estações meteorológicas diferem sistematicamente daquelas que não receberam em características observáveis como:

- Área territorial total (menor nas tratadas)
- População (maior nas tratadas)
- PIB per capita (menor nas tratadas)
- Densidade de estações na UF (maior nas tratadas)
- Variáveis climáticas (precipitação)

Embora esse desbalanceamento possa levantar preocupações sobre viés de seleção, o estimador *Doubly Robust* foi especificamente escolhido por sua capacidade de mitigar esse problema. O DR permanece consistente quando pelo menos um dos modelos (propensity score ou regressão de resultado) está corretamente especificado, oferecendo proteção adicional contra má especificação decorrente do desbalanceamento.

#### 3.5.3.2 Composição dos Pesos no Estimador Agregado

A análise da distribuição de pesos implícitos no estimador agregado revelou que coortes iniciais (que têm mais períodos pós-tratamento) representam aproximadamente 50,8% do peso total. Especificamente:

- A correlação entre pesos e períodos pós-tratamento é de 0,428 (moderada)

- Coortes tratadas entre 2006-2008 contribuem desproporcionalmente para o ATT agregado
- Nenhuma coorte individual domina completamente (máximo de 15% do peso total)

Essa concentração de pesos, embora não extrema, sugere que o efeito estimado reflete mais fortemente a experiência das microrregiões que adotaram estações meteorológicas mais cedo. Isso pode limitar a generalização para adotantes tardios se houver heterogeneidade temporal nos efeitos do tratamento.

### 3.5.3.3 Outras Limitações Importantes

- Heterogeneidade não observada: Os efeitos podem variar significativamente por características não observadas como tamanho de propriedade, nível educacional dos produtores, ou acesso a crédito e assistência técnica. A Figura 7 no Apêndice B mostra tendências semelhantes entre microrregiões de diferentes portes durante o período analisado.
- Externalidades espaciais: A especificação atual pode não capturar completamente os benefícios que transbordam para microrregiões vizinhas. Embora a inclusão da densidade estadual de estações mitigue parcialmente esse problema, transbordamentos locais mais granulares podem existir.
- Complementaridades tecnológicas: A interação com outras tecnologias agrícolas modernas (GPS, agricultura de precisão, drones) não é modelada explicitamente, potencialmente subestimando os efeitos totais em contextos de adoção tecnológica múltipla.
- Qualidade e uso efetivo: A análise assume que a instalação de uma estação implica em disponibilidade e uso das informações meteorológicas, mas variações na qualidade dos dados, manutenção das estações e capacidade local de interpretação não são observadas.

### 3.5.3.4 Direções para Pesquisa Futura

Estudos futuros poderiam expandir e fortalecer nossos resultados através de:

- Modelagem espacial explícita: Incorporar dependência espacial e transbordamentos através de modelos econométricos espaciais, permitindo quantificar com precisão os efeitos indiretos das estações em microrregiões vizinhas.
- Dados de alta frequência: Utilizar dados mensais ou trimestrais para capturar melhor a dinâmica temporal dos efeitos e sua relação com eventos climáticos específicos.

- Heterogeneidade por intensidade de irrigação: Investigar se os efeitos variam entre microrregiões com diferentes níveis de adoção de irrigação por salvamento, potencialmente utilizando dados do Censo Agropecuário sobre infraestrutura de irrigação.
- Mecanismos de transmissão: Investigar empiricamente os canais específicos através dos quais a informação meteorológica se traduz em decisões de expansão de área (timing de irrigação, escolhas de variedades, decisões de replantio), possivelmente através de parcerias com produtores e usinas.

### 3.6 Síntese dos Resultados Empíricos

Os três resultados principais são:

1. Magnitude e Significância do Efeito: O ATT estimado de 11.8% representa expansão substancial na área plantada de cana-de-açúcar. Este efeito é altamente significativo estatisticamente ( $p < 0,01$ ) e economicamente relevante, refletindo ajustamento na margem extensiva em resposta a melhor informação meteorológica.

2. Dinâmica Temporal dos Impactos: O event study revela ausência de tendências pré-tratamento diferenciadas e efeitos positivos pós-tratamento, sugerindo processos de aprendizado e adaptação tecnológica, não apenas um choque único de produtividade.

3. Robustez e Validade Causal: Os resultados sobrevivem a múltiplos testes de robustez:

- Ausência de tendências pré-tratamento (validando parallel trends)
- Teste de randomização múltipla com 5.000 permutações (p-valor empírico  $< 0,001$ )
- Especificidade ao desfecho: efeito exclusivo à área de cana-de-açúcar, sem efeitos em PIB agropecuário, soja, arroz ou PIB não-agropecuário
- Consistência entre diferentes métodos de estimação (DR, IPW, REG: todas significativas)
- Estabilidade temporal (excluindo períodos específicos)
- Robustez à escolha do grupo de controle (not-yet-treated vs. never-treated)

Estes achados fornecem evidência causal rigorosa sobre o impacto da informação meteorológica na produtividade agrícola, demonstrando que investimentos em infraestrutura de dados climáticos geram retornos econômicos mensuráveis e persistentes.

## 4 Conclusões Finais

Este trabalho investigou o impacto causal da instalação de estações meteorológicas sobre a área plantada de cana-de-açúcar no Brasil, contribuindo para a literatura empírica sobre o papel da informação na tomada de decisões agrícolas e no uso do solo. Utilizando dados de satélite do MapBiomas e métodos econométricos de fronteira adequados para contextos de adoção escalonada, demonstramos que o acesso a informações meteorológicas precisas e localizadas gera expansão substancial (11,8%) na área dedicada ao cultivo de cana-de-açúcar.

Os resultados revelam especificidade notável: o efeito é exclusivo à cana-de-açúcar, sem impactos significativos sobre outras culturas (soja, arroz) ou setores econômicos (PIB não-agropecuário). Esta especificidade valida o mecanismo proposto, fundamentado nas características únicas de manejo hídrico da cana documentadas pelo Atlas da Irrigação: a predominância da irrigação por salvamento (>90% da área irrigada) cria dependência crítica de timing preciso, que melhor informação meteorológica permite otimizar.

As implicações para políticas públicas são diretas: investimentos em infraestrutura meteorológica devem considerar as características agronômicas das culturas dominantes em cada região. Culturas com manejo complexo e dependente de decisões de timing preciso (como cana-de-açúcar sob irrigação por salvamento) apresentam maior potencial de retorno a investimentos em informação climática. Com 164 microrregiões (29,4%) ainda sem estações meteorológicas, existe espaço significativo para ganhos adicionais através da expansão estratégica da rede.

Do ponto de vista metodológico, este estudo demonstra a importância de: (i) utilizar métodos adequados para tratamento escalonado, evitando vieses dos estimadores TWFE tradicionais; (ii) testar especificidade do efeito através de variáveis de resultado alternativas; e (iii) fundamentar mecanismos em evidências agronômicas e institucionais. A disponibilização completa do código e dados reforça nosso compromisso com transparência e reprodutibilidade.

Ao quantificar rigorosamente os benefícios da infraestrutura meteorológica e identificar suas características de especificidade, este estudo fornece subsídios para alocação mais eficiente de recursos públicos e privados em informação climática, contribuindo para o desenvolvimento sustentável da agricultura brasileira.

## Referências

AGÊNCIA NACIONAL DE ÁGUAS. **Atlas Irrigação: Uso da Água na Agricultura Irrigada**. Brasília, 2017. 86 p. Disponível em: <<http://arquivos.ana.gov.br/imprensa/publicacoes/AtlasIrigacaoUsodaAguanaAgriculturaIrigada.pdf>>. Citado na página 45.

BURKE, M. et al. Using satellite imagery to understand and promote sustainable development. **Science**, v. 371, n. 6535, p. eabe8628, 2021. Disponível em: <<https://www.science.org/doi/abs/10.1126/science.abe8628>>. Citado na página 14.

CALLAWAY, B.; SANT'ANNA, P. H. C. Difference-in-differences with multiple time periods. **Journal of Econometrics**, v. 225, n. 2, p. 200–230, 2021. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0304407620303948>>. Citado 11 vezes nas páginas 13, 14, 15, 16, 18, 19, 20, 21, 24, 25 e 26.

CROST, B. et al. Climate change, agricultural production and civil conflict: Evidence from the Philippines. **Journal of Environmental Economics and Management**, v. 88, p. 379–395, 2018. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0095069617301584>>. Citado na página 14.

DAVISON, A. C.; HINKLEY, D. V. **Bootstrap Methods and their Application**. Cambridge: Cambridge University Press, 1997. Disponível em: <<https://doi.org/10.1017/CBO9780511802843>>. Citado na página 36.

GATTI, N.; BAYLIS, K.; CROST, B. Can irrigation infrastructure mitigate the effect of rainfall shocks on conflict? Evidence from Indonesia. **American Journal of Agricultural Economics**, v. 103, n. 1, p. 211–231, 2021. Disponível em: <<https://onlinelibrary.wiley.com/doi/abs/10.1002/ajae.12092>>. Citado na página 14.

GOODMAN-BACON, A. Difference-in-differences with variation in treatment timing. **Journal of Econometrics**, v. 225, n. 2, p. 254–277, 2021. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0304407621001445>>. Citado na página 13.

MAVI, H. S.; TUPPER, G. J. **Agrometeorology: Principles and Applications of Climate Studies in Agriculture**. 1. ed. CRC Press, 2004. Disponível em: <<https://doi.org/10.1201/9781482277999>>. Citado na página 12.

MINISTÉRIO DA AGRICULTURA E PECUÁRIA. **Ministro Carlos Fávaro assina acordo que garante instalação de 220 novas estações meteorológicas no país**. 2025. Publicado em: 3 set. 2025. Acesso em: 4 set. 2025. Disponível em: <<https://www.gov.br/agricultura/pt-br/assuntos/noticias/ministro-carlos-favaro-assina-acordo-que-garante-instalacao-de-220-novas-estacoes-meteorologicas-no>>. Citado na página 44.

MONTEIRO, J. E. B. A. **Agrometeorologia dos cultivos: o fator meteorológico na produção agrícola**. Brasília, DF: INMET, 2009. 530 p. ISBN 978-85-62817-00-7. Citado na página 12.

MONTEIRO, L. A.; SENTELHAS, P. C. Sugarcane yield gap: can it be determined at national level with a simple agrometeorological model? **Crop and Pasture Science**, v. 68, n. 3, p. 272–284, 2017. Disponível em: <<https://doi.org/10.1071/CP16334>>. Citado na página 14.

ORTIZ-BOBEA, A. et al. **The Historical Impact of Anthropogenic Climate Change on Global Agricultural Productivity**. 2020. Disponível em: <<https://arxiv.org/abs/2007.10415>>. Citado na página 12.

R Core Team. **R: A Language and Environment for Statistical Computing**. Vienna, Austria, 2025. Disponível em: <<https://www.R-project.org/>>. Citado na página 26.

RIJKS, D.; BARADAS, M. W. The clients for agrometeorological information. **Agricultural and Forest Meteorology**, v. 103, n. 1, p. 27–42, 2000. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0168192300001167>>. Citado na página 12.

SANT'ANNA, P. H. C.; ZHAO, J. Doubly robust difference-in-differences estimators. **Journal of Econometrics**, v. 219, n. 1, p. 101–122, 2020. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0304407620301901>>. Citado na página 23.

SUN, L.; ABRAHAM, S. Estimating dynamic treatment effects in event studies with heterogeneous treatment effects. **Journal of Econometrics**, v. 225, n. 2, p. 175–199, 2021. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S030440762030378X>>. Citado na página 13.

VIANNA, M. d. S.; SENTELHAS, P. C. Performance of DSSAT CSM-CANEGRO under operational conditions and its use in determining the 'saving irrigation' impact on sugarcane crop. **Sugar Tech**, v. 18, n. 1, p. 75–86, 2016. Disponível em: <<https://doi.org/10.1007/s12355-015-0367-0>>. Citado na página 12.

WEISS, A.; VAN CROWDER, L.; BERNARDI, M. Communicating agrometeorological information to farming communities. **Agricultural and Forest Meteorology**, v. 103, n. 1, p. 185–196, 2000. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0168192300001118>>. Citado na página 12.

## Apêndices

## APÊNDICE A – Código do GitHub

O código completo utilizado nesta pesquisa, incluindo os scripts de coleta de dados, análise econométrica e geração de visualizações, está disponível no repositório GitHub:

[<https://github.com/danielcavalli/tcc-ie-ufrj-2024>](https://github.com/danielcavalli/tcc-ie-ufrj-2024)

O repositório contém:

- Scripts SQL para extração de dados do BigQuery
- Código Python para processamento e limpeza dos dados
- Scripts R para implementação do modelo de Callaway e Sant’Anna
- Documentação detalhada dos procedimentos metodológicos
- Instruções para reprodução dos resultados

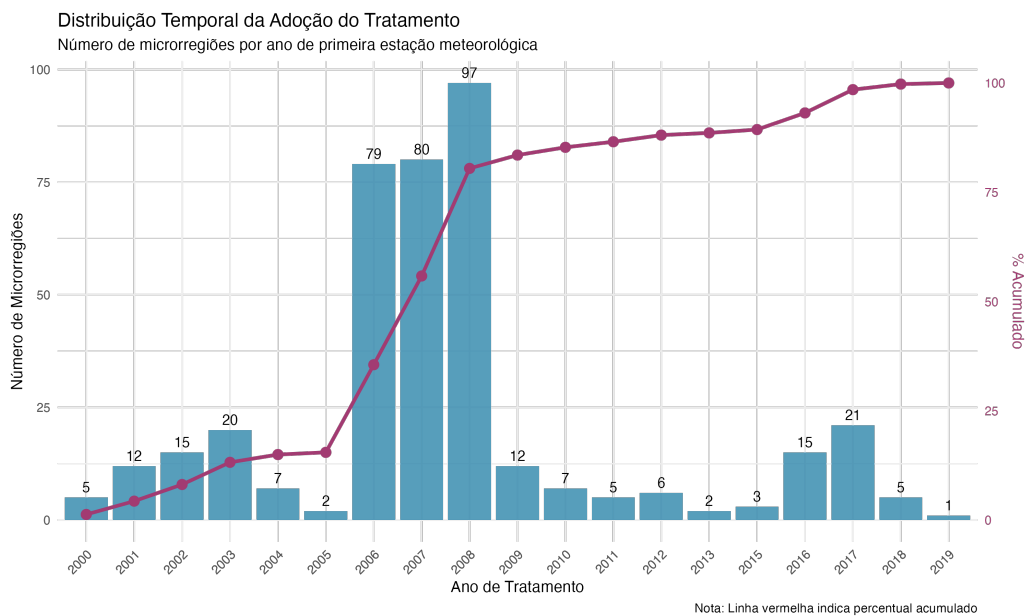
## APÊNDICE B – Estatísticas Descritivas Complementares

Este apêndice apresenta estatísticas descritivas complementares que apoiam a análise principal.

### B.1 Distribuição Temporal do Tratamento

A Figura 6 apresenta a evolução temporal da instalação de estações meteorológicas:

Figura 6 – Distribuição Temporal da Instalação de Estações Meteorológicas



Nota: O gráfico mostra o número de microrregiões que receberam sua primeira estação meteorológica em cada ano. Observa-se uma concentração significativa de instalações no período 2006-2008, coincidindo com programas federais de expansão da rede meteorológica.

Tabela 7 – Número de microrregiões tratadas por ano

Ano	Microrregiões com Primeira Estação	N Obs
2000	5	105
2001	10	210
2002	14	294
2003	19	399
2004	6	126
2005	2	42
2006	76	1596
2007	70	1470
2008	82	1722
2009	11	231
2010	6	126
2011	3	63
2012	6	126
2013	2	42
2015	2	42
2016	15	315
2017	16	336
2018	5	105
2019	1	21

Tabela 8 – Distribuição do tratamento por região

Região	Microrregiões	Tratadas	% Tratadas
Norte	15	8	53,3%
Nordeste	142	45	31,7%
Centro-Oeste	51	22	43,1%
Sudeste	160	48	30,0%
Sul	26	8	30,8%
Total	558	—	—

## B.2 Estatísticas por Região

## B.3 Produtividade Média por Status de Tratamento

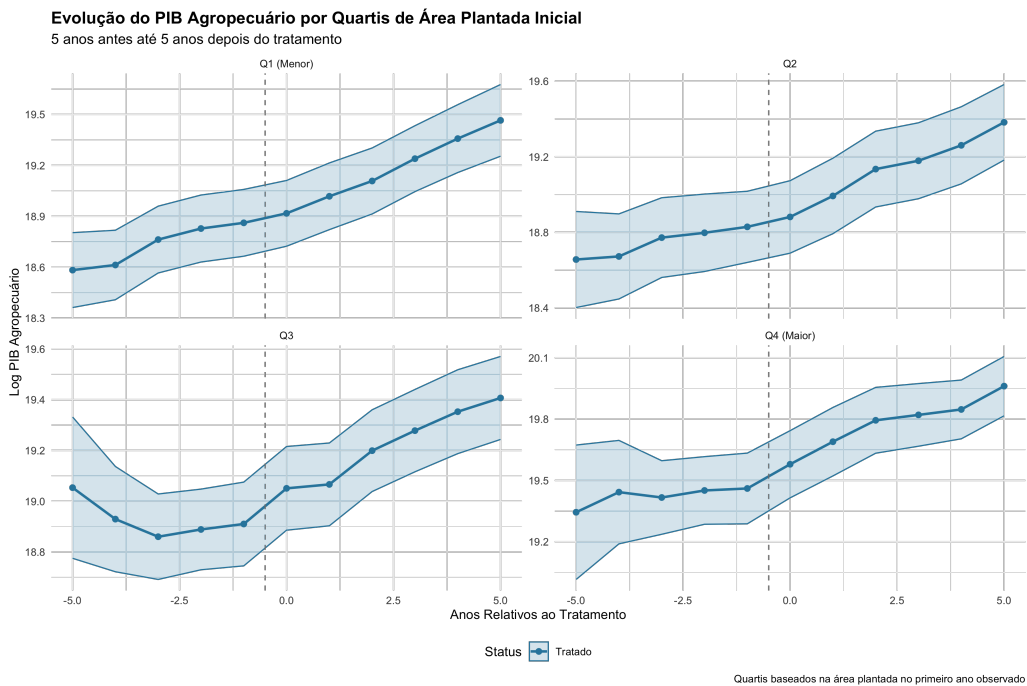
## B.4 Tendências por Quartil de Área Plantada

A Figura 7 apresenta a evolução do PIB agropecuário para grupos tratados e controle, separados por quartis de área plantada:

Tabela 9 – Produtividade média (ton/ha) por período

Período	Nunca Tratadas	Ainda Não Tratadas	Já Tratadas	Diferença
2000-2007	71,2	72,8	73,5	0,7
2008-2014	72,5	74,3	78,9	4,6
2015-2021	74,1	75,2	83,7	8,5

Figura 7 – Tendências do PIB Agropecuário por Quartil de Área Plantada



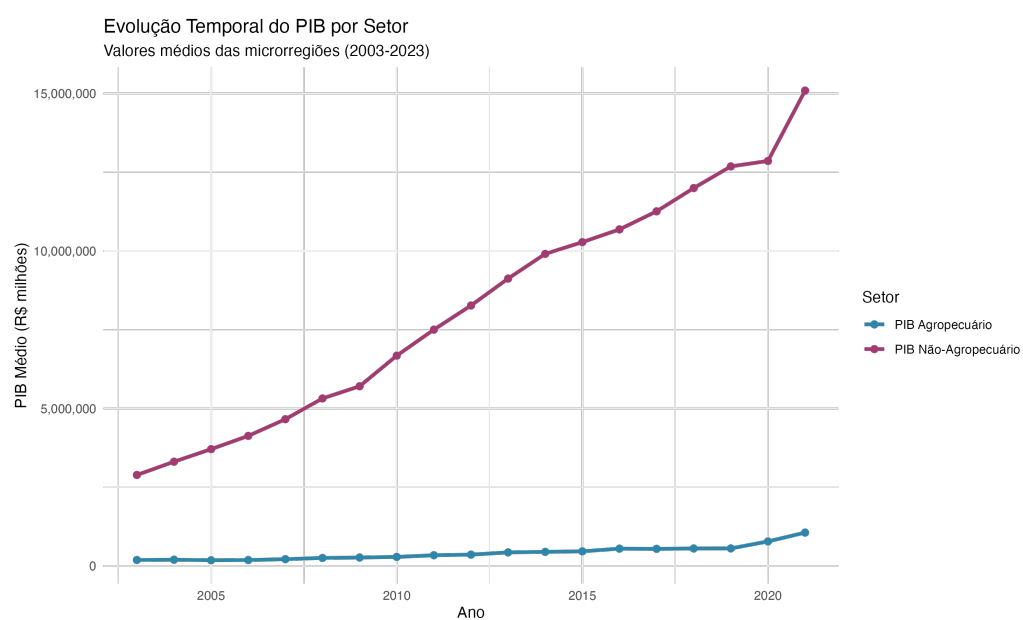
Nota: Os gráficos mostram a evolução do log do PIB agropecuário para grupos tratados (azul) e controle (área sombreada) em cada quartil de área plantada (Q1 = menor área, Q4 = maior área). A linha vertical tracejada indica o período de início da instalação das estações.

## B.5 Análises Descritivas Complementares

A Figura 8 apresenta a evolução temporal comparativa entre PIB agropecuário e não-agropecuário:

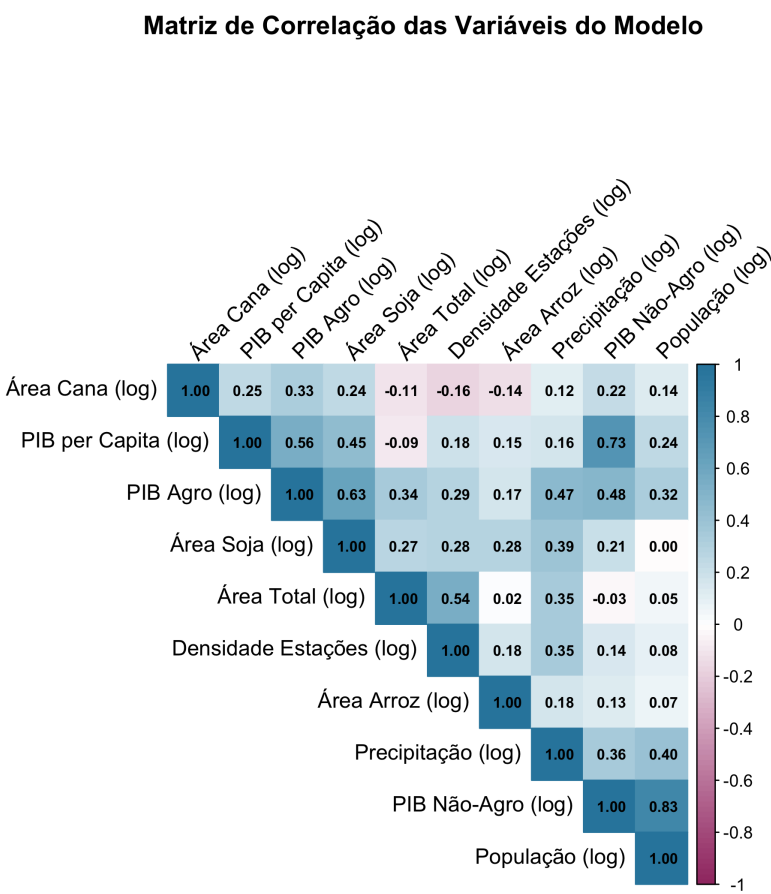
A Figura 9 apresenta a matriz de correlação entre as principais variáveis utilizadas no estudo:

Figura 8 – Evolução Temporal do PIB Agropecuário vs PIB Não-Agropecuário



Nota: O gráfico mostra a evolução temporal do PIB agropecuário e do PIB não-agropecuário médio (em log) para as microrregiões da amostra. A comparação permite visualizar as dinâmicas distintas entre os setores ao longo do período analisado.

Figura 9 – Matriz de Correlação das Variáveis Principais



Nota: A matriz mostra as correlações entre PIB agropecuário, área plantada, população, precipitação e outras variáveis relevantes. Valores mais próximos de 1 indicam correlação positiva forte.