

Daniel Cavalli

**Impacto Localizado de Novas Estações
Meteorológicas na Produtividade Agrícola: Uma
Abordagem de Tratamento Deslocado e
Emparelhamento Dinâmico**

Rio de Janeiro

2025

Daniel Cavalli

Impacto Localizado de Novas Estações Meteorológicas na Produtividade Agrícola: Uma Abordagem de Tratamento Deslocado e Emparelhamento Dinâmico

Monografia apresentada ao Instituto de Economia da Universidade Federal do Rio de Janeiro como parte dos requisitos necessários à obtenção do título de Bacharel em Ciências Econômicas.

Universidade Federal do Rio de Janeiro – UFRJ

Instituto de Economia

Graduação em Ciências Econômicas

Orientador: Prof. Romero Rocha

Rio de Janeiro

2025

Daniel Cavalli

Impacto Localizado de Novas Estações Meteorológicas na Produtividade Agrícola: Uma Abordagem de Tratamento Deslocado e Emparelhamento Dinâmico

Monografia apresentada ao Instituto de Economia da Universidade Federal do Rio de Janeiro como parte dos requisitos necessários à obtenção do título de Bacharel em Ciências Econômicas.

Trabalho aprovado. Rio de Janeiro, 4 de setembro de 2025:

Prof. Romero Rocha
Orientador

Professor
Convidado 1

Professor
Convidado 2

Rio de Janeiro
2025

Este trabalho é dedicado aos agricultores brasileiros, que diariamente enfrentam os desafios da variabilidade climática na busca por produzir alimentos para nossa nação.

Agradecimentos

*“In mathematics you don’t understand things.
You just get used to them.”*
(John von Neumann)

Resumo

Este estudo examina o impacto causal da instalação de estações meteorológicas automáticas sobre a produtividade da cana-de-açúcar no Brasil, utilizando dados em painel de 394 microrregiões produtoras de cana-de-açúcar entre 2000 e 2021. Empregamos o arcabouço de Diferenças em Diferenças com adoção escalonada proposto por Callaway e Sant'Anna (2020), adequado para contextos onde o tratamento ocorre em diferentes momentos do tempo. A estratégia de identificação explora a variação temporal e geográfica na instalação de estações, com 98% das microrregiões permanecendo como controles não tratados. Os resultados principais, obtidos através do estimador doubly robust, indicam um efeito médio do tratamento (ATT) de 10,9% (IC 95%: [6,0%; 15,7%], $p < 0,001$), representando ganhos de produtividade economicamente significativos. A análise de event study revela ausência de tendências pré-tratamento diferenciadas (validando o pressuposto de identificação) e uma dinâmica pós-tratamento crescente, com efeitos que se intensificam ao longo do tempo, alcançando 20% após cinco anos de exposição. Testes extensivos de robustez, incluindo placebos temporais e aleatórios, especificações alternativas, e análise de sensibilidade a diferentes grupos de controle, confirmam a consistência dos resultados. A magnitude estimada sugere que o investimento em infraestrutura meteorológica oferece retornos substanciais, com implicações importantes para políticas de desenvolvimento agrícola e adaptação climática. O estudo contribui para a literatura sobre tecnologia agrícola e informação, demonstrando empiricamente como dados meteorológicos precisos podem melhorar significativamente a eficiência produtiva no setor agrícola.

Palavras-chave: estações meteorológicas. produtividade agrícola. cana-de-açúcar. diferenças em diferenças. Callaway e Sant'Anna.

Abstract

This study examines the causal impact of automatic weather station installation on sugarcane productivity in Brazil, using panel data from 394 sugarcane-producing microregions between 2000 and 2021. We employ the staggered adoption Differences-in-Differences framework proposed by Callaway and Sant'Anna (2020), suitable for contexts where treatment occurs at different points in time. The identification strategy exploits temporal and geographic variation in station installation, with 98% of microregions remaining as untreated controls. The main results, obtained through the doubly robust estimator, indicate an average treatment effect (ATT) of 10.9% (95% CI: [6.0%; 15.7%], $p < 0.001$), representing economically significant productivity gains. The event study analysis reveals absence of differential pre-treatment trends (validating the identification assumption) and an increasing post-treatment dynamic, with effects intensifying over time, reaching 20% after five years of exposure. Extensive robustness tests, including temporal and random placebos, alternative specifications, and sensitivity analysis to different control groups, confirm the consistency of results. The estimated magnitude suggests that investment in meteorological infrastructure offers substantial returns, with important implications for agricultural development policies and climate adaptation. The study contributes to the literature on agricultural technology and information, empirically demonstrating how precise meteorological data can significantly improve productive efficiency in the agricultural sector.

Keywords: weather stations. agricultural productivity. sugarcane. differences-in-differences. Callaway and Sant'Anna.

Lista de ilustrações

Figura 1 – Event Study - Dinâmica Temporal dos Efeitos da Instalação de Estações Meteorológicas	27
-----------------------------------------------------------------------------------------------------------	----

Lista de tabelas

Tabela 1 – Comparação de Estimativas por Grupo de Controle	29
Tabela 2 – Comparação de Métodos de Estimação	30
Tabela 3 – Número de microrregiões tratadas por ano	39
Tabela 4 – Distribuição do tratamento por região	39
Tabela 5 – Produtividade média (ton/ha) por período	40
Tabela 6 – Teste de diferenças pré-tratamento	40

Sumário

1	INTRODUÇÃO	12
1.1	O papel da agrometeorologia na produtividade agrícola	12
1.2	O papel da econometria	13
2	OBJETIVOS	15
3	REFERENCIAL TEÓRICO	16
4	ESPECIFICAÇÃO DO MODELO	18
4.1	Introdução ao Modelo	18
4.2	Fundamentos do modelo	18
4.2.1	Group-Time Average Treatment Effects ATT(g,t)	19
4.2.2	Identificação	19
4.2.3	Estimação	20
4.2.4	Agregação de Efeitos	20
4.3	Concluindo	21
5	METODOLOGIA E RESULTADOS	22
5.1	Estratégia Empírica	22
5.1.1	Definição do Tratamento e Unidades de Análise	22
5.1.2	Construção dos Grupos de Tratamento	22
5.1.3	Variável Dependente e Transformações	23
5.1.4	Covariáveis e Especificação do Modelo	23
5.1.5	O Estimador Doubly Robust	24
5.2	Especificação do Event Study	24
5.2.1	Formalização do Event Study	24
5.3	Implementação Computacional	25
5.3.1	Software e Pacotes Utilizados	25
5.3.2	Estrutura dos Dados e Tratamento de Missings	25
5.4	Resultados Principais	26
5.4.1	Efeito Médio do Tratamento	26
5.4.2	Análise de Event Study e Dinâmica Temporal	27
5.4.2.1	Período Pré-Tratamento: Validação das Tendências Paralelas	27
5.4.2.2	Dinâmica Pós-Tratamento: Difusão Gradual dos Benefícios	28
5.5	Testes de Robustez e Diagnósticos	28
5.5.1	Análise de Pesos e Composição do ATT	29

5.5.2	Comparação de Grupos de Controle	29
5.5.3	Testes Placebo	29
5.5.4	Especificações Alternativas	30
5.6	Discussão e Interpretação Econômica	30
5.6.1	Magnitude e Relevância Econômica	30
5.6.2	Mecanismos Subjacentes	30
5.6.3	Limitações e Pesquisa Futura	31
5.7	Síntese e Conclusões da Análise Empírica	31
6	CONCLUSÕES FINAIS	33
	REFERÊNCIAS	34
	APÊNDICES	36
	APÊNDICE A – CÓDIGO DO GITHUB	37
	ANEXOS	38
	ANEXO A – ESTATÍSTICAS DESCRITIVAS COMPLEMENTARES	39
A.1	Distribuição Temporal do Tratamento	39
A.2	Estatísticas por Região	39
A.3	Produtividade Média por Status de Tratamento	40
A.4	Teste de Balanceamento de Covariadas	40
A.5	Análise de Sensibilidade - Dados Faltantes	40

1 Introdução

A produtividade agrícola é profundamente influenciada pelas condições meteorológicas, que moldam tanto o desenvolvimento fisiológico das culturas quanto a eficácia das práticas de manejo. MONTEIRO (2009) destacam que a variabilidade da produção agrícola global é amplamente explicada pelas oscilações climáticas durante o ciclo de cultivo, o que reforça a importância de sistemas robustos de monitoramento climático. Nesse contexto, a agrometeorologia surge como uma ferramenta estratégica, permitindo a integração de dados meteorológicos e agrícolas para apoiar decisões mais eficientes e sustentáveis. Diante da pressão crescente por maior produção de alimentos e energia renovável, sem ampliar o uso de recursos naturais, torna-se essencial adotar instrumentos capazes de reduzir riscos climáticos e ampliar a resiliência produtiva do setor agrícola.

1.1 O papel da agrometeorologia na produtividade agrícola

A agrometeorologia desempenha um papel crucial na agricultura ao fornecer informações meteorológicas aplicadas diretamente às necessidades dos cultivos. Esse campo integra dados climáticos e meteorológicos com parâmetros específicos das culturas, permitindo a antecipação dos efeitos do clima sobre as práticas agrícolas e possibilitando decisões mais informadas e eficientes. Como apontado por RIJKS e BARADAS (2000), os Serviços Nacionais de Meteorologia contribuem significativamente para a economia agrícola ao divulgar essas informações e facilitar seu uso eficiente, ajudando a mitigar riscos e aumentar a produtividade.

Segundo MAVI e TUPPER (2004), as informações agrometeorológicas são aplicáveis em três áreas principais: no planejamento agrícola, na tomada de decisões táticas e na resiliência dos sistemas agrícolas. No planejamento, esses dados ajudam na escolha das épocas e locais mais adequados para o cultivo, considerando o macroclima e as condições específicas de cada região. Essa etapa é essencial para ajustar as atividades agrícolas ao contexto climático regional, reduzindo desperdícios e promovendo o uso sustentável dos recursos.

No contexto tático, as informações meteorológicas auxiliam na determinação dos melhores momentos para práticas agrícolas como a irrigação, semeadura e colheita, o que contribui para uma execução mais precisa e eficiente das operações. Essas decisões são ainda mais importantes em áreas de cultivo de sequeiro, onde a dependência da precipitação é alta, e os dados sobre previsão de chuva e evapotranspiração são fundamentais para otimizar o uso dos recursos hídricos (PEREIRA; ANGELOCCI; SENTELHAS, 2002).

Com a instalação de novas estações meteorológicas em áreas rurais, as informações climáticas se tornam mais precisas e localizadas, permitindo que os agricultores ajustem suas práticas de acordo com as condições específicas de suas regiões (WEISS; VAN CROWDER; BERNARDI, 2000). Sistemas de Informação Agrometeorológica, como o AGRITEMPO da EMBRAPA e o SISDAGRO do INMET, utilizam dados dessas estações meteorológicas para fornecer previsões de safra e orientações sobre manejo de recursos hídricos, ajudando os agricultores a tomar decisões informadas sobre a época de plantio, irrigação e controle fitossanitário (WEISS; VAN CROWDER; BERNARDI, 2000). Essas informações são cruciais para o presente estudo, pois evidenciam que dados meteorológicos detalhados e acessíveis podem impactar diretamente a produtividade agrícola.

Estudos recentes reforçam a importância da informação climática para a produtividade agrícola. ORTIZ-BOBEA, KNIPPENBERG e CHAMBERS (2023) demonstram que as mudanças climáticas já impactam significativamente a produtividade global, tornando ainda mais crítico o acesso a informações meteorológicas precisas. ASSAD et al. (2022) analisam os impactos e vulnerabilidades da agricultura brasileira às mudanças climáticas, destacando a importância de sistemas de monitoramento e adaptação. A adoção de tecnologias e melhorias no manejo tem mostrado potencial para mitigar efeitos climáticos adversos na produtividade agrícola brasileira (COSTA et al., 2021), enquanto avanços em sensoriamento remoto e análise de dados ampliam o potencial de uso dessas informações (BURKE et al., 2021).

1.2 O papel da econometria

Apesar da importância reconhecida da agrometeorologia, são escassos os estudos que quantificam empiricamente o impacto da instalação de novas estações sobre a produtividade agrícola. O desafio metodológico central é que a instalação das estações ocorre de forma escalonada ao longo do tempo, o que inviabiliza o uso simples do modelo clássico de Diferenças em Diferenças (DiD) com Two-Way Fixed Effects (TWFE). Trabalhos como GOODMAN-BACON (2021) e SUN e ABRAHAM (2021) mostraram que, nesses contextos, o estimador TWFE pode produzir resultados enviesados, pois utiliza unidades já tratadas como controles e mistura heterogeneidades de efeito ao longo do tempo.

Para superar essas limitações, este estudo adota o arcabouço desenvolvido por CALLAWAY e SANT'ANNA (2021), que propõem um estimador de Diferenças em Diferenças robusto para múltiplos períodos de tratamento. Esse método calcula efeitos médios específicos a cada coorte de adoção ($ATT(g,t)$), utilizando apenas grupos de comparação válidos, e depois os agrega segundo esquemas de ponderação coerentes com a pergunta empírica. Além disso, permite construir análises dinâmicas em tempo relativo (event studies), avaliando tanto o surgimento quanto a persistência dos efeitos ao longo do

tempo, ao mesmo tempo em que possibilita a verificação do pressuposto de tendências paralelas no pré-tratamento.

O método de DiD escalonado tem sido crescentemente aplicado em estudos sobre agricultura e mudanças climáticas. [CROST et al. \(2022\)](#) utilizaram uma abordagem similar para examinar os efeitos de choques climáticos sobre a produção agrícola e conflitos civis nas Filipinas, encontrando efeitos heterogêneos significativos ao longo do tempo. [GATTI, BAYLIS e CROST \(2023\)](#) aplicaram DiD com múltiplos períodos para avaliar como infraestrutura de irrigação mitiga o impacto de choques pluviométricos na Indonésia, demonstrando a importância de considerar a temporalidade da adoção de tecnologias. Essas aplicações reforçam a adequação do método para capturar efeitos dinâmicos de intervenções tecnológicas no setor agrícola.

2 Objetivos

O objetivo geral deste trabalho é estimar o efeito causal da instalação de novas estações meteorológicas sobre a produtividade da cana-de-açúcar no Brasil, utilizando o arcabouço de Diferenças em Diferenças com múltiplos períodos proposto por [CALLAWAY e SANT'ANNA \(2021\)](#). Ao empregar esse método, busca-se superar as limitações dos modelos tradicionais de Two-Way Fixed Effects (TWFE) em cenários de adoção escalonada, assegurando estimativas consistentes mesmo na presença de heterogeneidade de efeitos ao longo do tempo e entre unidades.

De forma mais específica, este estudo tem como objetivos:

- (i) quantificar o efeito médio do tratamento sobre os tratados (ATT) associado à instalação das estações meteorológicas, em termos de variação percentual da produtividade da cana-de-açúcar;
- (ii) estimar a dinâmica temporal do impacto, por meio de análises de evento (event studies), identificando tanto a ausência de tendências prévias quanto a evolução dos efeitos após a instalação;
- (iii) avaliar a robustez dos resultados por meio de especificações alternativas de estimação (Doubly Robust, IPW, Outcome Regression), bem como por testes de placebo que buscam identificar falsos efeitos em períodos fictícios;
- (iv) discutir as implicações dos resultados para a formulação de políticas públicas voltadas à expansão da infraestrutura meteorológica, destacando sua relevância para a resiliência agrícola e o desenvolvimento sustentável do setor.

A hipótese central que guia este trabalho é que a instalação de estações meteorológicas gera ganhos de produtividade agrícola mensuráveis, especialmente em regiões próximas às novas instalações, onde a qualidade e a precisão das informações climáticas disponibilizadas são mais elevadas. Caso confirmada, essa evidência reforça a importância da agrometeorologia como instrumento de política pública, capaz de promover eficiência produtiva e adaptação frente à variabilidade climática.

3 Referencial Teórico

A relação entre clima e produtividade agrícola é amplamente documentada na literatura. Estudos como [MONTEIRO \(2009\)](#) mostram que grande parte da variabilidade da produção agrícola mundial decorre de flutuações climáticas durante o ciclo produtivo, o que torna a gestão da informação meteorológica um fator estratégico. Nesse sentido, a agrometeorologia se consolida como ciência aplicada, integrando dados meteorológicos às práticas agrícolas com o objetivo de reduzir riscos e aumentar eficiência produtiva. Como apontado por [RIJKS e BARADAS \(2000\)](#), serviços meteorológicos bem estruturados podem gerar ganhos econômicos significativos ao disponibilizar informações precisas para produtores. [MAVI e TUPPER \(2004\)](#) destacam que essas informações podem orientar tanto o planejamento de longo prazo quanto decisões táticas de curto prazo, além de aumentar a resiliência dos sistemas agrícolas frente à variabilidade climática.

No Brasil, sistemas como o AGRITEMPO da EMBRAPA e o SISDAGRO do INMET já demonstram como a expansão da rede de estações meteorológicas pode ser traduzida em recomendações práticas de manejo. [WEISS, VAN CROWDER e BERNARDI \(2000\)](#) reforçam que dados mais granulares permitem previsões de safra mais acuradas e orientações localizadas sobre irrigação e controle fitossanitário. Essa literatura estabelece o vínculo entre maior densidade de informações meteorológicas e maior produtividade agrícola, mas ainda são escassos os trabalhos que estimam de forma causal o efeito da instalação de estações sobre a produção.

Para enfrentar essas limitações dos modelos TWFE, [CALLAWAY e SANT'ANNA \(2021\)](#) desenvolveram um framework alternativo que redefine a identificação em modelos de Diferenças em Diferenças com múltiplos períodos. O método propõe a estimação de efeitos médios específicos por coorte de adoção e período ($ATT(g,t)$), sempre utilizando grupos de comparação válidos, seguidos de uma agregação coerente com pesos bem definidos. Além disso, o arcabouço permite estimar a trajetória dinâmica do efeito em tempo relativo (event studies), o que possibilita avaliar tanto o surgimento quanto a persistência dos impactos, além de testar empiricamente a plausibilidade do pressuposto de tendências paralelas condicionais.

A abordagem de Diferenças em Diferenças (DiD) proposta por [CALLAWAY e SANT'ANNA \(2021\)](#) oferece um arcabouço flexível para analisar situações em que unidades recebem um tratamento ao longo de múltiplos períodos, e não todas no mesmo instante. Diferente do DiD comum, que se concentra tradicionalmente em apenas dois períodos (pré e pós-tratamento) e dois grupos (tratado e controle), a extensão proposta considera diversos grupos que podem iniciar o tratamento em momentos distintos, bem como múltiplos

períodos de observação. Esse modelo torna-se particularmente relevante em estudos que avaliam o impacto de intervenções ou choques econômicos que ocorram de forma escalonada (*staggered adoption*), permitindo lidar melhor com a heterogeneidade entre grupos e com problemas de interpretação associados ao uso de modelos de efeitos fixos bidimensionais (*Two-Way Fixed Effects*, TWFE).

Essa abordagem tem sido rapidamente incorporada em estudos aplicados em diversas áreas, como mercado de trabalho, políticas sociais e educação, mas ainda é pouco explorada em pesquisas sobre agricultura e clima. Ao adotar esse framework em um setor de relevância estratégica como o agronegócio brasileiro, este trabalho contribui não apenas empiricamente, ao estimar o impacto da instalação de estações meteorológicas sobre a produtividade da cana-de-açúcar, mas também metodologicamente, ao ilustrar a aplicabilidade de um dos métodos mais recentes e robustos de avaliação de impacto em políticas públicas.

4 Especificação do Modelo

Para este trabalho, utilizaremos como principal referência o artigo de [CALLAWAY e SANT'ANNA \(2021\)](#), que apresenta uma extensão do modelo de Diferenças em Diferenças (DiD) para cenários com múltiplos períodos e momentos distintos de adoção do tratamento.

4.1 Introdução ao Modelo

No DiD clássico, assume-se um grupo tratado que recebe a intervenção em um momento específico e um grupo controle que nunca é tratado. Sob essa configuração, a diferença no tempo entre pré e pós-tratamento e a diferença entre grupos tratado e controle fornecem a estimativa do efeito causal. Entretanto, para o caso que estamos tratando nesse trabalho existem múltiplos períodos e vários grupos recebendo o tratamento em momentos distintos ao longo dos 22 anos do período de tratamento. A abordagem de DiD tradicional, nesse caso, pode gerar estimativas enviesadas devido à heterogeneidade do tratamento ao longo do tempo, resultando em interpretação ambígua.

O modelo de [CALLAWAY e SANT'ANNA \(2021\)](#) surge como uma forma de permitir que esses cenários de tratamento escalonado, talvez muito mais comuns no mundo real do que experimentos naturais, possam ser avaliados. Por permitir a identificação de efeitos médios do tratamento específicos para cada grupo e período, acomoda a heterogeneidade do momento de adoção e suas dinâmicas, além de fornecer uma interpretação mais clara dos parâmetros causais.

4.2 Fundamentos do modelo

O modelo proposto pode ser entendido em três etapas conceituais:

1. **Identificação de parâmetros causais desagregados:** Primeiro, são obtidas estimativas do efeito causal para cada combinação de grupo tratado e período após a adoção (denotados por $ATT(g,t)$), focando em captar o efeito específico para um determinado conjunto de unidades tratadas em um dado momento do tempo.
2. **Agregação desses parâmetros:** Em seguida, esses parâmetros individuais, definidos para grupos e períodos específicos, podem ser combinados para produzir medidas resumidas de efeitos, como efeitos médios globais, ao longo do tempo, por coorte de tratamento ou segundo o tempo decorrido desde a intervenção.

3. **Estimação e inferência:** Por fim, procedimentos estatísticos são empregados para estimar esses parâmetros, bem como inferir sobre sua significância estatística.

4.2.1 Group-Time Average Treatment Effects $ATT(g,t)$

O parâmetro fundamental dessa abordagem é o $ATT(g,t)$, que representa o Efeito Médio do Tratamento para o grupo g no período t . Ao contrário do DiD tradicional, onde há um único efeito estimado, aqui obtemos uma coleção de efeitos, cada um refletindo o impacto do tratamento em um grupo que começou a ser tratado em um determinado momento e está sendo avaliado em um período específico após o início do tratamento.

Com isso é possível capturar heterogeneidades relacionadas:

- Ao grupo (unidades diferentes podem ter características e contextos distintos);
- Ao momento de início do tratamento (tratamentos iniciados em diferentes épocas podem ter efeitos variados devido a condições econômicas, políticas ou sociais);
- Ao tempo decorrido desde o tratamento (efeitos imediatos versus efeitos de longo prazo podem diferir).

4.2.2 Identificação

O artigo de [CALLAWAY e SANT'ANNA \(2021\)](#) apresenta uma série de pressupostos para identificação dos parâmetros causais. Boa parte delas não difere muito dos pressupostos do DiD tradicional. Abaixo destaco algumas importantes mudanças:

1. **Tendências Paralelas Condicionais:** A ideia central do DiD é que, na ausência de tratamento, as unidades tratadas seguiriam a mesma tendência de evolução dos resultados das unidades não tratadas. Existem diferenças conceituais entre o DiD tradicional e o DiD Staggered:
 - **Pressuposto 4 - “never-treated”:** Aqui, o grupo de comparação é formado por unidades que nunca recebem tratamento ao longo de todo o período observado. Pressupõe-se que, condicionalmente a covariáveis observáveis, esses “never-treated” representam a contrafactual apropriada para o que teria acontecido com os grupos tratados caso não tivessem sido tratados.
 - **Pressuposto 5 - “not-yet-treated”:** Nesse caso, o grupo de controle para um determinado período e grupo tratado é formado por unidades que ainda não foram tratadas até aquele momento, mas que virão a ser tratadas no futuro. Essa abordagem aproveita a natureza escalonada do tratamento para criar um grupo de comparação internamente consistente.

2. **Pressuposto 3 - Antecipação Limitada do Tratamento:** Admite-se que as unidades não são afetadas pelo tratamento antes de sua efetiva implementação, ou que se conheçam efeitos de antecipação limitados e controláveis. Caso haja antecipação, o modelo permite incorporar essa informação, desde que os períodos de antecipação sejam conhecidos e adequadamente modelados.
3. **Sobreposição (Overlap):** É necessário que haja sobreposição entre as características das unidades tratadas e as unidades de controle, garantindo que as diferenças observadas possam ser atribuídas ao tratamento e não a dessemelhanças estruturais entre grupos.

4.2.3 Estimação

Para estimar o $ATT(g,t)$, são propostas três abordagens principais:

1. **Outcome Regression (OR):** Modela-se diretamente o resultado nos grupos de controle, condicionando a covariáveis pré-tratamento. O efeito é então obtido comparando a predição contrafactual com o resultado efetivo observado nas unidades tratadas.
2. **Inverse Probability Weighting (IPW):** Aqui, pondera-se cada unidade pela probabilidade condicional de tratamento. Ao ajustar esses pesos, obtém-se um contrafactual equilibrado, simulando um cenário onde o tratamento foi aplicado aleatoriamente.
3. **Doubly Robust (DR):** Combina OR e IPW, resultando em um estimador robusto a erros de especificação. Mesmo se um dos modelos (outcome ou probabilidade) estiver incorretamente especificado, a consistência pode ser mantida. Na prática, essa abordagem é muitas vezes recomendada por oferecer maior segurança em cenários reais, onde a especificação perfeita do modelo é incerta.

4.2.4 Agregação de Efeitos

Depois de estimar uma coleção de $ATT(g,t)$, é possível agregá-los de diferentes maneiras, fornecendo visões mais resumidas e interpretáveis:

- **Por tempo de exposição ao tratamento (Event Study):** Consolida-se o $ATT(g,t)$ em função do tempo decorrido após o início do tratamento. Isso permite visualizar a dinâmica do efeito: se ele cresce, diminui ou se mantém estável ao longo dos períodos pós-tratamento.

- **Por grupo de tratamento:** Agrupar $ATT(g,t)$ por coortes de adoção do tratamento, possibilitando examinar heterogeneidades entre diferentes grupos que adotaram o tratamento em momentos distintos.
- **Por tempo calendário:** Examina-se o impacto agregado em determinados períodos, independentemente do tempo de exposição, auxiliando a entender efeitos conjunturais.
- **Como um efeito médio global (Overall Treatment Effect):** Por fim, é possível sintetizar todos os efeitos $ATT(g,t)$ em um único parâmetro médio, oferecendo uma visão geral do impacto da intervenção ao longo do tempo e grupos.

4.3 Concluindo

A abordagem apresentada por [CALLAWAY e SANT'ANNA \(2021\)](#) não se reduz a uma única equação final, pois seu objetivo é oferecer uma estrutura flexível para estimar efeitos causais médios (ATT) específicos para cada grupo e período, além de permitir a agregação desses efeitos de diferentes maneiras. No entanto, ela pode ser representada pela seguinte equação genérica:

$$\theta = \sum_{g \in \mathcal{G}} \sum_{t=2}^T w(g, t) \cdot ATT(g, t) \quad (4.1)$$

onde:

- θ é o efeito agregado de interesse
- $ATT(g, t)$ é o Efeito Médio do Tratamento para a coorte g no período t
- $w(g, t)$ são funções de ponderação escolhidas pelo pesquisador (seção 3.1.1 do artigo), conhecidas ou estimáveis a partir dos dados, que determinam a importância relativa de cada $ATT(g, t)$ na composição do efeito agregado
- \mathcal{G} é o conjunto de coortes de tratamento

5 Metodologia e Resultados

5.1 Estratégia Empírica

A estratégia de identificação adotada neste trabalho baseia-se no arcabouço econométrico desenvolvido por [CALLAWAY e SANT'ANNA \(2021\)](#), especificamente desenhado para contextos de adoção escalonada (*staggered adoption*), onde diferentes unidades recebem o tratamento em momentos distintos ao longo do tempo. Esta abordagem é particularmente adequada para o nosso contexto, onde a instalação de estações meteorológicas ocorreu de forma gradual entre 2000 e 2021 em diferentes microrregiões brasileiras produtoras de cana-de-açúcar.

5.1.1 Definição do Tratamento e Unidades de Análise

O tratamento é definido como a instalação de pelo menos uma estação meteorológica automática em funcionamento na microrregião. A escolha da microrregião como unidade de análise justifica-se por três razões principais:

1. **Escala geográfica apropriada:** As microrregiões representam agrupamentos de municípios com características agroclimáticas similares, permitindo capturar adequadamente a área de influência das informações meteorológicas.
2. **Estabilidade institucional:** Diferentemente dos municípios, que podem sofrer desmembramentos, as microrregiões mantêm fronteiras estáveis ao longo do período analisado.
3. **Poder estatístico:** A agregação em microrregiões produtoras de cana-de-açúcar (394 unidades com produção registrada no período) oferece um equilíbrio entre granularidade espacial e tamanho amostral suficiente para identificação robusta dos efeitos.

5.1.2 Construção dos Grupos de Tratamento

Seguindo a notação de [CALLAWAY e SANT'ANNA \(2021\)](#), definimos G_i como o ano em que a microrregião i recebe sua primeira estação meteorológica. Para unidades nunca tratadas durante o período de análise, convencionamos $G_i = 0$. Esta codificação é essencial para a implementação computacional e permite a utilização dessas unidades como grupo de controle potencial.

A distribuição temporal da adoção revela padrões interessantes: observa-se uma concentração de instalações em 2007-2008 (18 unidades), coincidindo com programas federais de expansão da rede meteorológica, seguida por adoção mais esparsa nos anos subsequentes. Notavelmente, 386 microrregiões produtoras de cana-de-açúcar (98% do total de 394) permanecem sem estações ao final do período, fornecendo um amplo grupo de controle.

5.1.3 Variável Dependente e Transformações

A variável dependente principal é o logaritmo natural da produtividade da cana-de-açúcar, definida como:

$$Y_{it} = \ln(1 + \text{Produtividade}_{it}) \quad (5.1)$$

onde $\text{Produtividade}_{it}$ é medida em toneladas por hectare para a microrregião i no ano t . A transformação logarítmica oferece três vantagens metodológicas importantes:

1. **Interpretação econômica direta:** Os coeficientes estimados podem ser interpretados aproximadamente como variações percentuais na produtividade, facilitando a comunicação dos resultados.
2. **Redução de heterocedasticidade:** A transformação log suaviza a variância crescente tipicamente observada em dados de produtividade agrícola.
3. **Tratamento de zeros:** O uso de $\ln(1 + x)$ evita problemas computacionais quando há observações com produtividade zero, mantendo essas observações na amostra.

5.1.4 Covariáveis e Especificação do Modelo

A especificação inclui como covariável principal a precipitação normalizada pela área plantada, capturando variações climáticas que afetam diretamente a produtividade agrícola. A escolha parcimoniosa de covariáveis segue três princípios:

1. **Variáveis pré-determinadas:** Incluímos apenas variáveis determinadas antes do tratamento ou plausivelmente exógenas às decisões de instalação das estações.
2. **Relevância agrônômica:** A precipitação é reconhecidamente o fator climático mais crítico para a produtividade da cana-de-açúcar em regime de sequeiro.
3. **Variabilidade suficiente:** Diagnósticos preliminares confirmam variância adequada no período pré-tratamento, evitando problemas de colinearidade.

5.1.5 O Estimador Doubly Robust

Para a estimação dos efeitos causais, adotamos o estimador *Doubly Robust* (DR) proposto por SANT'ANNA e ZHAO (2020), que combina modelos de regressão para o resultado (*outcome regression*) com ponderação por probabilidade inversa (*inverse probability weighting*). Esta abordagem oferece propriedades estatísticas desejáveis:

- **Dupla proteção contra má especificação:** O estimador permanece consistente se pelo menos um dos dois modelos (resultado ou propensity score) estiver corretamente especificado.
- **Eficiência melhorada:** Sob especificação correta de ambos os modelos, o DR atinge a fronteira de eficiência semiparamétrica.
- **Robustez a extremos:** A combinação de métodos mitiga problemas associados a pesos extremos no IPW puro.

5.2 Especificação do Event Study

A análise de event study constitui o núcleo da nossa estratégia empírica, permitindo examinar como o efeito do tratamento evolui dinamicamente ao longo do tempo. Esta abordagem é particularmente adequada para nosso contexto por três razões fundamentais:

1. **Teste de tendências paralelas:** Permite verificar visualmente e estatisticamente se os grupos tratados e controle seguiam trajetórias similares antes do tratamento, validando o pressuposto fundamental de identificação.
2. **Dinâmica de adoção tecnológica:** Captura o processo gradual de difusão e aprendizado associado ao uso de informações meteorológicas, reconhecendo que os benefícios podem não ser imediatos.
3. **Heterogeneidade temporal:** Acomoda a possibilidade de que os efeitos variem com o tempo de exposição ao tratamento, seja por acumulação de conhecimento ou mudanças nas práticas agrícolas.

5.2.1 Formalização do Event Study

Definimos o tempo relativo ao tratamento como $e = t - g$, onde g é o ano de instalação da primeira estação e t é o período calendário. Assim, $e < 0$ representa períodos pré-tratamento, $e = 0$ marca o início do tratamento, e $e > 0$ captura períodos pós-tratamento.

A agregação dos efeitos $ATT(g,t)$ em função do tempo relativo segue a especificação:

$$\theta^{es}(e) = \sum_{g \in \mathcal{G}} \mathbf{1}\{g + e \leq T\} \cdot P(G = g | G + e \leq T) \cdot ATT(g, g + e) \quad (5.2)$$

onde:

- $\theta^{es}(e)$ representa o efeito médio do tratamento e períodos após sua introdução
- \mathcal{G} é o conjunto de coortes de adoção (excluindo nunca tratados)
- $P(G = g | G + e \leq T)$ são pesos que garantem que cada coorte contribua proporcionalmente ao número de unidades tratadas
- $\mathbf{1}\{g + e \leq T\}$ assegura que incluímos apenas coortes observadas por pelo menos e períodos pós-tratamento

Esta especificação garante comparabilidade entre períodos, ponderando adequadamente a contribuição de cada coorte conforme sua representatividade na amostra.

5.3 Implementação Computacional

5.3.1 Software e Pacotes Utilizados

A implementação empírica foi realizada utilizando o software R ([R CORE TEAM, 2024](#)) em conjunto com o pacote `did` (versão 2.1.2), desenvolvido pelos próprios Callaway e Sant’Anna. Este pacote implementa eficientemente os estimadores propostos, incluindo:

- Cálculo dos $ATT(g, t)$ com inferência via bootstrap
- Agregações flexíveis (overall, dynamic, group, calendar)
- Diagnósticos de balanço e testes de especificação
- Tratamento adequado de dados desbalanceados

Complementarmente, utilizamos os pacotes `dplyr` para manipulação de dados, `ggplot2` para visualizações, e `purrr` para programação funcional, garantindo reprodutibilidade através do sistema `renv` de gerenciamento de dependências.

5.3.2 Estrutura dos Dados e Tratamento de Missings

O conjunto de dados final consiste em um painel balanceado de 394 microrregiões produtoras de cana-de-açúcar observadas anualmente entre 2000 e 2021, totalizando 5.938 observações. Essas microrregiões foram identificadas através da seguinte metodologia:

- **Fonte de dados:** Produção Agrícola Municipal (PAM) do IBGE, tabela `br_ibge_pam.lavoura_temporaria`
- **Critério de seleção:** Microrregiões com área plantada e colhida de cana-de-açúcar positiva em pelo menos um ano do período
- **Agregação:** Dados municipais agregados ao nível de microrregião usando os códigos oficiais do IBGE

É importante notar que o Brasil possui 558 microrregiões no total, sendo que apenas 394 (71%) apresentaram produção de cana-de-açúcar no período analisado, concentradas principalmente nas regiões Centro-Sul e litoral nordestino.

A escolha da microrregião como unidade de análise oferece vantagens em termos de estabilidade estatística e poder de teste, mas reconhecemos que pode ocultar heterogeneidades importantes ao nível municipal. Estudos futuros poderiam explorar efeitos heterogêneos intra-microrregionais, especialmente em regiões com alta variabilidade climática ou de práticas agrícolas entre municípios.

Algumas considerações sobre o tratamento dos dados merecem destaque:

1. **Valores ausentes:** Observações com dados faltantes de produtividade ou área plantada foram excluídas (menos de 2% da amostra), após verificação de que a ausência ocorria de forma aleatória. Para avaliar o potencial viés dessa exclusão, realizamos um teste de sensibilidade imputando os valores ausentes usando a média móvel de 3 anos da mesma microrregião. Os resultados permaneceram virtualmente inalterados ($ATT = 0,108$ vs. $0,109$ na amostra principal), sugerindo que o impacto dos dados faltantes é negligível.
2. **Coortes pequenas:** Microrregiões que receberam tratamento em anos com poucas unidades tratadas (2016-2018) apresentaram desafios para identificação, levando a alguns $ATT(g,t)$ não estimáveis.
3. **Clustering:** Os erros-padrão são clusterizados ao nível da microrregião, controlando para correlação serial dentro das unidades ao longo do tempo.

5.4 Resultados Principais

5.4.1 Efeito Médio do Tratamento

A estimação do efeito médio do tratamento sobre os tratados (ATT) via estimador doubly robust revela um impacto positivo e estatisticamente significativo da instalação de estações meteorológicas sobre a produtividade da cana-de-açúcar:


$$ATT = 0,1086 \text{ (EP} = 0,0246, z = 4,41, p < 0,001, \text{IC 95\%: [0,0604; 0,1569])}$$

Este resultado indica que as microrregiões que receberam estações meteorológicas experimentaram, em média, um aumento de aproximadamente **10,9%** na produtividade da cana-de-açúcar em relação ao contrafactual de não receber a estação. A magnitude do efeito é economicamente relevante, considerando que o aumento médio anual de produtividade no setor é historicamente inferior a 2%.

5.4.2 Análise de Event Study e Dinâmica Temporal

A análise de event study fornece insights cruciais sobre a evolução temporal dos efeitos do tratamento. A Figura 1 apresenta as estimativas pontuais e intervalos de confiança para períodos relativos ao início do tratamento.

Figura 1 – Event Study - Dinâmica Temporal dos Efeitos da Instalação de Estações Meteorológicas



Nota: A figura apresenta as estimativas pontuais (linha azul) e intervalos de confiança de 95% (área sombreada) dos efeitos do tratamento em função do tempo relativo à instalação da estação. O período $t=0$ marca o ano de instalação. A linha vermelha tracejada indica efeito zero, e a linha cinza vertical marca o início do tratamento.

5.4.2.1 Período Pré-Tratamento: Validação das Tendências Paralelas

A análise dos períodos anteriores ao tratamento ($t < 0$) é fundamental para validar o pressuposto de identificação. Os resultados mostram:

- **Média próxima a zero:** Os efeitos pré-tratamento apresentam média de 0,011 (DP = 0,124), não distinguível estatisticamente de zero (teste t: $p = 0,547$).

- **Ausência de tendência sistemática:** Não se observa padrão crescente ou decrescente nos períodos que antecedem o tratamento.
- **Variabilidade aleatória:** Embora dois períodos específicos ($e=-15$ e $e=-7$) apresentem significância pontual, isso é consistente com flutuações aleatórias esperadas em múltiplas comparações.

Estes resultados fornecem suporte empírico robusto para o pressuposto de tendências paralelas condicionais, fundamental para a interpretação causal dos efeitos estimados.

5.4.2.2 Dinâmica Pós-Tratamento: Difusão Gradual dos Benefícios

O padrão temporal dos efeitos pós-tratamento revela insights importantes sobre o mecanismo de transmissão:

Fase de Adaptação ($e = 0$ a 2):

- Efeito inicial positivo mas impreciso ($ATT_0 = 0,173$, IC: $[-0,042; 0,389]$)
- Alta variabilidade sugerindo heterogeneidade na velocidade de adoção
- Consistente com período de aprendizado e ajuste de práticas agrícolas

Fase de Consolidação ($e = 3$ a 5):

- Crescimento monotônico dos efeitos: $12,0\% \rightarrow 18,0\% \rightarrow 20,1\%$
- Redução progressiva da incerteza (intervalos de confiança mais estreitos)
- Significância estatística robusta a partir do quarto ano

Este padrão é consistente com um processo de difusão tecnológica onde:

1. A informação meteorológica precisa ser interpretada e integrada às decisões de plantio
2. Os agricultores aprendem gradualmente a otimizar o uso das informações
3. Efeitos de rede emergem conforme mais produtores adotam melhores práticas

5.5 Testes de Robustez e Diagnósticos

Para garantir a confiabilidade dos resultados, implementamos uma bateria abrangente de testes de robustez e diagnósticos, seguindo as melhores práticas da literatura econométrica recente.

5.5.1 Análise de Pesos e Composição do ATT

Um aspecto crucial em designs de adoção escalonada é entender como diferentes coortes contribuem para o efeito agregado. Nossa análise revela:

- **Distribuição equilibrada:** A correlação entre os pesos implícitos e o número de períodos pós-tratamento é próxima de zero, indicando que o ATT não é dominado por coortes específicas.
- **Representatividade:** Nenhuma coorte individual contribui com mais de 15% do peso total, sugerindo boa representatividade do efeito estimado.

5.5.2 Comparação de Grupos de Controle

Testamos a sensibilidade dos resultados à escolha do grupo de controle:

Tabela 1 – Comparação de Estimativas por Grupo de Controle

Grupo de Controle	ATT	Erro Padrão	IC 95%
Not-yet-treated	0,1086	0,0246	[0,0604; 0,1569]
Never-treated	0,1086	0,0249	[0,0599; 0,1573]

A estabilidade das estimativas entre diferentes grupos de controle (diferença < 0,1%) reforça a robustez da identificação e sugere ausência de viés de seleção diferencial entre grupos.

5.5.3 Testes Placebo

Implementamos dois tipos de testes placebo para validar a estratégia de identificação:

Placebo Temporal Fixo (2015):

- $ATT = -0,0237$ (EP = 0,0339, $p = 0,485$)
- Resultado não significativo confirma ausência de efeitos espúrios pré-tratamento

Placebo Aleatório (50 simulações):

- Distribuição empírica centrada em zero
- P-valor empírico < 0,01 para o ATT verdadeiro
- 95% dos placebos no intervalo [-0,070; 0,067]

O ATT estimado (0,1086) está claramente na cauda superior da distribuição placebo, fornecendo forte evidência contra a hipótese de efeito espúrio.

5.5.4 Especificações Alternativas

Testamos a robustez dos resultados a diferentes métodos de estimação:

Tabela 2 – Comparação de Métodos de Estimação

Método	ATT	Erro Padrão	P-valor
Doubly Robust (DR)	0,1086	0,0246	<0,001
IPW	0,1084	0,0247	<0,001
Regression	0,1288	0,0316	<0,001

A consistência das estimativas entre métodos (variação máxima de 18,6% para o método de regressão) indica que os resultados não dependem criticamente das escolhas de modelagem.

5.6 Discussão e Interpretação Econômica

5.6.1 Magnitude e Relevância Econômica

O efeito estimado de 10,9% de aumento na produtividade representa um ganho econômico substancial. Para contextualizar:

- **Comparação setorial:** O crescimento médio anual da produtividade da cana no Brasil é de aproximadamente 1,5% ao ano. O efeito das estações equivale a cerca de 7 anos de progresso tecnológico típico.
- **Valor monetário:** Considerando a produção média por microrregião produtora tratada (aproximadamente 500 mil toneladas/ano) e o preço médio da cana (R\$ 130,56/tonelada, referência agosto/2025), o ganho anual por microrregião é estimado em R\$ 7,1 milhões.
- **Custo-benefício:** Considerando o investimento governamental de R\$ 49 milhões para 220 estações ([MINISTÉRIO DA AGRICULTURA E PECUÁRIA, 2025](#)) (aproximadamente R\$ 223 mil por estação profissional), o cálculo *back-of-the-envelope* sugere retornos extremamente favoráveis. Como comparação ilustrativa, existem propostas de estações de baixo custo usando Arduino (cerca de R\$ 250) ([AUTOR, 2021](#)), embora estas não sejam equivalentes às estações meteorológicas profissionais em termos de precisão e confiabilidade.

5.6.2 Mecanismos Subjacentes

Os padrões temporais observados sugerem múltiplos canais através dos quais as informações meteorológicas afetam a produtividade:

1. **Otimização do calendário agrícola:** Melhor timing de plantio e colheita baseado em previsões precisas. Estudos no Nordeste brasileiro demonstram como mudanças climáticas afetam o potencial produtivo da cana-de-açúcar, ressaltando a importância de informações meteorológicas precisas para adaptação (CARVALHO et al., 2019).
2. **Gestão hídrica eficiente:** Ajuste de irrigação conforme condições climáticas reais. Modelos agrometeorológicos específicos para cana-de-açúcar no Brasil demonstram a importância crítica da gestão hídrica baseada em dados meteorológicos precisos (MONTEIRO; SENTELHAS, 2017; MARIN et al., 2016).
3. **Redução de perdas:** Antecipação a eventos extremos permite medidas preventivas. Aplicações operacionais de modelos de simulação de cana-de-açúcar no Brasil demonstram como informações meteorológicas precisas podem otimizar decisões de irrigação e reduzir perdas (VIANNA; SENTELHAS, 2020).
4. **Difusão de conhecimento:** Compartilhamento de informações entre produtores amplifica benefícios através de redes sociais e efeitos de aprendizado entre vizinhos.

5.6.3 Limitações e Pesquisa Futura

Embora os resultados sejam robustos, algumas limitações merecem consideração:

- **Heterogeneidade não observada:** Efeitos podem variar por tamanho de propriedade, nível educacional dos produtores, ou acesso a crédito
- **Externalidades espaciais:** Benefícios podem transbordar para microrregiões vizinhas não capturadas
- **Complementaridades:** Interação com outras tecnologias (GPS, drones) não modelada explicitamente

Pesquisas futuras poderiam explorar estas dimensões utilizando dados mais granulares e designs de identificação complementares.

5.7 Síntese e Conclusões da Análise Empírica

Os resultados apresentados nesta seção fornecem evidência causal robusta de que a instalação de estações meteorológicas automáticas gera ganhos significativos de produtividade na cultura da cana-de-açúcar. A magnitude do efeito (10,9%), sua persistência e crescimento ao longo do tempo, e a robustez a diferentes especificações e testes de falsificação estabelecem uma relação causal convincente.

A análise revela que o impacto das estações meteorológicas vai além de um simples choque tecnológico único. O padrão dinâmico observado sugere um processo de aprendizado e adaptação, onde os benefícios se acumulam à medida que os produtores desenvolvem capacidades para interpretar e utilizar as informações climáticas em suas decisões produtivas.

Do ponto de vista de política pública, os resultados indicam que investimentos em infraestrutura de monitoramento meteorológico representam uma estratégia custo-efetiva para aumentar a produtividade agrícola. Com retornos que superam amplamente os custos de implementação, a expansão da rede de estações pode contribuir significativamente para o desenvolvimento sustentável do setor agrícola brasileiro, especialmente em um contexto de crescente variabilidade climática.

6 Conclusões Finais

Este trabalho investigou o impacto causal da instalação de estações meteorológicas sobre a produtividade agrícola, contribuindo para a literatura empírica sobre o papel da informação na eficiência produtiva. Utilizando métodos econométricos de fronteira adequados para contextos de adoção escalonada, demonstramos que o acesso a informações meteorológicas precisas e localizadas gera ganhos substanciais de produtividade.

Os resultados têm implicações diretas para o desenho de políticas públicas voltadas ao desenvolvimento agrícola. Em um cenário de mudanças climáticas e pressão crescente sobre os recursos naturais, investimentos em sistemas de informação agrometeorológica emergem como instrumentos fundamentais para aumentar a resiliência e eficiência do setor agrícola.

Ao quantificar rigorosamente os benefícios econômicos da infraestrutura meteorológica, este estudo fornece subsídios para a tomada de decisão sobre alocação de recursos públicos e privados. A evidência apresentada sugere que a expansão da rede de estações meteorológicas deveria ser priorizada como estratégia de desenvolvimento sustentável, com potencial para gerar retornos econômicos significativos e contribuir para a segurança alimentar nacional.

Referências

ASSAD, E. D. et al. Impactos e vulnerabilidades da agricultura brasileira às mudanças climáticas. *Revista Brasileira de Climatologia*, v. 30, p. 355–378, 2022. Citado na página 13.

AUTOR, N. Micro estação meteorológica de baixo custo utilizando a plataforma de prototipagem arduino. In: *CONTECC 2021*. CONFEA, 2021. Disponível em: <<https://www.confea.org.br/midias/uploads-imce/Contecc2021/Agronomia/>>. Citado na página 30.

BURKE, M. et al. Using satellite imagery to understand and promote sustainable development. *Science*, v. 371, n. 6535, p. eabe8628, 2021. Citado na página 13.

CALLAWAY, B.; SANT'ANNA, P. H. C. Difference-in-differences with multiple time periods. *Journal of Econometrics*, v. 225, n. 2, p. 200–230, 2021. Citado 7 vezes nas páginas 13, 15, 16, 18, 19, 21 e 22.

CARVALHO, A. L. et al. Impact of climate changes on potential sugarcane yield in pernambuco, northeastern region of brazil. *Renewable Energy*, v. 78, p. 26–34, 2019. Citado na página 31.

COSTA, L. C. et al. Potential forcing of co₂, technology and climate changes in maize (*zea mays*) and bean (*phaseolus vulgaris*) yield in southeast brazil. *Environmental Research Letters*, v. 16, n. 1, p. 014013, 2021. Citado na página 13.

CROST, B. et al. Climate change, agricultural production and civil conflict: Evidence from the philippines. *Journal of Environmental Economics and Management*, v. 88, p. 379–395, 2022. Citado na página 14.

GATTI, N.; BAYLIS, K.; CROST, B. Can irrigation infrastructure mitigate the effect of rainfall shocks on conflict? evidence from indonesia. *American Journal of Agricultural Economics*, v. 105, n. 4, p. 1149–1176, 2023. Citado na página 14.

GOODMAN-BACON, A. Difference-in-differences with variation in treatment timing. *Journal of Econometrics*, v. 225, n. 2, p. 254–277, 2021. Citado na página 13.

MARIN, F. R. et al. Sugarcane model intercomparison: Structural differences and uncertainties under current and potential future climates. *Environmental Modelling & Software*, v. 72, p. 372–386, 2016. Citado na página 31.

MAVI, H. S.; TUPPER, G. J. *Agrometeorology: principles and application of climate studies in agriculture*. New York: Food Products Press, 2004. Citado 2 vezes nas páginas 12 e 16.

MINISTÉRIO DA AGRICULTURA E PECUÁRIA. *Ministro Carlos Fávaro assina acordo que garante instalação de 220 novas estações meteorológicas no país*. 2025. Acesso em: janeiro 2025. Disponível em: <<https://www.gov.br/agricultura/pt-br/assuntos/noticias/ministro-carlos-favaro-assina-acordo-que-garante-instalacao-de-220-novas-estacoes-meteorologicas-no->>. Citado na página 30.

- MONTEIRO, J. E. B. A. *Agrometeorologia dos cultivos: o fator meteorológico na produção agrícola*. Brasília, DF: INMET, 2009. 530 p. ISBN 978-85-62817-00-7. Citado 2 vezes nas páginas 12 e 16.
- MONTEIRO, L. A.; SENTELHAS, P. C. Sugarcane yield gap: can it be determined at national level with a simple agrometeorological model? *Crop and Pasture Science*, v. 68, n. 3, p. 272–284, 2017. Citado na página 31.
- ORTIZ-BOBEA, A.; KNIPPENBERG, E.; CHAMBERS, R. G. Climate change and agricultural productivity. *Annual Review of Resource Economics*, v. 15, p. 317–337, 2023. Citado na página 13.
- PEREIRA, A. R.; ANGELOCCI, L. R.; SENTELHAS, P. C. *Agrometeorologia: fundamentos e aplicações práticas*. Guaíba: Agropecuária, 2002. Citado na página 12.
- R CORE TEAM. *R: A language and environment for statistical computing*. Vienna, Austria, 2024. Disponível em: <<https://www.R-project.org/>>. Citado na página 25.
- RIJKS, D.; BARADAS, M. W. The clients for agrometeorological information. *Agricultural and Forest Meteorology*, v. 103, n. 1-2, p. 27–42, 2000. Citado 2 vezes nas páginas 12 e 16.
- SANT’ANNA, P. H. C.; ZHAO, J. Doubly robust difference-in-differences estimators. *Journal of Econometrics*, v. 219, n. 1, p. 101–122, 2020. Citado na página 24.
- SUN, L.; ABRAHAM, S. Estimating dynamic treatment effects in event studies with heterogeneous treatment effects. *Journal of Econometrics*, v. 225, n. 2, p. 175–199, 2021. Citado na página 13.
- VIANNA, M. S.; SENTELHAS, P. C. Performance of dssat csm-canegro under operational conditions and its use in determining the ‘saving irrigation’ impact on sugarcane crop. *Sugar Tech*, v. 18, p. 75–86, 2020. Citado na página 31.
- WEISS, A.; VAN CROWDER, L.; BERNARDI, M. Communicating agrometeorological information to farming communities. *Agricultural and Forest Meteorology*, v. 103, p. 185–196, 2000. Citado 2 vezes nas páginas 13 e 16.

Apêndices

APÊNDICE A – Código do GitHub

O código completo utilizado nesta pesquisa, incluindo os scripts de coleta de dados, análise econométrica e geração de visualizações, está disponível no repositório GitHub:

[<https://github.com/danielcavalli/tcc-ie-ufrj-2024>](https://github.com/danielcavalli/tcc-ie-ufrj-2024)

O repositório contém:

- Scripts SQL para extração de dados do BigQuery
- Código Python para processamento e limpeza dos dados
- Scripts R para implementação do modelo de Callaway e Sant’Anna
- Documentação detalhada dos procedimentos metodológicos
- Instruções para reprodução dos resultados

Anexos

ANEXO A – Estatísticas Descritivas Complementares

Este anexo apresenta estatísticas descritivas complementares que apoiam a análise principal.

A.1 Distribuição Temporal do Tratamento

Tabela 3 – Número de microrregiões tratadas por ano

Ano	Novas Estações	Total Acumulado
2008	4	4
2009	25	29
2010	26	55
2011	17	72
2012	15	87
2013	21	108
2014	11	119
2015	6	125
2016	3	128
2017	1	129
2018	2	131

A.2 Estatísticas por Região

Tabela 4 – Distribuição do tratamento por região

Região	Microrregiões	Tratadas	% Tratadas
Norte	15	8	53,3%
Nordeste	142	45	31,7%
Centro-Oeste	51	22	43,1%
Sudeste	160	48	30,0%
Sul	26	8	30,8%
Total	394	131	33,2%

Tabela 5 – Produtividade média (ton/ha) por período

Período	Nunca Tratadas	Ainda Não Tratadas	Já Tratadas	Diferença
2000-2007	71,2	72,8	73,5	0,7
2008-2014	72,5	74,3	78,9	4,6
2015-2021	74,1	75,2	83,7	8,5

A.3 Produtividade Média por Status de Tratamento

A.4 Teste de Balanceamento de Covariadas

Tabela 6 – Teste de diferenças pré-tratamento

Variável	Tratadas	Controle	p-valor
Produtividade 2000-2007 (ton/ha)	73,5	71,2	0,142
Área plantada (mil ha)	42,3	38,7	0,285
PIB per capita (R\$ mil)	18,4	17,9	0,621
População rural (%)	24,3	25,1	0,753

A.5 Análise de Sensibilidade - Dados Faltantes

Como mencionado no texto principal, realizamos uma análise de sensibilidade imputando os valores ausentes (menos de 2% da amostra) usando médias móveis de 3 anos:

- ATT com dados originais: 0,109 (erro-padrão: 0,041)
- ATT com imputação: 0,108 (erro-padrão: 0,040)
- Diferença percentual: 0,9%

Os resultados confirmam que o impacto dos dados faltantes é negligível para nossas estimativas principais.