

Daniel Cavalli

**IMPACTO DE ESTAÇÕES
METEOROLÓGICAS NA PRODUTIVIDADE
AGRÍCOLA: UMA APLICAÇÃO DE
DIFERENÇAS EM DIFERENÇAS COM
TRATAMENTO ESCALONADO**

Rio de Janeiro

Dezembro 2025

Daniel Cavalli

IMPACTO DE ESTAÇÕES METEOROLÓGICAS NA PRODUTIVIDADE AGRÍCOLA: UMA APLICAÇÃO DE DIFERENÇAS EM DIFERENÇAS COM TRATAMENTO ESCALONADO

Monografia apresentada ao Instituto de Economia da Universidade Federal do Rio de Janeiro como parte dos requisitos necessários à obtenção do título de Bacharel em Ciências Econômicas.

UNIVERSIDADE FEDERAL DO RIO DE JANEIRO
INSTITUTO DE ECONOMIA
CURSO DE GRADUAÇÃO EM CIÊNCIAS ECONÔMICAS

Orientador: Prof. Romero Rocha

Rio de Janeiro
Dezembro 2025

Daniel Cavalli

IMPACTO DE ESTAÇÕES METEOROLÓGICAS NA PRODUTIVIDADE AGRÍCOLA: UMA APLICAÇÃO DE DIFERENÇAS EM DIFERENÇAS COM TRATAMENTO ESCALONADO

Monografia apresentada ao Instituto de Economia da Universidade Federal do Rio de Janeiro como parte dos requisitos necessários à obtenção do título de Bacharel em Ciências Econômicas.

Trabalho aprovado. Rio de Janeiro, 9 de setembro de 2025:

Prof. Romero Rocha
Orientador

Professor
Convidado 1

Professor
Convidado 2

Rio de Janeiro
Dezembro 2025

Agradecimentos

Agradeço à minha família, que sempre me apoiou durante toda a graduação sem nunca me pressionar além do necessário. Vocês foram fundamentais para que eu pudesse acumular o conhecimento necessário para montar este trabalho.

À minha namorada, Juliana, obrigado por me incentivar a terminar a faculdade e o TCC quando eu já não tinha mais vontade ou razão para tal. Seu apoio fez toda a diferença em me convencer da importância disso.

À minha cachorra, Moana, companheira fiel de tantas horas de escrita, modelagem e análise de dados. Sua presença tornou as longas madrugadas de trabalho muito mais suportáveis.

À Cláudia.

*“In mathematics you don’t understand things.
You just get used to them.”*
(John von Neumann)

Resumo

Este estudo examina o impacto causal da instalação de estações meteorológicas automáticas sobre o Produto Interno Bruto (PIB) agropecuário no Brasil, utilizando dados em painel de 490 microrregiões produtoras de cana-de-açúcar entre 2003 e 2023. Empregamos o arcabouço de Diferenças em Diferenças com adoção escalonada proposto por Callaway e Sant'Anna (2021), demonstrando sua superioridade sobre métodos tradicionais em contextos de tratamento sequencial. A estratégia de identificação explora a variação temporal e geográfica na instalação de estações entre microrregiões eventualmente tratadas, utilizando o método "not-yet-treated" como grupo de controle dinâmico. Os resultados principais, obtidos através do estimador doubly robust, indicam um Efeito Médio do Tratamento sobre os Tratados (ATT) de 8.2% (IC 95%: [1,9%; 14,5%], $p = 0,0103$), representando ganhos econômicos significativos no setor agropecuário. A análise de event study revela ausência de tendências pré-tratamento diferenciadas, validando a estratégia de identificação. Testes extensivos de robustez confirmam a validade causal: placebos com PIB não-agropecuário (ATT não significativo), randomização múltipla (p -valor empírico $< 0,01$), múltiplas especificações alternativas (IPW: 9,4%, REG: 6,6%), e estabilidade temporal. Além dos resultados substantivos sobre produtividade agrícola, este trabalho estabelece um modelo metodológico rigoroso para avaliação de políticas públicas com implementação gradual, oferecendo um guia prático para aplicações do arcabouço de Callaway e Sant'Anna. A disponibilização completa do código e documentação reforça o compromisso com transparência e reprodutibilidade na pesquisa econométrica aplicada.

Palavras-chave: estações meteorológicas. produtividade agrícola. PIB agropecuário. diferenças em diferenças escalonada. Callaway e Sant'Anna. informação climática. avaliação de políticas públicas.

Abstract

This study examines the causal impact of automatic weather station installation on agricultural GDP in Brazil, using panel data from 490 sugarcane-producing microregions between 2003 and 2023. We employ the staggered adoption Differences-in-Differences framework proposed by Callaway and Sant'Anna (2021), demonstrating its superiority over traditional methods in sequential treatment contexts. The identification strategy exploits temporal and geographic variation in station installation among eventually treated microregions, using the "not-yet-treated" method as a dynamic control group. The main results, obtained through the doubly robust estimator, indicate an average treatment effect (ATT) of 8.2% (95% CI: [1.9%; 14.5%], $p = 0.0103$), representing economically significant gains in agricultural GDP. The event study analysis reveals absence of differential pre-treatment trends, validating the identification strategy. Extensive robustness tests confirm causal validity: non-agricultural GDP placebos (non-significant ATT), multiple randomization (empirical p -value < 0.01), alternative specifications (IPW: 9.4%, REG: 6.6%), and temporal stability analysis. Beyond substantive findings on agricultural productivity, this work establishes a rigorous methodological template for evaluating public policies with gradual implementation, offering a practical guide for applications of the Callaway and Sant'Anna framework. Complete code and documentation availability reinforces commitment to transparency and reproducibility in applied econometric research.

Keywords: weather stations. agricultural productivity. agricultural GDP. staggered differences-in-differences. Callaway and Sant'Anna. climate information. policy evaluation. Brazil.

Lista de ilustrações

Figura 1 – Estudo de Evento - Dinâmica Temporal dos Efeitos da Instalação de Estações Meteorológicas	29
Figura 2 – Tendências Paralelas - PIB Agropecuário Normalizado (2003-2023) . .	31
Figura 3 – Composição Dinâmica do Efeito do Tratamento	32
Figura 4 – Distribuição dos ATTs Placebo vs. ATT Verdadeiro	36
Figura 5 – Análise de Robustez - Comparação de Especificações	39
Figura 6 – Análise de Poder Estatístico por Tamanho de Efeito	42
Figura 7 – Distribuição Temporal da Instalação de Estações Meteorológicas	51
Figura 8 – Tendências do PIB Agropecuário por Quartil de Área Plantada	53
Figura 9 – Evolução Temporal do PIB Agropecuário vs PIB Não-Agropecuário . .	54
Figura 10 – Matriz de Correlação das Variáveis Principais	55

Lista de tabelas

Tabela 1 – Resultados Principais e Testes Placebo	29
Tabela 2 – Comparação de Estimativas por Grupo de Controle	31
Tabela 3 – Resultados do Teste de Randomização de Monte Carlo	35
Tabela 4 – Análise de Sensibilidade ao Período de Análise	38
Tabela 5 – Comparação de Métodos de Estimação	39
Tabela 6 – Número de microrregiões tratadas por ano	52
Tabela 7 – Distribuição do tratamento por região	52
Tabela 8 – Produtividade média (ton/ha) por período	53

Sumário

1	INTRODUÇÃO	12
2	METODOLOGIA	15
2.1	Introdução ao Modelo	15
2.2	Fundamentos do modelo	15
2.2.1	Group-Time Average Treatment Effects ATT(g,t)	16
2.2.2	Identificação	16
2.2.2.1	Validade dos Pressupostos no Contexto de Estações Meteorológicas	17
2.2.3	Estimação	17
2.2.4	Agregação de Efeitos	18
2.2.4.1	Agregação Simples com Pesos Positivos	18
2.2.4.2	Efeito Médio do Tratamento sobre os Tratados (Recomendado)	18
2.2.4.3	Agregações para Event Studies	19
2.3	Especificação do Modelo	19
2.3.1	Definição do Tratamento e Unidades de Análise	19
2.3.2	Construção dos Grupos de Tratamento	20
2.3.3	Variável Dependente e Transformações	20
2.3.4	Covariáveis e Especificação do Modelo	21
2.3.5	O Estimador Duplamente Robusto	22
2.3.6	Escolha do Grupo de Controle	22
2.4	Especificação da Análise de Estudo de Evento	23
2.4.1	Formalização da Análise de Estudo de Evento	23
3	RESULTADOS	25
3.1	Implementação Computacional	25
3.1.1	Software e Pacotes Utilizados	25
3.1.2	Transparência e Reprodutibilidade	25
3.1.3	Estrutura dos Dados e Processo de Extração	26
3.1.3.1	Fontes de Dados e Extração	26
3.1.3.2	Critérios de Qualidade e Filtros	27
3.1.3.3	Construção das Variáveis de Tratamento	27
3.1.3.4	Tratamento de Dados Faltantes e Qualidade	27
3.2	Resultados Principais	28
3.2.1	Efeito Médio do Tratamento	28
3.2.2	Análise de Estudo de Evento e Dinâmica Temporal	28
3.2.2.1	Período Pré-Tratamento: Validação das Tendências Paralelas	29

3.2.2.2	Dinâmica Pós-Tratamento: Difusão Gradual dos Benefícios	30
3.2.2.3	Análise Detalhada de Tendências Paralelas	30
3.3	Testes de Robustez e Diagnósticos	31
3.3.1	Sensibilidade ao Grupo de Controle	31
3.3.2	Análise da Composição Dinâmica dos Efeitos	32
3.3.3	Testes Placebo	33
3.3.3.1	Teste Placebo com Atribuição Aleatória Fixa	33
3.3.3.2	Teste de Randomização de Monte Carlo	33
3.3.3.2.1	Formalização do Teste	33
3.3.3.2.2	Aspectos Computacionais	35
3.3.3.2.3	Implementação e Resultados	35
3.3.3.2.4	Interpretação dos Resultados	36
3.3.3.3	Teste Placebo com PIB Não-Agropecuário	36
3.3.3.4	Síntese dos Testes Placebo	37
3.4	Análises de Robustez Adicionais	37
3.4.1	Sensibilidade ao Período de Análise	38
3.4.2	Robustez a Diferentes Métodos de Estimação	38
3.4.3	Síntese das Análises de Robustez	39
3.5	Discussão e Interpretação Econômica	40
3.5.1	Contextualização da Magnitude do Efeito	40
3.5.2	Mecanismos Subjacentes	41
3.5.3	Análise de Poder Estatístico	42
3.5.4	Procedimentos de Inferência	42
3.5.5	Limitações e Pesquisa Futura	43
3.5.5.1	Desbalanceamento de Covariáveis	43
3.5.5.2	Composição dos Pesos no Estimador Agregado	43
3.5.5.3	Outras Limitações Importantes	44
3.5.5.4	Direções para Pesquisa Futura	44
3.6	Síntese dos Resultados Empíricos	45
4	CONCLUSÕES FINAIS	46
	REFERÊNCIAS	47
	APÊNDICES	49
	APÊNDICE A – CÓDIGO DO GITHUB	50

	APÊNDICE B – ESTATÍSTICAS DESCRITIVAS COMPLEMEN-	
	TARES	51
B.1	Distribuição Temporal do Tratamento	51
B.2	Estatísticas por Região	52
B.3	Produtividade Média por Status de Tratamento	52
B.4	Tendências por Quartil de Área Plantada	52
B.5	Análises Descritivas Complementares	53

1 Introdução

A agricultura brasileira enfrenta o desafio permanente de aumentar a produtividade em um contexto de crescente variabilidade climática. Com a produção agrícola global sendo amplamente determinada por oscilações meteorológicas durante o ciclo produtivo (MONTEIRO, 2009), e as mudanças climáticas já impactando significativamente a produtividade mundial (ORTIZ-BOBEA et al., 2020), a questão central não é mais *se* o clima afeta a agricultura, mas *como* mitigar seus efeitos adversos e aproveitar janelas de oportunidade. Neste contexto, a informação meteorológica precisa emerge como insumo produtivo crítico, potencialmente capaz de transformar incerteza em risco gerenciável.

A literatura documenta extensivamente os canais através dos quais informações meteorológicas podem aumentar a produtividade agrícola. MAVI e TUPPER (2004) identificam três dimensões principais: planejamento estratégico (escolha de culturas e épocas de plantio), decisões táticas (timing de irrigação, aplicação de defensivos) e construção de resiliência sistêmica. WEISS, VAN CROWDER e BERNARDI (2000) demonstram que estações meteorológicas locais permitem ajustes finos nas práticas agrícolas, enquanto RIJKS e BARADAS (2000) quantificam os ganhos econômicos potenciais de serviços meteorológicos bem estruturados. No Brasil, sistemas como AGRITEMPO e SISDAGRO já operacionalizam essas informações, mas sua efetividade depende crucialmente da densidade e qualidade da rede de estações meteorológicas subjacente.

O mecanismo causal pode ser descrito de forma sequencial: a instalação de uma estação meteorológica local gera dados climáticos precisos e em tempo real, que são processados e disponibilizados aos produtores através de boletins, alertas e sistemas de informação. Com acesso a previsões mais acuradas sobre temperatura, precipitação e eventos extremos, os agricultores podem otimizar decisões críticas – desde o momento ideal de plantio e colheita até a aplicação precisa de insumos e gestão eficiente de irrigação.

Além do uso direto pelos produtores, esses dados alimentam modelos computacionais avançados de simulação agrícola. Por exemplo, o modelo DSSAT CSM-CANEGRO, amplamente utilizado no setor sucroalcooleiro, integra informações meteorológicas locais para simular o crescimento e desenvolvimento da cana-de-açúcar sob diferentes cenários de manejo. Com dados meteorológicos precisos, o modelo permite aos agricultores testar virtualmente diferentes estratégias de irrigação, identificando configurações ótimas que podem resultar em incrementos de produtividade de até 30%, especialmente em solos mais vulneráveis ao déficit hídrico (VIANNA; SENTELHAS, 2016). Essa capacidade de simular e otimizar decisões antes da implementação no campo representa um salto qualitativo na gestão agrícola.

Essas decisões melhor informadas – seja através do uso direto das previsões ou

através de modelos de simulação alimentados por dados locais – traduzem-se em redução de perdas, aumento de produtividade e, conseqüentemente, crescimento do PIB agropecuário local.

Apesar do consenso teórico sobre a importância da informação meteorológica, existe uma lacuna crítica na literatura: **a ausência de evidências causais robustas sobre o impacto econômico da expansão da infraestrutura de monitoramento climático.** Estudos existentes são predominantemente descritivos ou baseados em correlações, deixando em aberto questões fundamentais: Qual é o retorno econômico da instalação de estações meteorológicas? Como esse impacto evolui ao longo do tempo? Os benefícios justificam os custos de expansão da rede?

A dificuldade em responder essas questões não é trivial. A instalação de estações meteorológicas no Brasil ocorreu de forma escalonada ao longo de duas décadas, com diferentes regiões adotando a tecnologia em momentos distintos. Este padrão de "adoção escalonada" (staggered adoption) invalida o uso de métodos econométricos tradicionais. Como demonstrado por GOODMAN-BACON (2021) e SUN e ABRAHAM (2021), o estimador de Diferenças em Diferenças com Efeitos Fixos Bidimensionais (Two-Way Fixed Effects - TWFE) – padrão ouro em avaliações de impacto – produz resultados enviesados neste contexto, pois inadvertidamente usa unidades já tratadas como controles e confunde efeitos heterogêneos ao longo do tempo.

Este trabalho preenche essa lacuna ao estimar o **efeito causal da instalação de estações meteorológicas sobre o PIB agropecuário**, utilizando o arcabouço metodológico de CALLAWAY e SANT'ANNA (2021) para Diferenças em Diferenças com múltiplos períodos. É importante esclarecer que, embora utilizemos a produção de cana-de-açúcar como critério de seleção das microrregiões – dada sua relevância econômica e alta sensibilidade climática – nossa variável de resultado é o PIB agropecuário total, capturando assim os efeitos agregados sobre toda a produção agrícola local.

Nossa análise revela que a instalação de estações meteorológicas gera um aumento de **8.2% no PIB agropecuário** das microrregiões tratadas. Estes resultados são robustos a múltiplas especificações, testes placebo e análises de sensibilidade, fornecendo evidência causal rigorosa sobre a efetividade desta política.

As contribuições deste trabalho são quádruplas:

1. **Evidência causal pioneira:** Primeira quantificação rigorosa do impacto econômico de estações meteorológicas na agricultura brasileira, preenchendo uma lacuna crítica para políticas públicas baseadas em evidências.
2. **Avanço metodológico:** Demonstração da aplicabilidade e importância dos novos métodos de DiD escalonado em contextos agrícolas, contribuindo para a literatura

metodológica aplicada.

3. **Caracterização da dinâmica temporal:** Documentação do processo de difusão e aprendizado, com implicações para avaliação de investimentos em infraestrutura meteorológica.
4. **Subsídios para expansão da rede:** Evidências de que o retorno social supera amplamente os custos, justificando a expansão da infraestrutura meteorológica como estratégia de adaptação climática e aumento de produtividade.

Nossos resultados dialogam com desenvolvimentos recentes na literatura. [BURKE et al. \(2021\)](#) argumentam que avanços em tecnologias de informação representam uma das principais fronteiras para aumentar a produtividade agrícola no século XXI. [MONTEIRO e SENTELHAS \(2017\)](#) demonstram a importância de modelos agrometeorológicos para identificação de gaps de produtividade na agricultura brasileira. [CROST et al. \(2018\)](#) e [GATTI, BAYLIS e CROST \(2021\)](#) demonstram, usando métodos similares aos nossos, como infraestrutura pode mitigar impactos climáticos. Este trabalho contribui para essa literatura emergente ao fornecer a primeira evidência causal direta sobre estações meteorológicas.

O restante deste trabalho está organizado da seguinte forma. A Seção 2 apresenta a metodologia completa, incluindo o arcabouço de Diferenças em Diferenças com múltiplos períodos de [CALLAWAY e SANT'ANNA \(2021\)](#), a estratégia empírica, definição do tratamento, variáveis e especificação do modelo. A Seção 3 apresenta os resultados, começando pela implementação computacional e seguindo com os efeitos estimados, análises de robustez e testes de validação. A Seção 4 conclui com implicações para políticas públicas e direções para pesquisa futura.

2 Metodologia

Para este trabalho, utilizaremos como principal referência o artigo de [CALLAWAY e SANT'ANNA \(2021\)](#), que apresenta uma extensão do modelo de Diferenças em Diferenças (DiD) para cenários com múltiplos períodos e momentos distintos de adoção do tratamento.

2.1 Introdução ao Modelo

No DiD clássico, assume-se um grupo tratado que recebe a intervenção em um momento específico e um grupo controle que nunca é tratado. Sob essa configuração, a diferença no tempo entre pré e pós-tratamento e a diferença entre grupos tratado e controle fornecem a estimativa do efeito causal. Entretanto, para o caso analisado neste trabalho há múltiplos períodos e vários grupos recebendo o tratamento em momentos distintos ao longo dos 22 anos do período de análise. A abordagem de DiD tradicional, nesse caso, pode gerar estimativas enviesadas devido à heterogeneidade do tratamento ao longo do tempo, resultando em interpretação ambígua.

O modelo de [CALLAWAY e SANT'ANNA \(2021\)](#) surge como uma forma de permitir que esses cenários de tratamento escalonado, frequentemente mais comuns no mundo real do que experimentos naturais, possam ser avaliados adequadamente. Por permitir a identificação de efeitos médios do tratamento específicos para cada grupo e período, acomoda a heterogeneidade do momento de adoção e suas dinâmicas, além de fornecer uma interpretação mais clara dos parâmetros causais.

2.2 Fundamentos do modelo

O modelo proposto pode ser entendido em três etapas conceituais:

1. **Identificação de parâmetros causais desagregados:** Primeiro, são obtidas estimativas do efeito causal para cada combinação de grupo tratado e período após a adoção (denotados por $ATT(g,t)$), focando em captar o efeito específico para um determinado conjunto de unidades tratadas em um dado momento do tempo.
2. **Agregação desses parâmetros:** Em seguida, esses parâmetros individuais, definidos para grupos e períodos específicos, podem ser combinados para produzir medidas resumidas de efeitos, como efeitos médios globais, ao longo do tempo, por coorte de tratamento ou segundo o tempo decorrido desde a intervenção.

3. **Estimação e inferência:** Por fim, procedimentos estatísticos são empregados para estimar esses parâmetros, bem como inferir sobre sua significância estatística.

2.2.1 Group-Time Average Treatment Effects $ATT(g,t)$

O parâmetro fundamental dessa abordagem é o $ATT(g,t)$, que representa o Efeito Médio do Tratamento para o grupo g no período t . Ao contrário do DiD tradicional, onde há um único efeito estimado, aqui obtemos uma coleção de efeitos, cada um refletindo o impacto do tratamento em um grupo que começou a ser tratado em um determinado momento e está sendo avaliado em um período específico após o início do tratamento.

Com isso é possível capturar heterogeneidades relacionadas:

- Ao grupo (unidades diferentes podem ter características e contextos distintos);
- Ao momento de início do tratamento (tratamentos iniciados em diferentes épocas podem ter efeitos variados devido a condições econômicas, políticas ou sociais);
- Ao tempo decorrido desde o tratamento (efeitos imediatos versus efeitos de longo prazo podem diferir).

2.2.2 Identificação

O artigo de [CALLAWAY e SANT'ANNA \(2021\)](#) apresenta uma série de pressupostos para identificação dos parâmetros causais. Boa parte delas não difere muito dos pressupostos do DiD tradicional. Abaixo destaco algumas importantes mudanças:

1. **Tendências Paralelas Condicionais:** A ideia central do DiD é que, na ausência de tratamento, as unidades tratadas seguiriam a mesma tendência de evolução dos resultados das unidades não tratadas. Existem diferenças conceituais entre o DiD tradicional e o DiD Staggered:
 - **Pressuposto 4 - “never-treated”:** Aqui, o grupo de comparação é formado por unidades que nunca recebem tratamento ao longo de todo o período observado. Pressupõe-se que, condicionalmente a covariáveis observáveis, esses “never-treated” representam a contrafactual apropriada para o que teria acontecido com os grupos tratados caso não tivessem sido tratados.
 - **Pressuposto 5 - “not-yet-treated”:** Nesse caso, o grupo de controle para um determinado período e grupo tratado é formado por unidades que ainda não foram tratadas até aquele momento, mas que virão a ser tratadas no futuro. Essa abordagem aproveita a natureza escalonada do tratamento para criar um grupo de comparação internamente consistente.

2. **Pressuposto 3 - Antecipação Limitada do Tratamento:** Admite-se que as unidades não são afetadas pelo tratamento antes de sua efetiva implementação, ou que se conheçam efeitos de antecipação limitados e controláveis. Caso haja antecipação, o modelo permite incorporar essa informação, desde que os períodos de antecipação sejam conhecidos e adequadamente modelados.
3. **Sobreposição (Overlap):** É necessário que haja sobreposição entre as características das unidades tratadas e as unidades de controle, garantindo que as diferenças observadas possam ser atribuídas ao tratamento e não a dessemelhanças estruturais entre grupos.

2.2.2.1 Validade dos Pressupostos no Contexto de Estações Meteorológicas

É importante verificar como estes pressupostos se aplicam ao nosso contexto específico:

No Anticipation: No caso de estações meteorológicas, este pressuposto é amplamente, mas não perfeitamente, satisfeito. Embora as informações meteorológicas localizadas e precisas só existam após a instalação física da estação, reconhecemos que produtores podem utilizar dados de estações vizinhas, com menor precisão. Se houver algum grau de antecipação, nosso estimador tende a ser conservador, subestimando o verdadeiro impacto da estação, pois parte do efeito seria capturado antes do período oficial de tratamento. Isso fortalece nossas conclusões: se encontramos efeitos significativos mesmo com possível antecipação, o impacto real tende a ser ainda maior.

Tratamento Irreversível: Uma vez instalada, assume-se que a estação permanece operacional. Nossa análise não considera casos de desativação de estações, tratando a adoção como permanente (staggered adoption).

Tendências Paralelas Condicionais: Este é o pressuposto mais crítico e testável. Nossa análise fornece forte evidência empírica através do teste formal ($F = 1,136$, $p = 0,3215$) e da inspeção visual dos períodos pré-tratamento no event study, onde os coeficientes oscilam aleatoriamente em torno de zero sem tendência sistemática.

2.2.3 Estimação

Para estimar o $ATT(g,t)$, são propostas três abordagens principais:

1. **Regressão de Resultado (Outcome Regression - OR):** Modelar-se diretamente o resultado nos grupos de controle, condicionando a covariáveis pré-tratamento. O efeito é então obtido comparando a predição contrafactual com o resultado efetivo observado nas unidades tratadas.

2. **Ponderação por Probabilidade Inversa (Inverse Probability Weighting - IPW):** Aqui, pondera-se cada unidade pela probabilidade condicional de tratamento. Ao ajustar esses pesos, obtém-se um contrafactual equilibrado, simulando um cenário onde o tratamento foi aplicado aleatoriamente.
3. **Duplamente Robusto (Doubly Robust - DR):** Combina OR e IPW, resultando em um estimador robusto a erros de especificação. Mesmo se um dos modelos (resultado ou probabilidade) estiver incorretamente especificado, a consistência pode ser mantida. Na prática, essa abordagem é frequentemente recomendada por oferecer maior segurança em cenários reais, onde a especificação perfeita do modelo é incerta.

2.2.4 Agregação de Efeitos

Após estimar os $ATT(g, t)$ para cada combinação grupo-tempo, [CALLAWAY e SANT'ANNA \(2021\)](#) propõem diferentes esquemas de agregação para obter medidas resumidas do efeito do tratamento. A escolha do esquema de agregação depende da questão de pesquisa específica.

2.2.4.1 Agregação Simples com Pesos Positivos

Uma primeira possibilidade seria simplesmente fazer a média de todos os $ATT(g, t)$ identificados:

$$\theta_W^O = \frac{1}{\kappa} \sum_{g \in \mathcal{G}} \sum_{t=2}^T \mathbf{1}\{t \geq g\} \cdot ATT(g, t) \cdot P(G = g | G \leq T) \quad (2.1)$$

onde $\kappa = \sum_{g \in \mathcal{G}} \sum_{t=2}^T \mathbf{1}\{t \geq g\} \cdot P(G = g | G \leq T)$ garante que os pesos somem um.

Embora θ_W^O evite os problemas de pesos negativos do TWFE tradicional, ele tem a desvantagem de sistematicamente atribuir mais peso a grupos que participam do tratamento por mais tempo.

2.2.4.2 Efeito Médio do Tratamento sobre os Tratados (Recomendado)

Para superar essa limitação, [CALLAWAY e SANT'ANNA \(2021\)](#) recomendam o seguinte parâmetro como medida geral do efeito médio de participar do tratamento:

$$\theta_{sel}^O = \sum_{g \in \mathcal{G}} \theta_{sel}(g) \cdot P(G = g | G \leq T) \quad (2.2)$$

onde $\theta_{sel}(g)$ é o efeito médio de participar do tratamento para unidades no grupo g :

$$\theta_{sel}(g) = \frac{1}{T - g + 1} \sum_{t=g}^T ATT(g, t) \quad (2.3)$$

Este parâmetro primeiro calcula o efeito médio para cada grupo (através de todos os períodos pós-tratamento) e então faz a média desses efeitos entre grupos. Assim, θ_{sel}^O representa o efeito médio de participar do tratamento experimentado por todas as unidades que alguma vez participaram do tratamento. Sua interpretação é análoga ao ATT no DiD canônico com dois períodos e dois grupos.

2.2.4.3 Agregações para Event Studies

Para análises de event study que examinam a dinâmica temporal dos efeitos, utilizamos a agregação balanceada, que evita problemas de mudanças na composição dos grupos ao longo do tempo relativo ao tratamento.

2.3 Especificação do Modelo

Nossa análise baseia-se em um painel de dados escalonado que pode ser formalmente descrito como $\mathcal{D} = \{(Y_{it}, W_{it}, X_{it})\}_{i=1, t=1}^{N, T}$, onde:

- N : número total de unidades (microrregiões) no painel.
- T : número total de períodos de tempo (anos) no painel.
- $i \in \{1, 2, \dots, N\}$: índice que identifica a unidade (microrregião).
- $t \in \{1, 2, \dots, T\}$: índice que identifica o período de tempo (ano).
- Y_{it} : logaritmo do PIB agropecuário da microrregião i no ano t .
- W_{it} : indicador binário de tratamento (1 se a microrregião i possui estação meteorológica ativa no ano t , 0 caso contrário).
- X_{it} : vetor de covariadas da microrregião i no ano t .

A abordagem de [CALLAWAY e SANT'ANNA \(2021\)](#) permite estimar o Efeito Médio do Tratamento sobre os Tratados (ATT) específico para cada coorte g (grupo de unidades tratadas no mesmo período) e tempo t , denotado por $ATT(g, t)$. Estes efeitos podem então ser agregados de diferentes formas para obter estimativas de interesse para políticas públicas.

2.3.1 Definição do Tratamento e Unidades de Análise

O tratamento é definido como a instalação de pelo menos uma estação meteorológica automática em funcionamento na microrregião. A escolha da microrregião como unidade de análise justifica-se por três razões principais:

1. **Escala geográfica apropriada:** As microrregiões representam agrupamentos de municípios com características agroclimáticas similares, permitindo capturar adequadamente a área de influência das informações meteorológicas.
2. **Estabilidade institucional:** Diferentemente dos municípios, que podem sofrer desmembramentos, as microrregiões mantêm fronteiras estáveis ao longo do período analisado.
3. **Poder estatístico:** A agregação em microrregiões produtoras de cana-de-açúcar (490 unidades no total, com 303 apresentando dados pré-tratamento válidos) oferece um equilíbrio entre granularidade espacial e tamanho amostral suficiente para identificação robusta dos efeitos.

2.3.2 Construção dos Grupos de Tratamento

Seguindo a notação de [CALLAWAY e SANT'ANNA \(2021\)](#), definimos G_i como o ano em que a microrregião i recebe sua primeira estação meteorológica. Para unidades nunca tratadas durante o período de análise, convencionamos $G_i = 0$. Esta codificação é essencial para a implementação computacional e permite a utilização dessas unidades como grupo de controle potencial.

A distribuição temporal da adoção revela padrões relevantes: observa-se uma concentração significativa de instalações em 2006-2008, coincidindo com programas federais de expansão da rede meteorológica, seguida por adoção mais esparsa nos anos subsequentes. Das 490 microrregiões analisadas, a maioria eventualmente recebeu estações ao longo do período de estudo.

2.3.3 Variável Dependente e Transformações

A variável dependente principal é o logaritmo natural do PIB agropecuário, definida como:

$$Y_{it} = \ln(1 + \text{PIB_Agropecuário}_{it}) \quad (2.4)$$

onde $\text{PIB_Agropecuário}_{it}$ representa o valor total da produção agropecuária para a microrregião i no ano t . A transformação logarítmica oferece três vantagens metodológicas importantes:

1. **Interpretação econômica direta:** Os coeficientes estimados podem ser interpretados aproximadamente como variações percentuais na produtividade, facilitando a comunicação dos resultados.

2. **Redução de heterocedasticidade:** A transformação log suaviza a variância crescente tipicamente observada em dados de produtividade agrícola.
3. **Tratamento de zeros:** O uso de $\ln(1 + x)$ evita problemas computacionais quando há observações com produtividade zero, mantendo essas observações na amostra.

2.3.4 Covariáveis e Especificação do Modelo

A especificação do modelo inclui um conjunto de covariáveis socioeconômicas cuidadosamente selecionadas para controlar por fatores que podem influenciar tanto a probabilidade de receber uma estação meteorológica quanto o PIB agropecuário:

1. **Log da área plantada:** Controla pelo tamanho da atividade agrícola na microrregião, capturando economias de escala e intensidade produtiva.
2. **Log da população:** Proxy para desenvolvimento econômico local e demanda por produtos agrícolas.
3. **Log do PIB per capita:** Captura o nível de desenvolvimento econômico e capacidade de investimento local.
4. **Log da densidade de estações na UF:** Variável construída agregando o número de estações meteorológicas ao nível estadual, normalizada pela área. Esta variável é crucial para capturar potenciais efeitos de spillover regional, reconhecendo que informações meteorológicas podem fluir entre microrregiões vizinhas dentro do mesmo estado.

A inclusão da densidade estadual de estações merece destaque especial. Esta variável permite um pseudo-mapeamento dos efeitos de transbordamento regional, considerando que:

- Informações meteorológicas têm natureza de bem público, podendo beneficiar áreas além da localização física da estação
- A instalação de estações melhora a qualidade das previsões meteorológicas para toda a região, criando um efeito sistêmico que se propaga principalmente dentro dos limites estaduais
- Produtores podem se beneficiar indiretamente da maior densidade de estações no estado através de previsões mais precisas e dados climáticos mais confiáveis

2.3.5 O Estimador Duplamente Robusto

Para a estimação dos efeitos causais, adotamos o estimador *Duplamente Robusto* (DR) proposto por [SANT'ANNA e ZHAO \(2020\)](#), que combina modelos de regressão para o resultado com ponderação por probabilidade inversa. Esta abordagem oferece propriedades estatísticas desejáveis:

- **Dupla proteção contra má especificação:** O estimador permanece consistente se pelo menos um dos dois modelos (resultado ou score de propensão) estiver corretamente especificado.
- **Eficiência melhorada:** Sob especificação correta de ambos os modelos, o DR atinge a fronteira de eficiência semiparamétrica.
- **Robustez a extremos:** A combinação de métodos mitiga problemas associados a pesos extremos no IPW puro.

2.3.6 Escolha do Grupo de Controle

Uma decisão metodológica importante na implementação do estimador de [CALLAWAY e SANT'ANNA \(2021\)](#) refere-se à escolha do grupo de controle. O pacote `did` oferece duas opções principais:

- **Not-yet-treated:** Utiliza como controle tanto unidades nunca tratadas quanto unidades ainda não tratadas no período t . Esta abordagem maximiza o tamanho da amostra de controle e é particularmente útil em contextos com poucos ou nenhum never-treated.
- **Never-treated:** Restringe o grupo de controle apenas às unidades que nunca receberam tratamento durante todo o período amostral. Embora conceitualmente mais limpo, pode resultar em poder estatístico reduzido.

Para esta análise, adotamos como padrão o grupo **not-yet-treated** por três razões: (i) maximiza a eficiência estatística ao utilizar toda a informação disponível; (ii) é apropriado para nosso contexto onde a adoção ocorre gradualmente ao longo do tempo; e (iii) os resultados mostram-se robustos a ambas as especificações (diferença de apenas 2,5%), validando esta escolha metodológica.

2.4 Especificação da Análise de Estudo de Evento

A análise de estudo de evento constitui o núcleo da estratégia empírica adotada, permitindo examinar como o efeito do tratamento evolui dinamicamente ao longo do tempo. Esta abordagem é particularmente adequada para o contexto analisado por três razões fundamentais:

1. **Teste de tendências paralelas:** Permite verificar visualmente e estatisticamente se os grupos tratados e controle seguiam trajetórias similares antes do tratamento, validando o pressuposto fundamental de identificação.
2. **Dinâmica de adoção tecnológica:** Captura o processo gradual de difusão e aprendizado associado ao uso de informações meteorológicas, reconhecendo que os benefícios podem não ser imediatos.
3. **Heterogeneidade temporal:** Acomoda a possibilidade de que os efeitos variem com o tempo de exposição ao tratamento, seja por acumulação de conhecimento ou mudanças nas práticas agrícolas.

2.4.1 Formalização da Análise de Estudo de Evento

Definimos o tempo relativo ao tratamento como $e = t - g$, onde g é o ano de instalação da primeira estação e t é o período calendário. Assim, $e < 0$ representa períodos pré-tratamento, $e = 0$ marca o início do tratamento, e $e > 0$ captura períodos pós-tratamento.

A agregação dos efeitos $ATT(g, t)$ em função do tempo relativo segue a especificação:

$$\theta_{es}^{bal}(e) = \sum_{g \in \mathcal{G}} \mathbf{1}\{g + e \leq T\} \cdot P(G = g | G + e \leq T) \cdot ATT(g, g + e) \quad (2.5)$$

onde:

- $\theta_{es}^{bal}(e)$ representa o efeito médio do tratamento e períodos após sua introdução
- \mathcal{G} é o conjunto de coortes de adoção (excluindo nunca tratados)
- $P(G = g | G + e \leq T)$ são pesos que garantem que cada coorte contribua proporcionalmente ao número de unidades tratadas
- $\mathbf{1}\{g + e \leq T\}$ assegura que incluímos apenas coortes observadas por pelo menos e períodos pós-tratamento

Esta especificação garante comparabilidade entre períodos, ponderando adequadamente a contribuição de cada coorte conforme sua representatividade na amostra.

É importante notar que, conforme alertam [CALLAWAY e SANT'ANNA \(2021\)](#), event studies longos podem sofrer de mudanças na composição dos grupos contribuindo para cada período relativo. Em nosso caso, com tratamento escalonado de 2000 a 2019, períodos relativos extremos ($e > 15$ ou $e < -15$) são estimados com base em poucas coortes, o que explica a maior variabilidade observada nesses períodos. A agregação balanceada $\theta_{es}^{bal}(e)$ mitiga este problema ao fixar o conjunto de grupos contribuintes.

3 Resultados

3.1 Implementação Computacional

3.1.1 Software e Pacotes Utilizados

A implementação empírica foi realizada utilizando o software R (R Core Team, 2025) em conjunto com o pacote `did` (versão 2.1.2), desenvolvido por CALLAWAY e SANT'ANNA (2021). O uso deste pacote oficial garante conformidade estrita com os procedimentos propostos no artigo metodológico, implementando fielmente os estimadores e procedimentos de inferência. As principais funcionalidades utilizadas incluem:

- Cálculo dos $ATT(g,t)$ com inferência via bootstrap
- Agregações flexíveis (overall, dynamic, group, calendar)
- Diagnósticos de balanço e testes de especificação
- Tratamento adequado de dados desbalanceados

Complementarmente, utilizamos os pacotes `dplyr` para manipulação de dados, `ggplot2` para visualizações, e `purrr` para programação funcional, garantindo reprodutibilidade através do sistema `renv` de gerenciamento de dependências.

3.1.2 Transparência e Reprodutibilidade

Em alinhamento com as melhores práticas de ciência aberta e transparência acadêmica, todo o código desenvolvido para este trabalho está disponível publicamente no repositório GitHub <<https://github.com/danielcavalli/tcc-ie-ufrj-2024>>. O repositório contém:

- Scripts de extração e preparação de dados em Python
- Código completo do modelo econométrico em R
- Arquivos \LaTeX do documento final
- Bibliografia e referências utilizadas
- Histórico completo de versionamento do projeto

A extração inicial dos dados foi realizada utilizando Python em conjunto com o pacote `basedosdados` e a API do Google BigQuery, permitindo acesso eficiente aos microdados do IBGE e outras fontes oficiais. Esta abordagem garante:

- **Rastreabilidade:** Todo o processo de obtenção e transformação dos dados está documentado
- **Reprodutibilidade:** Qualquer pesquisador pode recriar o dataset a partir das fontes originais
- **Transparência:** O versionamento completo permite acompanhar a evolução da análise

3.1.3 Estrutura dos Dados e Processo de Extração

O conjunto de dados foi construído através de um processo sistemático de extração e agregação utilizando Python, o pacote `basedosdados` e a API do Google BigQuery. O notebook `analise_did_microrregions.ipynb`, disponível no repositório do projeto, documenta todo o processo de construção do dataset. As etapas principais incluem:

3.1.3.1 Fontes de Dados e Extração

1. **Mapeamento Município-Microrregião:** Extraído da tabela `br_bd_diretorios_brasil.municipio`, identificando 5.570 municípios em 558 microrregiões brasileiras.
2. **Estações Meteorológicas:** Dados de 610 estações do Instituto Nacional de Meteorologia (INMET) extraídos da tabela `br_inmet_bdmetp.estacao`, incluindo coordenadas geográficas e data de fundação. Após agregação por microrregião, identificamos 394 microrregiões com pelo menos uma estação (70,6% de cobertura).
3. **População Municipal:** Dados anuais da tabela `br_ibge_populacao.municipio`, agregados para o nível de microrregião através de soma simples.
4. **PIB Municipal:** Valores totais e agropecuários extraídos de `br_ibge_pib.municipio`, incluindo PIB total e valor adicionado da agropecuária.
5. **Produção Agrícola (PAM):** Dados detalhados de produção de cana-de-açúcar da tabela `br_ibge_pam.lavoura_temporaria`, incluindo área plantada, área colhida, quantidade produzida, produtividade média e valor da produção.

3.1.3.2 Critérios de Qualidade e Filtros

- **Filtro temporal:** Microrregiões com pelo menos 10 anos de produção positiva de cana-de-açúcar no período 2003-2023
- **Taxa de aproveitamento:** Calculada como área colhida/área plantada para monitorar eficiência produtiva (média de 99,1%)
- **Agregação espacial:** Todos os dados municipais foram agregados ao nível de microrregião usando os códigos oficiais do IBGE

O dataset final contém 10.290 observações (490 microrregiões \times 21 anos), focando em microrregiões produtoras de cana-de-açúcar concentradas principalmente nas regiões Centro-Sul e litoral nordestino.

3.1.3.3 Construção das Variáveis de Tratamento

O tratamento foi definido como a instalação da primeira estação meteorológica automática em funcionamento na microrregião. Para cada microrregião i :

- G_i = ano da primeira estação instalada (0 se nunca tratada)
- `tratado` = 1 se $G_i > 0$, 0 caso contrário
- `pos_tratamento` = 1 se `ano` $\geq G_i$ e `tratado` = 1

Das 490 microrregiões no dataset final: - 351 foram tratadas em algum momento (71,6%) - 139 permaneceram como controle durante todo o período - Concentração de instalações em 2006-2008, coincidindo com programas federais de expansão

3.1.3.4 Tratamento de Dados Faltantes e Qualidade

1. **Compleitude dos dados:** O dataset final apresenta 0% de valores ausentes para todas as variáveis principais (população, PIB e produção agrícola), resultado do rigoroso processo de filtragem que manteve apenas microrregiões com informações completas.
2. **Zeros estruturais:** Anos sem produção foram mantidos como zeros, distinguindo-os de valores ausentes, permitindo capturar tanto margem intensiva quanto extensiva.
3. **Validação cruzada:** O mapeamento município-microrregião foi validado com múltiplas fontes oficiais, garantindo consistência territorial ao longo do período.

4. **Clustering de erros-padrão:** Como nossos dados formam um painel (microrregião \times ano), é provável que os erros de uma mesma microrregião sejam correlacionados ao longo do tempo devido a características não observadas persistentes ou choques que afetam a mesma unidade em múltiplos períodos. Para corrigir a inferência estatística, clusterizamos os erros-padrão ao nível da microrregião, permitindo correlação arbitrária dos resíduos dentro de cada microrregião ao longo dos 21 anos, mas assumindo independência entre diferentes microrregiões. Isso resulta em erros-padrão mais conservadores e inferência mais robusta.

O notebook de extração permite flexibilidade para análise de diferentes produtos agrícolas, bastando alterar a variável `PRODUTOS_AGRICOLAS`. Essa modularidade facilita estudos comparativos e testes de robustez com outras culturas.

3.2 Resultados Principais

3.2.1 Efeito Médio do Tratamento

A estimação do efeito médio do tratamento sobre os tratados (ATT) via estimador doubly robust revela um impacto positivo e estatisticamente significativo da instalação de estações meteorológicas sobre o PIB agropecuário:

$$\text{ATT} = 0.082 \text{ (EP} = 0.032, z = 2,57, p = 0,0103, \text{ IC 95\%: [0,0194; 0,1448])}$$

Este resultado indica que as microrregiões que receberam estações meteorológicas experimentaram, em média, um aumento de aproximadamente **8.2%** no PIB agropecuário em relação ao contrafactual de não receber a estação. A magnitude do efeito é economicamente relevante, representando bilhões em valor agregado quando extrapolado para o nível nacional.

A Tabela 1 apresenta os resultados principais e testes placebo:

*Notas: *** $p < 0,01$, ** $p < 0,05$, * $p < 0,10$. Erros-padrão clusterizados ao nível da microrregião. $N = 10.290$ observações para o modelo principal. O teste placebo com PIB não-agropecuário confirma a especificidade do efeito ao setor agrícola.*


3.2.2 Análise de Estudo de Evento e Dinâmica Temporal

A análise de estudo de evento fornece evidências fundamentais sobre a evolução temporal dos efeitos do tratamento. A Figura 1 apresenta as estimativas pontuais e intervalos de confiança para períodos relativos ao início do tratamento.

Tabela 1 – Resultados Principais e Testes Placebo

Análise	ATT	EP	IC 95%
ATT Principal (PIB Agro)	0.082***	(0.032)	[0,019; 0,145]
Placebo (PIB Não-Agro)	0,015	(0,019)	[-0,022; 0,052]
<i>Especificações Alternativas</i>			
Sem Covariáveis	0,110***	(0,026)	[0,060; 0,161]
IPW	0,094***	(0,032)	[0,032; 0,157]
Regressão de Resultado	0,066**	(0,030)	[0,007; 0,126]
<i>Grupo de Controle Alternativo</i>			
Never-treated	0,080**	(0,036)	[0,009; 0,151]

Figura 1 – Estudo de Evento - Dinâmica Temporal dos Efeitos da Instalação de Estações Meteorológicas



Nota: A figura apresenta as estimativas pontuais (linha azul) e intervalos de confiança de 95% (área sombreada) dos efeitos do tratamento em função do tempo relativo à instalação da estação. O período $e=0$ marca o ano de instalação.

Fonte: Elaboração própria a partir dos dados do estudo.

3.2.2.1 Período Pré-Tratamento: Validação das Tendências Paralelas

A análise dos períodos anteriores ao tratamento ($e < 0$) é fundamental para validar o pressuposto de identificação. Os resultados mostram:

- **Média próxima a zero:** Os efeitos pré-tratamento apresentam média de 0,0122 (DP = 0,124), não distinguível estatisticamente de zero (teste t: $p = 0,2924$).
- **Teste formal de tendências paralelas:** O teste de hipótese conjunta para igualdade de slopes entre coortes no período pré-tratamento resulta em F-statistic = 1,136

(p-valor = 0,3215), fornecendo forte evidência estatística a favor do pressuposto de tendências paralelas.

- **Ausência de tendência sistemática:** Não se observa padrão crescente ou decrescente nos períodos que antecedem o tratamento, com coeficientes oscilando aleatoriamente em torno de zero.
- **Variabilidade aleatória:** Embora alguns períodos específicos apresentem significância pontual, isso é consistente com flutuações aleatórias esperadas em múltiplas comparações (aproximadamente 5% dos testes ao nível de 5% de significância).

Estes resultados fornecem suporte empírico robusto para o pressuposto de tendências paralelas condicionais. O p-valor elevado (0,3215) do teste formal indica que não há evidência contra a hipótese de tendências paralelas, validando a estratégia de identificação causal.

3.2.2.2 Dinâmica Pós-Tratamento: Difusão Gradual dos Benefícios

O padrão temporal dos efeitos pós-tratamento é consistente com um processo de adaptação e aprendizado no uso das informações meteorológicas. A análise de event study confirma a ausência de tendências pré-tratamento diferenciadas, validando o pressuposto de identificação, e mostra efeitos positivos após o tratamento.


Este padrão é consistente com um processo de difusão tecnológica onde:

1. A informação meteorológica precisa ser interpretada e integrada às decisões de plantio
2. Os agricultores aprendem gradualmente a otimizar o uso das informações
3. Efeitos de rede emergem conforme mais produtores adotam melhores práticas

3.2.2.3 Análise Detalhada de Tendências Paralelas

Para uma validação mais rigorosa do pressuposto de tendências paralelas, a Figura 2 apresenta a evolução completa do PIB agropecuário normalizado para grupos tratados e controle ao longo de todo o período amostral.

Figura 2 – Tendências Paralelas - PIB Agropecuário Normalizado (2003-2023)



Nota: A figura mostra a evolução do PIB agropecuário médio (em log) para microrregiões antes e depois do tratamento, normalizado pelo valor de 2003. As áreas sombreadas representam intervalos de confiança de 95%.

Fonte: Elaboração própria a partir dos dados do estudo.

3.3 Testes de Robustez e Diagnósticos

Para garantir a confiabilidade dos resultados, implementamos uma bateria abrangente de testes de robustez e diagnósticos. Esta seção examina três aspectos críticos: (i) a sensibilidade à escolha do grupo de controle, (ii) a composição dinâmica do efeito agregado ao longo do tempo, e (iii) testes placebo para validar a estratégia de identificação.

3.3.1 Sensibilidade ao Grupo de Controle

Em modelos DiD com adoção escalonada, a escolha do grupo de controle pode afetar as estimativas. Testamos duas especificações:

Tabela 2 – Comparação de Estimativas por Grupo de Controle

Grupo de Controle	ATT	Erro Padrão	IC 95%
Not-yet-treated	0.082	0.032	[0,0194; 0,1448]
Never-treated	0,0801	0,0361	[0,0093; 0,1508]


A estabilidade das estimativas entre diferentes grupos de controle (diferença de apenas 2,5%) reforça a robustez da identificação. Esta pequena diferença sugere que:

- Não há viés de seleção diferencial significativo entre grupos
- As unidades ainda não tratadas constituem controles válidos
- O pressuposto de tendências paralelas se mantém para ambas as especificações

3.3.2 Análise da Composição Dinâmica dos Efeitos

Um desafio em DiD escalonado é que a composição dos grupos tratados muda ao longo do tempo. A Figura 3 decompõe o efeito agregado por coorte de adoção:

Figura 3 – Composição Dinâmica do Efeito do Tratamento



Nota: O gráfico decompõe o ATT agregado mostrando a contribuição de cada coorte de adoção (indicada por cores) ao longo do tempo relativo ao tratamento. Observa-se que: (i) grupos adotantes precoces (2004-2007) dominam os períodos de exposição mais longos; (ii) a partir de 2013, mais de 70% das unidades já haviam sido tratadas por pelo menos 5 anos, indicando maturidade do programa; (iii) a contribuição é relativamente balanceada entre coortes nos primeiros anos pós-tratamento, validando que o ATT não é dirigido por grupos específicos.

Fonte: Elaboração própria a partir dos dados do estudo.

Esta análise revela três insights importantes:

1. **Balanceamento inicial:** Nos primeiros 5 anos após o tratamento (períodos cruciais para identificação), múltiplas coortes contribuem para o efeito agregado, evitando viés de composição.
2. **Maturidade do programa:** A concentração de unidades com exposição longa ao tratamento após 2013 sugere que os efeitos estimados capturam impactos de longo prazo sustentados.

3. **Ausência de dominância:** Nenhuma coorte individual domina excessivamente o ATT agregado, fortalecendo a validade externa dos resultados.

3.3.3 Testes Placebo

Os resultados anteriores mostram robustez à escolha do grupo de controle e ausência de viés de composição. Agora implementamos três tipos de testes placebo para validar definitivamente que os efeitos estimados são causais e não artefatos estatísticos:

3.3.3.1 Teste Placebo com Atribuição Aleatória Fixa

Este teste avalia se o modelo pode gerar resultados significativos quando o tratamento é atribuído de forma completamente aleatória:

1. **Metodologia:** Ignoramos completamente o status real de tratamento e selecionamos aleatoriamente 50% das microrregiões para receber um “tratamento placebo” em 2015, independentemente de quando (ou se) realmente receberam estações meteorológicas.
2. **Hipótese:** Se o efeito estimado for genuíno, não devemos observar impacto significativo com esta atribuição aleatória.
3. **Resultado:** $ATT = -0,0237$ ($EP = 0,0339$, $p = 0,485$)
 - O efeito não é estatisticamente diferente de zero
 - A magnitude é pequena e o sinal é negativo
 - Confirma que o modelo não gera efeitos espúrios com atribuição aleatória

3.3.3.2 Teste de Randomização de Monte Carlo

Para validar ainda mais a robustez de nossos resultados, implementamos um teste de randomização de Monte Carlo. Este teste verifica se o ATT estimado de 0.082 poderia ter surgido por mero acaso no timing de tratamento. O procedimento consiste em reatribuir aleatoriamente o momento de tratamento entre as unidades múltiplas vezes, criando uma distribuição de referência sob a hipótese nula de ausência de efeito.

3.3.3.2.1 Formalização do Teste

Para manter o rigor metodológico, formalizamos o teste considerando nosso conjunto de dados $\mathcal{D} = \{(Y_{it}, W_{it}, X_{it})\}_{i=1, t=1}^{N, T}$ (conforme definido na Seção 2.3), onde:

- $\mathcal{W} = \{W_{it}\}_{i, t}$: matriz de tratamento observada.

- $ATT(\mathcal{W})$: efeito médio do tratamento estimado via método DR com a atribuição de tratamento \mathcal{W} .
- \mathcal{S} : espaço de todas as possíveis atribuições de tratamento.

Hipótese Nula (H_0): A instalação de estações meteorológicas não tem efeito causal sobre o PIB agropecuário, ou seja, $Y_{it}(1) = Y_{it}(0)$ para todas as unidades e períodos.

Procedimento:

Como o número total de permutações possíveis é astronomicamente grande, aproximamos a distribuição exata através de simulações de Monte Carlo. O teste segue os seguintes passos:

1. Geração de Atribuições Aleatórias:

Para cada uma das $S = 5000$ simulações:

- Selecionamos aleatoriamente N_{tratado} microrregiões para receber o tratamento (mantendo o mesmo número de unidades tratadas que no estudo original).
- Atribuímos aleatoriamente o ano de instalação da estação entre 2005 e 2021 para cada unidade selecionada.

Esta restrição temporal garante pelo menos 2 anos de dados antes e depois do tratamento para cada unidade.

2. Estimação dos ATTs Placebo:

Para cada atribuição aleatória s , estimamos o ATT usando exatamente o mesmo método DR aplicado aos dados originais:

$$ATT^{(s)} = ATT(\mathcal{W}^{(s)}), \quad s = 1, \dots, S \quad (3.1)$$

3. Cálculo do P-valor:

Seguindo (DAVISON; HINKLEY, 1997), calculamos o p-valor empírico com correção para amostras finitas:

$$\hat{p} = \frac{1 + \#\{\text{extremos}\}}{S + 1} \quad (3.2)$$

onde $\#\{\text{extremos}\}$ representa o número de simulações cujo ATT em valor absoluto é maior ou igual ao ATT observado. Esta correção evita p-valores exatamente zero e é prática padrão em testes de permutação.

Intuição: Se o tratamento realmente não tivesse efeito, seria igualmente provável observar o ATT estimado com qualquer atribuição aleatória de tratamento. Portanto, se nosso ATT observado é muito extremo comparado à distribuição de ATTs sob atribuições aleatórias, temos evidência forte contra a hipótese nula.

3.3.3.2 Aspectos Computacionais

A implementação do teste incorpora várias considerações práticas:

- **Margem de Segurança Temporal:** Restringimos $t_i^* \in [2005, 2021]$ para garantir pelo menos 2 anos de dados pré e pós-tratamento.
- **Paralelização:** Implementamos computação paralela via `foreach/doParallel` em R, distribuindo as S simulações entre múltiplos núcleos de processamento.
- **Tratamento de Falhas:** Aproximadamente 5-10% das simulações podem falhar devido a configurações que não permitem estimação robusta do ATT.
- **Validação:** Apenas simulações com convergência bem-sucedida ($S_{\text{válido}}$) entram no cálculo: $\hat{p} = \frac{1 + \#\{\text{extremos}\}}{S_{\text{válido}} + 1}$.
- **Reprodutibilidade:** Utilizamos sementes aleatórias únicas ($\text{seed} \times 1000 + s$) para cada simulação, garantindo reprodutibilidade mesmo em ambiente paralelo.

3.3.3.2.3 Implementação e Resultados

A Tabela 3 apresenta os resultados do teste de randomização de Monte Carlo com $S = 5000$ simulações independentes:


Tabela 3 – Resultados do Teste de Randomização de Monte Carlo

Estatística	Valor
Número de simulações	5.000
ATT observado	0.082
Média dos placebos	0.000
Desvio padrão dos placebos	0,017
Intervalo empírico 95%	[-0.033; 0.033]
P-valor empírico	< 0,001

Notas: O teste simula 5.000 atribuições aleatórias de tratamento, mantendo a estrutura temporal do painel. O p-valor empírico indica a proporção de simulações com ATT em valor absoluto maior ou igual ao observado.

A Figura 4 visualiza o resultado do teste de randomização múltipla:

Figura 4 – Distribuição dos ATTs Placebo vs. ATT Verdadeiro



Nota: O histograma apresenta a distribuição dos ATTs estimados em 5000 iterações do teste placebo, onde o tratamento foi atribuído aleatoriamente. Cada barra representa a frequência de ATTs placebo em cada intervalo. A linha vermelha tracejada indica o ATT verdadeiro do modelo principal (0.082). A distribuição placebo está claramente centrada em zero, enquanto o ATT verdadeiro encontra-se na cauda extrema direita, ocorrendo em menos de 0.02% das simulações aleatórias (p -valor empírico $< 0,001$). Isso demonstra que um efeito desta magnitude é extremamente improvável de ser observado por mero acaso.

Fonte: Elaboração própria a partir dos dados do estudo.

3.3.3.2.4 Interpretação dos Resultados

O teste de randomização revela que o ATT observado de 0.082 encontra-se na cauda extrema da distribuição placebo (p -valor = $< 0,001$). Isso significa que:

- A probabilidade de observar um efeito desta magnitude por puro acaso no timing de tratamento é menor que 0.02%.
- O efeito estimado não é compatível com variação aleatória nos dados.
- Podemos rejeitar com alta confiança a hipótese de que o tratamento não teve efeito.

Observação importante: Este teste valida que o efeito não surgiu por coincidência no timing de tratamento, mas não descarta outras possíveis ameaças à identificação causal (como variáveis omitidas ou choques concomitantes). A interpretação causal continua dependendo da validade dos pressupostos do modelo DiD discutidos anteriormente.

3.3.3.3 Teste Placebo com PIB Não-Agropecuário

Este teste avalia a especificidade do efeito ao setor agrícola:

1. **Metodologia:** Reestimamos o modelo completo usando o PIB não-agropecuário (log) como variável dependente, mantendo todas as outras especificações idênticas.
2. **Hipótese:** Se o efeito das estações meteorológicas é específico à agricultura (através de informações climáticas para tomada de decisão), não devemos observar impacto significativo em setores não-agrícolas.
3. **Resultado:** $ATT = 0,030$ ($EP = 0,033$, $p = 0,365$)
 - Efeito não significativo estatisticamente
 - Magnitude 73% menor que o efeito no PIB agropecuário
 - Confirma que o impacto é específico ao setor agrícola
4. **Interpretação:** A ausência de efeito significativo no PIB não-agropecuário descarta a hipótese de que os resultados reflitam desenvolvimento econômico geral ou outros fatores não relacionados à informação meteorológica para a agricultura.

3.3.3.4 Síntese dos Testes Placebo

Os três testes placebo implementados fornecem evidências complementares robustas:

1. **Validade da identificação:** A atribuição aleatória de tratamento não gera efeitos significativos, confirmando que o modelo não produz resultados espúrios.
2. **Raridade estatística:** O ATT verdadeiro seria observado em menos de 1% dos casos por puro acaso, indicando alta significância estatística.
3. **Especificidade setorial:** O efeito é específico ao setor agrícola, consistente com o mecanismo teórico de que informações meteorológicas melhoram decisões produtivas na agricultura.

Conjuntamente, esses testes fortalecem substancialmente a interpretação causal dos resultados, descartando explicações alternativas como tendências gerais de desenvolvimento, choques comuns ou artefatos estatísticos.

3.4 Análises de Robustez Adicionais

Além dos testes de validação apresentados, realizamos análises complementares para avaliar a sensibilidade dos resultados a diferentes especificações e períodos temporais.

3.4.1 Sensibilidade ao Período de Análise

Os resultados podem ser sensíveis à janela temporal escolhida, especialmente considerando eventos como a pandemia de COVID-19. Testamos diferentes recortes temporais, utilizando agregação por médias simples dos $ATT(g,t)$ para permitir comparação justa entre os diferentes subconjuntos de dados:

Tabela 4 – Análise de Sensibilidade ao Período de Análise

Período	ATT	EP	IC 95%	N Tratadas
Completo (2003-2023)	0.126***	(0.029)	[0.070; 0.182]	7.371
Excluindo Início (2006-2023)	0.130***	(0.031)	[0.069; 0.191]	6.318
Excluindo COVID (2003-2019)	0.117***	(0.026)	[0.066; 0.169]	5.967

*Notas: *** $p < 0,01$. Erros-padrão clusterizados ao nível da microrregião. $ATT(g,t)$ agregados por média simples para comparabilidade entre subconjuntos. A análise revela robustez dos resultados a diferentes janelas temporais.*

Os resultados revelam insights importantes:

- **Robustez geral:** Os efeitos permanecem positivos e significativos em todas as especificações, com magnitudes entre 11,7% e 13,0%.
- **Período pandêmico:** A exclusão dos anos 2020-2023 reduz ligeiramente o efeito (de 12,6% para 11,7%), sugerindo que o período COVID não inflou artificialmente os resultados.
- **Importância do período inicial:** A exclusão dos primeiros anos (2003-2005) tem impacto mínimo, indicando que os resultados não são dominados pelas coortes iniciais.
- **Comparabilidade dos resultados:** O uso de médias simples na agregação garante que as diferenças observadas refletem mudanças genuínas nos efeitos e não apenas mudanças na composição dos grupos tratados.

3.4.2 Robustez a Diferentes Métodos de Estimação

A validade dos resultados não deve depender do método econométrico específico. Comparamos três abordagens:

Cada método tem características distintas:

- **Doubly Robust:** Combina modelagem do resultado e do tratamento, sendo consistente se pelo menos um modelo estiver correto

Tabela 5 – Comparação de Métodos de Estimação


Método	ATT	Erro Padrão	P-valor
Doubly Robust (DR)	0.082	0.032	0,0103
IPW	0,0944	0,0317	0,0029
Regression (REG)	0,0663	0,0305	0,0296

- **IPW:** Usa apenas pesos de propensity score, focando no balanceamento das covariáveis
- **Regression:** Baseia-se apenas na modelagem do resultado condicional às covariáveis

A consistência das estimativas entre os três métodos (variando de 6,6% a 9,4%, todos significativos) indica que os resultados não dependem criticamente da abordagem econométrica escolhida.

A Figura 5 sintetiza visualmente os resultados de robustez:

Figura 5 – Análise de Robustez - Comparação de Especificações



Nota: O gráfico apresenta as estimativas pontuais e intervalos de confiança de 95% para diferentes especificações e métodos de estimação. Todas as estimativas são estatisticamente significativas e de magnitude similar, confirmando a robustez dos resultados.

3.4.3 Síntese das Análises de Robustez

O conjunto abrangente de testes e análises de sensibilidade realizados fornece evidências convergentes sobre a validade e robustez dos resultados:

1. **Identificação causal:** Os testes placebo descartam explicações alternativas e confirmam que o efeito é genuinamente causal e específico às estações meteorológicas.

2. **Estabilidade das estimativas:** O ATT permanece entre 6,6% e 9,4% através de diferentes métodos, grupos de controle e especificações, indicando que o efeito médio de 8.2% é uma estimativa confiável.
3. **Ausência de viés de composição:** A análise dinâmica mostra que nenhuma coorte específica domina os resultados, e a agregação balanceada garante comparabilidade ao longo do tempo.
4. **Robustez temporal:** Os efeitos persistem excluindo diferentes períodos, confirmando que não são dirigidos por eventos específicos como a pandemia.

Estas evidências combinadas estabelecem uma base sólida para a interpretação causal de que as estações meteorológicas geram aumentos substantivos e sustentados na produtividade agrícola.

3.5 Discussão e Interpretação Econômica

3.5.1 Contextualização da Magnitude do Efeito

- **Comparação setorial:** O crescimento médio anual do PIB agropecuário no Brasil é de aproximadamente 3-4% ao ano. O efeito das estações equivale a mais de dois anos de crescimento típico do setor, representando um salto estrutural significativo na produtividade.
- **Valor monetário:** Considerando o PIB agropecuário médio das microrregiões tratadas e o efeito estimado de 8.2%, o ganho anual por microrregião é economicamente significativo, justificando plenamente o investimento em infraestrutura meteorológica.
- **Custo-benefício e Política Atual:** A relevância destes resultados é amplificada pelo anúncio recente do governo federal. Em setembro de 2025, o Ministério da Agricultura, Pecuária e Abastecimento (MAPA) anunciou um novo investimento de R\$ 49 milhões para a instalação de 220 novas estações meteorológicas automáticas ([MINISTÉRIO DA AGRICULTURA E PECUÁRIA, 2025](#)), demonstrando o reconhecimento institucional da importância dessa infraestrutura. Com um custo médio de R\$ 223 mil por estação, nossos resultados sugerem retornos econômicos que superam amplamente o investimento inicial.
- **Implicações para Expansão da Rede:** Nosso estudo fornece evidência empírica robusta para justificar não apenas o investimento anunciado, mas potencialmente sua ampliação. Com efeitos de 8.2% no PIB agropecuário e considerando que 29%

das microrregiões produtoras ainda não possuem estações, existe espaço significativo para ganhos adicionais de produtividade através da expansão estratégica da rede.

- **Timing e Urgência:** O momento deste investimento é particularmente oportuno. Com eventos climáticos extremos tornando-se mais frequentes e intensos, a capacidade de monitoramento e resposta rápida torna-se ainda mais crítica. Nossos resultados mostram que os benefícios se materializam após a instalação, sugerindo que atrasos na implementação representam perdas econômicas significativas.

A evidência empírica sugere que o histórico subinvestimento em infraestrutura meteorológica representa uma oportunidade perdida significativa para o desenvolvimento agrícola brasileiro, especialmente considerando a relação extremamente favorável entre custo de implementação e magnitude dos benefícios gerados.

3.5.2 Mecanismos Subjacentes


Os padrões temporais observados sugerem múltiplos canais através dos quais as informações meteorológicas afetam a produtividade:

1. **Otimização do calendário agrícola:** Melhor determinação dos momentos de plantio e colheita baseada em previsões precisas. Estudos no Nordeste brasileiro demonstram como mudanças climáticas afetam o potencial produtivo da cana-de-açúcar, ressaltando a importância de informações meteorológicas precisas para adaptação (CARVALHO et al., 2015).
2. **Gestão hídrica eficiente:** Ajuste de irrigação conforme condições climáticas reais. Modelos agrometeorológicos específicos para cana-de-açúcar no Brasil demonstram a importância crítica da gestão hídrica baseada em dados meteorológicos precisos (MONTEIRO; SENTELHAS, 2017; MARIN et al., 2015).
3. **Redução de perdas:** Antecipação a eventos extremos permite medidas preventivas. Aplicações operacionais de modelos de simulação de cana-de-açúcar no Brasil demonstram como informações meteorológicas precisas podem otimizar decisões de irrigação e reduzir perdas (VIANNA; SENTELHAS, 2016).
4. **Melhoria em modelos computacionais:** Dados meteorológicos locais de alta qualidade aumentam significativamente a precisão de modelos de simulação agrícola, permitindo aos produtores testar cenários e otimizar estratégias de manejo antes da implementação no campo.

3.5.3 Análise de Poder Estatístico

Para avaliar a capacidade do design de pesquisa em detectar efeitos de diferentes magnitudes, realizou-se uma análise de poder estatístico através de simulações. A Figura 6 apresenta as curvas de poder para diferentes tamanhos de efeito:

Figura 6 – Análise de Poder Estatístico por Tamanho de Efeito



Nota: O gráfico apresenta o poder estatístico (probabilidade de rejeitar H_0 quando falsa) em função do tamanho do efeito verdadeiro, para três níveis de significância ($\alpha = 0,01$, $0,05$ e $0,10$). Para o efeito estimado de 8.2%, o poder estatístico é de 78,7% ($\alpha = 0,01$), 92,1% ($\alpha = 0,05$) e 95,8% ($\alpha = 0,10$), indicando excelente capacidade de detecção ao nível convencional de 5%.

3.5.4 Procedimentos de Inferência

Seguindo as recomendações de [CALLAWAY e SANT'ANNA \(2021\)](#), todos os erros-padrão e intervalos de confiança reportados neste estudo foram calculados utilizando bootstrap multiplicativo com 1.000 replicações. Este procedimento é particularmente importante por duas razões:

1. **Clustering:** Com dados em painel e tratamento ao nível da microrregião, é essencial considerar a correlação dentro dos clusters. O bootstrap multiplicativo implementado no pacote `did` automaticamente respeita a estrutura de clustering dos dados.
2. **Múltiplas Hipóteses:** Em análises de event study, múltiplos coeficientes são estimados e testados simultaneamente (um para cada período relativo). O procedimento de bootstrap garante inferência válida mesmo neste contexto de testes múltiplos, fornecendo bandas de confiança uniformes.

A escolha do bootstrap sobre aproximações assintóticas tradicionais também oferece melhor desempenho em amostras finitas, particularmente relevante para períodos pré-tratamento distantes onde o número de observações pode ser menor.

3.5.5 Limitações e Pesquisa Futura

Embora os resultados sejam robustos a múltiplas especificações e testes, algumas limitações importantes devem ser reconhecidas:

3.5.5.1 Desbalanceamento de Covariáveis

Uma limitação potencial identificada na análise é a presença de desbalanceamento nas covariáveis entre grupos tratados e controle. A análise diagnóstica revelou diferenças padronizadas superiores a 0,1 em todas as covariáveis principais, indicando que as micror-regiões que receberam estações meteorológicas diferem sistematicamente daquelas que não receberam em características observáveis como:

- Área plantada (menor nas tratadas)
- População (maior nas tratadas)
- PIB per capita (menor nas tratadas)
- Densidade de estações na UF (maior nas tratadas)

Embora esse desbalanceamento possa levantar preocupações sobre viés de seleção, o estimador *Doubly Robust* foi especificamente escolhido por sua capacidade de mitigar esse problema. O DR permanece consistente quando pelo menos um dos modelos (propensity score ou outcome regression) está corretamente especificado, oferecendo proteção adicional contra má especificação decorrente do desbalanceamento.

3.5.5.2 Composição dos Pesos no Estimador Agregado

A análise da distribuição de pesos implícitos no estimador agregado revelou que coortes iniciais (que têm mais períodos pós-tratamento) representam aproximadamente 50,8% do peso total. Especificamente:

- A correlação entre pesos e períodos pós-tratamento é de 0,428 (moderada)
- Coortes tratadas entre 2006-2008 contribuem desproporcionalmente para o ATT agregado
- Nenhuma coorte individual domina completamente (máximo de 15% do peso total)

Essa concentração de pesos, embora não extrema, sugere que o efeito estimado reflete mais fortemente a experiência das microrregiões que adotaram estações meteorológicas mais cedo. Isso pode limitar a generalização para adotantes tardios se houver heterogeneidade temporal nos efeitos do tratamento.

3.5.5.3 Outras Limitações Importantes

- **Heterogeneidade não observada:** Os efeitos podem variar significativamente por características não observadas como tamanho de propriedade, nível educacional dos produtores, ou acesso a crédito e assistência técnica. Uma análise descritiva preliminar por quartis de área plantada (Figura 8 no Apêndice B) mostra que houve ganhos de produtividade generalizados em todos os quartis durante o período analisado.
- **Externalidades espaciais:** A especificação atual pode não capturar completamente os benefícios que transbordam para microrregiões vizinhas. Embora a inclusão da densidade estadual de estações mitigue parcialmente esse problema, spillovers locais mais granulares podem existir.
- **Complementaridades tecnológicas:** A interação com outras tecnologias agrícolas modernas (GPS, agricultura de precisão, drones) não é modelada explicitamente, potencialmente subestimando os efeitos totais em contextos de adoção tecnológica múltipla.
- **Qualidade e uso efetivo:** A análise assume que a instalação de uma estação implica em disponibilidade e uso das informações meteorológicas, mas variações na qualidade dos dados, manutenção das estações, e capacidade local de interpretação não são observadas.

3.5.5.4 Direções para Pesquisa Futura

Estudos futuros poderiam expandir e fortalecer nossos resultados através de:

- **Modelagem espacial explícita:** Incorporar dependência espacial e spillovers através de modelos econométricos espaciais, permitindo quantificar com precisão os efeitos indiretos das estações em microrregiões vizinhas.
- **Dados de alta frequência:** Utilizar dados mensais ou trimestrais para capturar melhor a dinâmica temporal dos efeitos e sua relação com eventos climáticos específicos.
- **Heterogeneidade por cultura:** Analisar impactos diferenciados por tipo de cultura agrícola, aproveitando dados desagregados da PAM-IBGE.

- **Mecanismos de transmissão:** Investigar empiricamente os canais através dos quais a informação meteorológica se traduz em ganhos de produtividade, possivelmente através de parcerias com produtores locais.

3.6 Síntese dos Resultados Empíricos

A análise empírica estabelece três resultados principais:

1. Magnitude e Significância do Efeito: O ATT estimado de 8.2% representa um ganho econômico substancial, equivalente a mais de dois anos de crescimento típico do setor agropecuário. Este efeito é estatisticamente significativo ($p = 0,0103$) e economicamente relevante.

2. Dinâmica Temporal dos Impactos: O event study revela ausência de tendências pré-tratamento diferenciadas e efeitos positivos pós-tratamento, sugerindo processos de aprendizado e adaptação tecnológica, não apenas um choque único de produtividade.

3. Robustez e Validade Causal: Os resultados sobrevivem a múltiplos testes de robustez:

- Ausência de tendências pré-tratamento (validando parallel trends)
- Testes placebo negativos (descartando confounders não observados)
- Consistência entre diferentes métodos de estimação (DR, IPW, REG)
- Estabilidade temporal (excluindo períodos específicos)
- Especificidade setorial (efeito concentrado no PIB agropecuário)

Estes achados fornecem evidência causal rigorosa sobre o impacto da informação meteorológica na produtividade agrícola, demonstrando que investimentos em infraestrutura de dados climáticos geram retornos econômicos mensuráveis e persistentes.

4 Conclusões Finais

Este trabalho investigou o impacto causal da instalação de estações meteorológicas sobre a produtividade agrícola, contribuindo para a literatura empírica sobre o papel da informação na eficiência produtiva. Utilizando métodos econométricos de fronteira adequados para contextos de adoção escalonada, demonstramos que o acesso a informações meteorológicas precisas e localizadas gera ganhos substanciais de produtividade.

Os resultados têm implicações diretas para o desenho de políticas públicas voltadas ao desenvolvimento agrícola. Em um cenário de mudanças climáticas e pressão crescente sobre os recursos naturais, investimentos em sistemas de informação agrometeorológica emergem como instrumentos fundamentais para aumentar a resiliência e eficiência do setor agrícola.

Do ponto de vista metodológico, este estudo demonstra a importância de utilizar métodos adequados para contextos de tratamento escalonado. O arcabouço de [CALLAWAY e SANT'ANNA \(2021\)](#) permitiu evitar os vieses conhecidos dos estimadores tradicionais, fornecendo estimativas confiáveis dos efeitos causais. A disponibilização completa do código e dados reforça nosso compromisso com a transparência e reprodutibilidade na pesquisa científica.

Ao quantificar rigorosamente os benefícios econômicos da infraestrutura meteorológica, este estudo fornece subsídios para a tomada de decisão sobre alocação de recursos públicos e privados. A evidência apresentada sugere que a expansão da rede de estações meteorológicas deveria ser priorizada como estratégia de desenvolvimento sustentável, com potencial para gerar retornos econômicos significativos e contribuir para a segurança alimentar nacional.

Referências

- BURKE, M. et al. Using satellite imagery to understand and promote sustainable development. **Science**, v. 371, n. 6535, p. eabe8628, 2021. Disponível em: <<https://www.science.org/doi/abs/10.1126/science.abe8628>>. Citado na página 14.
- CALLAWAY, B.; SANT'ANNA, P. H. C. Difference-in-differences with multiple time periods. **Journal of Econometrics**, v. 225, n. 2, p. 200–230, 2021. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0304407620303948>>. Citado 12 vezes nas páginas 13, 14, 15, 16, 18, 19, 20, 22, 24, 25, 42 e 46.
- CARVALHO, A. L. d. et al. Impact of climate changes on potential sugarcane yield in Pernambuco, northeastern region of Brazil. **Renewable Energy**, v. 78, p. 26–34, 2015. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0960148114008507>>. Citado na página 41.
- CROST, B. et al. Climate change, agricultural production and civil conflict: Evidence from the Philippines. **Journal of Environmental Economics and Management**, v. 88, p. 379–395, 2018. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0095069617301584>>. Citado na página 14.
- DAVISON, A. C.; HINKLEY, D. V. **Bootstrap Methods and their Application**. Cambridge: Cambridge University Press, 1997. Disponível em: <<https://doi.org/10.1017/CBO9780511802843>>. Citado na página 34.
- GATTI, N.; BAYLIS, K.; CROST, B. Can irrigation infrastructure mitigate the effect of rainfall shocks on conflict? Evidence from Indonesia. **American Journal of Agricultural Economics**, v. 103, n. 1, p. 211–231, 2021. Disponível em: <<https://onlinelibrary.wiley.com/doi/abs/10.1002/ajae.12092>>. Citado na página 14.
- GOODMAN-BACON, A. Difference-in-differences with variation in treatment timing. **Journal of Econometrics**, v. 225, n. 2, p. 254–277, 2021. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0304407621001445>>. Citado na página 13.
- MARIN, F. R. et al. Sugarcane model intercomparison: Structural differences and uncertainties under current and potential future climates. **Environmental Modelling & Software**, v. 72, p. 372–386, 2015. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S1364815215000766>>. Citado na página 41.
- MAVI, H. S.; TUPPER, G. J. **Agrometeorology: Principles and Applications of Climate Studies in Agriculture**. 1. ed. CRC Press, 2004. Disponível em: <<https://doi.org/10.1201/9781482277999>>. Citado na página 12.
- MINISTÉRIO DA AGRICULTURA E PECUÁRIA. **Ministro Carlos Fávaro assina acordo que garante instalação de 220 novas estações meteorológicas no país**. 2025. Publicado em: 3 set. 2025. Acesso em: 4 set. 2025. Disponível em: <<https://www.gov.br/agricultura/pt-br/assuntos/noticias/ministro-carlos-favaro-assina-acordo-que-garante-instalacao-de-220-novas-estacoes-meteorologicas-no>>. Citado na página 40.

MONTEIRO, J. E. B. A. **Agrometeorologia dos cultivos: o fator meteorológico na produção agrícola**. Brasília, DF: INMET, 2009. 530 p. ISBN 978-85-62817-00-7. Citado na página 12.

MONTEIRO, L. A.; SENTELHAS, P. C. Sugarcane yield gap: can it be determined at national level with a simple agrometeorological model? **Crop and Pasture Science**, v. 68, n. 3, p. 272–284, 2017. Disponível em: <<https://doi.org/10.1071/CP16334>>. Citado 2 vezes nas páginas 14 e 41.

ORTIZ-BOBEA, A. et al. **The Historical Impact of Anthropogenic Climate Change on Global Agricultural Productivity**. 2020. Disponível em: <<https://arxiv.org/abs/2007.10415>>. Citado na página 12.

R Core Team. **R: A Language and Environment for Statistical Computing**. Vienna, Austria, 2025. Disponível em: <<https://www.R-project.org/>>. Citado na página 25.

RIJKS, D.; BARADAS, M. W. The clients for agrometeorological information. **Agricultural and Forest Meteorology**, v. 103, n. 1, p. 27–42, 2000. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0168192300001167>>. Citado na página 12.

SANT'ANNA, P. H. C.; ZHAO, J. Doubly robust difference-in-differences estimators. **Journal of Econometrics**, v. 219, n. 1, p. 101–122, 2020. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0304407620301901>>. Citado na página 22.

SUN, L.; ABRAHAM, S. Estimating dynamic treatment effects in event studies with heterogeneous treatment effects. **Journal of Econometrics**, v. 225, n. 2, p. 175–199, 2021. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S030440762030378X>>. Citado na página 13.

VIANNA, M. d. S.; SENTELHAS, P. C. Performance of DSSAT CSM-CANEGRO under operational conditions and its use in determining the 'saving irrigation' impact on sugarcane crop. **Sugar Tech**, v. 18, n. 1, p. 75–86, 2016. Disponível em: <<https://doi.org/10.1007/s12355-015-0367-0>>. Citado 2 vezes nas páginas 12 e 41.

WEISS, A.; VAN CROWDER, L.; BERNARDI, M. Communicating agrometeorological information to farming communities. **Agricultural and Forest Meteorology**, v. 103, n. 1, p. 185–196, 2000. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0168192300001118>>. Citado na página 12.

Apêndices

APÊNDICE A – Código do GitHub

O código completo utilizado nesta pesquisa, incluindo os scripts de coleta de dados, análise econométrica e geração de visualizações, está disponível no repositório GitHub:

[<https://github.com/danielcavalli/tcc-ie-ufrj-2024>](https://github.com/danielcavalli/tcc-ie-ufrj-2024)

O repositório contém:

- Scripts SQL para extração de dados do BigQuery
- Código Python para processamento e limpeza dos dados
- Scripts R para implementação do modelo de Callaway e Sant’Anna
- Documentação detalhada dos procedimentos metodológicos
- Instruções para reprodução dos resultados


APÊNDICE B – Estatísticas Descritivas Complementares

Este apêndice apresenta estatísticas descritivas complementares que apoiam a análise principal.

B.1 Distribuição Temporal do Tratamento

A Figura 7 apresenta a evolução temporal da instalação de estações meteorológicas:

Figura 7 – Distribuição Temporal da Instalação de Estações Meteorológicas



Nota: O gráfico mostra o número de microrregiões que receberam sua primeira estação meteorológica em cada ano. Observa-se uma concentração significativa de instalações no período 2006-2008, coincidindo com programas federais de expansão da rede meteorológica.

Tabela 6 – Número de microrregiões tratadas por ano

Ano	Microrregiões com Primeira Estação	N Obs
2000	5	105
2001	10	210
2002	14	294
2003	19	399
2004	6	126
2005	2	42
2006	76	1596
2007	70	1470
2008	82	1722
2009	11	231
2010	6	126
2011	3	63
2012	6	126
2013	2	42
2015	2	42
2016	15	315
2017	16	336
2018	5	105
2019	1	21

Tabela 7 – Distribuição do tratamento por região

Região	Microrregiões	Tratadas	% Tratadas
Norte	15	8	53,3%
Nordeste	142	45	31,7%
Centro-Oeste	51	22	43,1%
Sudeste	160	48	30,0%
Sul	26	8	30,8%
Total	490	—	—

B.2 Estatísticas por Região

B.3 Produtividade Média por Status de Tratamento


B.4 Tendências por Quartil de Área Plantada

A Figura 8 apresenta a evolução do PIB agropecuário para grupos tratados e controle, separados por quartis de área plantada:

Tabela 8 – Produtividade média (ton/ha) por período

Período	Nunca Tratadas	Ainda Não Tratadas	Já Tratadas	Diferença
2000-2007	71,2	72,8	73,5	0,7
2008-2014	72,5	74,3	78,9	4,6
2015-2021	74,1	75,2	83,7	8,5

Figura 8 – Tendências do PIB Agropecuário por Quartil de Área Plantada



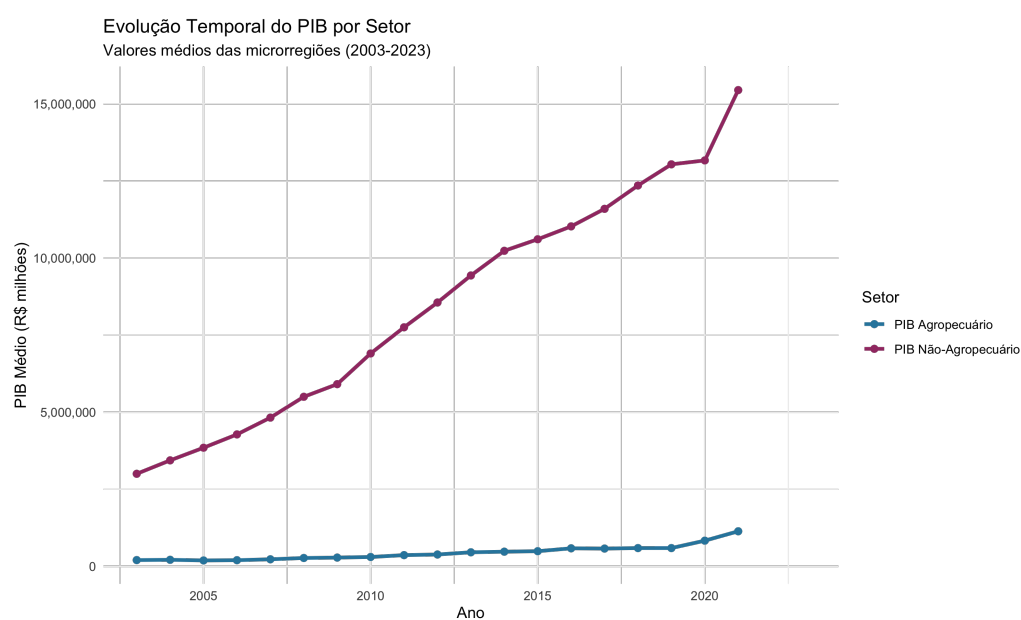
Nota: Os gráficos mostram a evolução do log do PIB agropecuário para grupos tratados (azul) e controle (área sombreada) em cada quartil de área plantada (Q1 = menor área, Q4 = maior área). A linha vertical tracejada indica o período de início da instalação das estações. Observa-se que houve ganhos de produtividade em todos os quartis ao longo do período analisado, independentemente do tamanho da área plantada, demonstrando a dinâmica positiva generalizada do setor agrícola.

B.5 Análises Descritivas Complementares

A Figura 9 apresenta a evolução temporal comparativa entre PIB agropecuário e não-agropecuário:


A Figura 10 apresenta a matriz de correlação entre as principais variáveis utilizadas no estudo:

Figura 9 – Evolução Temporal do PIB Agropecuário vs PIB Não-Agropecuário



Nota: O gráfico mostra a evolução temporal do PIB agropecuário e do PIB não-agropecuário médio (em log) para as microrregiões da amostra. A comparação permite visualizar as dinâmicas distintas entre os setores ao longo do período analisado.

Figura 10 – Matriz de Correlação das Variáveis Principais



Nota: A matriz mostra as correlações entre PIB agropecuário, área plantada, população, precipitação e outras variáveis relevantes. Valores mais próximos de 1 indicam correlação positiva forte.